Práctica 7
Algoritmos de Clasificación en R

Presentado por:
Miguel Angel Deza Cuela

Maestría en Ciencia de Datos – UNSA

Introducción a Ciencia de Datos

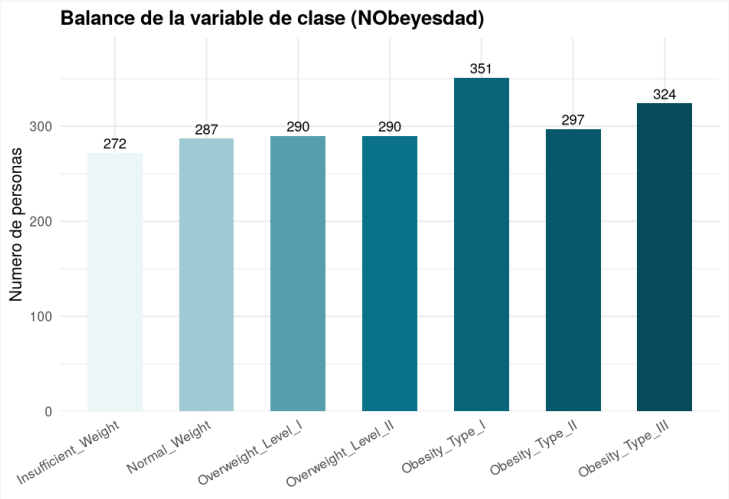
Docente: Yessenia Deysi Yari Ramos

Arequipa, Perú

Septiembre, 2026

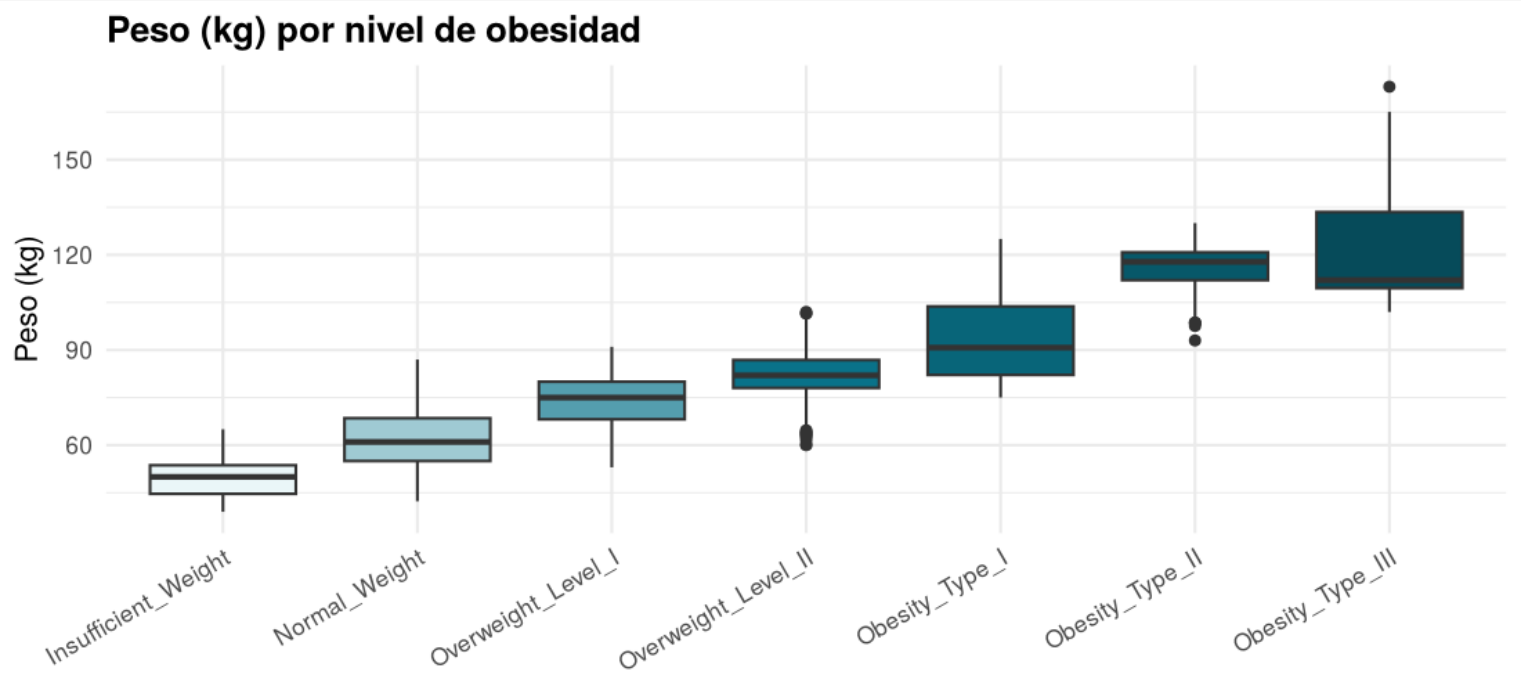
◎ Objetivo y dataset elegido

- **Objetivo**
  Explorar y comparar cinco algoritmos de clasificación en R con el paquete **caret**.
- **Obesity Levels (Kaggle)**
  Nivel de obesidad de personas de **México, Perú y Colombia** según sus hábitos alimenticios y actividad física.
- **Tamaño**
  2111 personas, 16 predictores y la clase `NObeyesdad` con **7 niveles**.
- **Calidad**
  Sin valores faltantes y con clases balanceadas (12.9 % – 16.6 % por nivel).



Balance de la variable de clase

Análisis exploratorio



Peso vs. nivel

La relación es monótona: a más peso, mayor nivel de obesidad (la clase se construye a partir del IMC).

Correlaciones

`Height`–`Weight` es la más fuerte (0.46); `Age`–`TUE` la única negativa relevante (-0.30).

Preprocesamiento



Correlación entre predictores numéricos

- **Sin imputación**
  No hay valores `NA` en ninguna de las 17 columnas.
- **Categóricas a dummies**
  Las 8 columnas categóricas quedan como `factor` y `train()` las convierte a variables dummy.
- **Centrado y escalado**
  Necesario para kNN y SVM, que son sensibles a la escala de las variables.
- **Partición 80/20**
  1691 filas de entrenamiento y 420 de prueba, estratificadas con `createDataPartition`.

Algoritmos ejecutados

LDA
Discriminante lineal

CART
Árbol de decisión

kNN
k vecinos

SVM
Kernel lineal

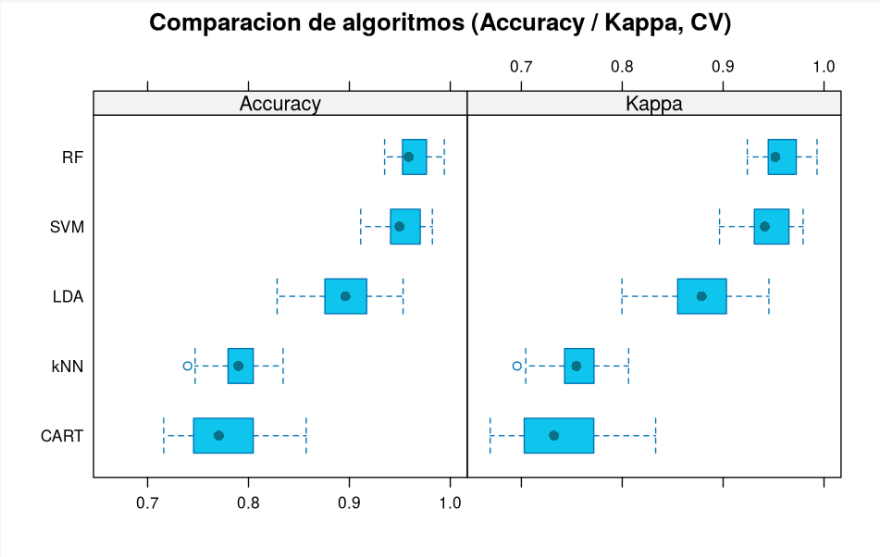
RF
Random Forest

Todos con la misma validación cruzada: **10 pliegues** $\times$ **3 repeticiones**, métrica **Accuracy**:

```
control <- trainControl(method = "repeatedcv",
                        number = 10, repeats = 3)
fit <- train(NObeyesdad ~ ., data = train, method = m,
             metric = "Accuracy", trControl = control)
# m = "lda", "rpart", "knn", "svmLinear", "rf"
```

Evaluación de los algoritmos

Modelo	Acc. CV	Acc. test	Kappa	Sensib.	Especif.
LDA	0.896	0.879	0.858	0.875	0.980
CART	0.777	0.783	0.747	0.789	0.964
kNN	0.790	0.819	0.789	0.815	0.970
SVM lineal	0.951	0.943	0.933	0.941	0.991
Random Forest	**0.965**	**0.969**	**0.964**	**0.969**	**0.995**



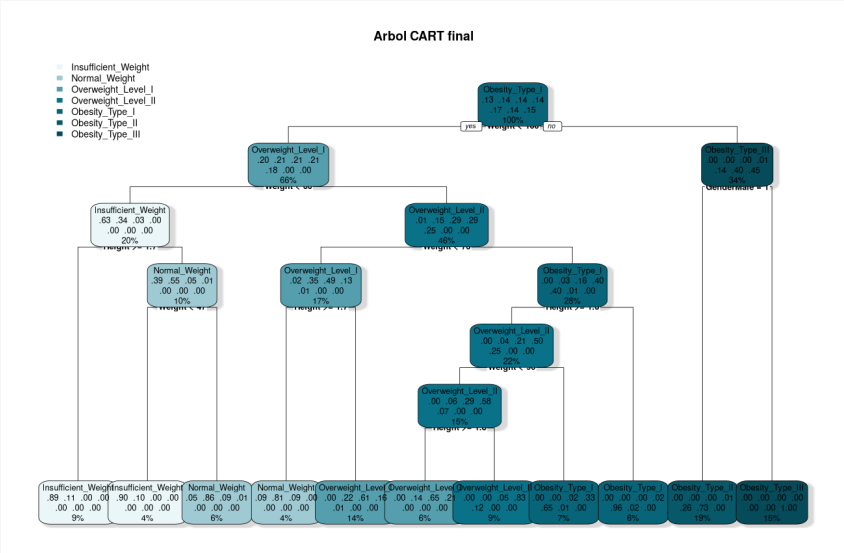
Ganador: Random Forest

96.9 % de accuracy en prueba (420 personas).

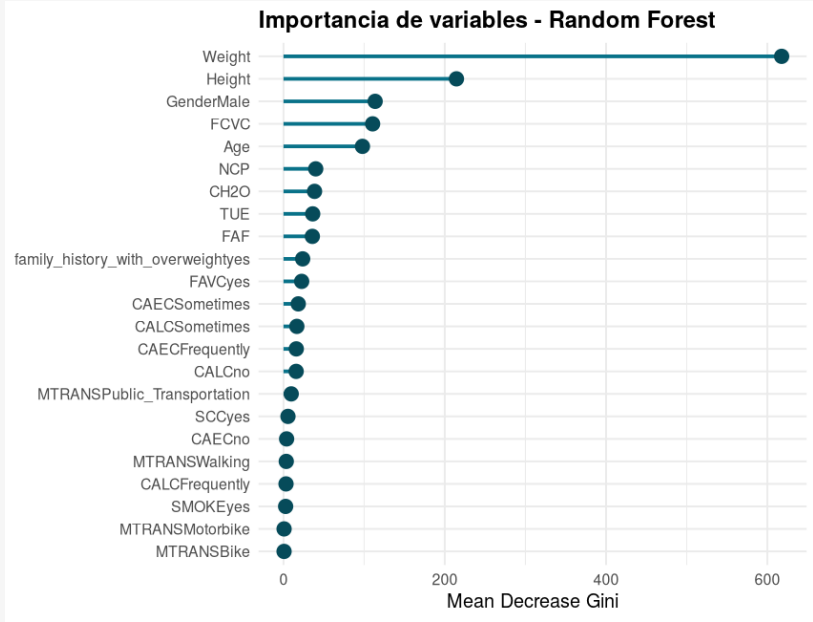
Jerarquía clara

RF > SVM > LDA > kNN > CART, igual en CV y en el conjunto de prueba.

¿Qué aprendieron los modelos?



Árbol CART final



Importancia de variables (Random Forest)

Peso y altura dominan

CART y Random Forest coinciden: `Weight` y `Height` son los predictores más fuertes, lógico porque la clase se deriva del IMC (peso / altura^2).

Predicciones con Random Forest

Muestra del set de prueba
6 personas elegidas al azar: **6 de 6 aciertos**.

Real	Predicción
Obesity_Type_I	Obesity_Type_I
Obesity_Type_III	Obesity_Type_III
Insufficient_Weight	Insufficient_Weight
Overweight_Level_II	Overweight_Level_II
Obesity_Type_I	Obesity_Type_I
Overweight_Level_II	Overweight_Level_II

Persona nueva (hipotética)
Varón de 27 años, 1.72 m, 88 kg, historial familiar de sobrepeso, poca actividad física.

Predicción:
Overweight_Level_II
probabilidad **85.4 %**

IMC $\approx$ 29.7, coherente con el rango de esa categoría.

Conclusiones

Random Forest es el mejor modelo

96.9 % de accuracy y Kappa 0.964 en prueba; SVM lineal queda muy cerca (94.3 %).

Los modelos simples se quedan cortos

CART (78.3 %) no captura bien las fronteras entre niveles con un solo árbol; un ensamble o un margen lineal lo logran.

LDA tiene una limitación real

Avisó *variables are collinear* por las dummies con niveles muy raros, aunque igual alcanzó 87.9 %.

caret unifica todo el flujo

Misma partición, validación cruzada y métricas para los cinco algoritmos: la comparación es justa y reproducible.

¡Gracias!