MAESTRÍA EN CIENCIA DE DATOS

Estimación por Máxima Verosimilitud

Ejercicios 5.2.1 – 5.2.16

Solución de la lista de ejercicios:
EMV con muestras observadas, ajuste a datos agrupados, soporte dependiente del parámetro y fórmulas generales

Elaborado por: Miguel Deza
Programa: Maestría en Ciencia de Datos – UNSA
Unidad: I – Fundamentos Matemáticos
Docente: Carlos Antonio Abanto Valle

Fecha: 25 de octubre de 2026

Índice

1. EMV con muestras observadas **2**
Ejercicio 5.2.1 . . . 3
Ejercicio 5.2.2 . . . 4
Ejercicio 5.2.3 . . . 5
Ejercicio 5.2.4 . . . 6
Ejercicio 5.2.5 . . . 7
Ejercicio 5.2.6 . . . 8
Ejercicio 5.2.7 . . . 9

2. Ajuste a datos agrupados **10**
Ejercicio 5.2.8 . . . 11
Ejercicio 5.2.9 . . . 12

3. Soporte que depende del parámetro **13**
Ejercicio 5.2.10 . . . 14
Ejercicio 5.2.11 . . . 15
Ejercicio 5.2.12 . . . 16

4. Fórmulas generales del EMV **17**
Ejercicio 5.2.13 . . . 18
Ejercicio 5.2.14 . . . 19
Ejercicio 5.2.15 . . . 20
Ejercicio 5.2.16 . . . 21

1

SECCIÓN

EMV con muestras observadas

Ejercicios 5.2.1 – 5.2.7

Ejercicio 5.2.1

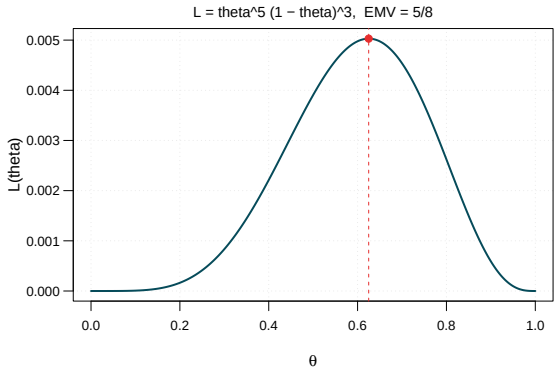
Una muestra aleatoria de tamaño 8 — $x_1 = 1, x_2 = 0, x_3 = 1, x_4 = 1, x_5 = 0, x_6 = 1, x_7 = 1$ y $x_8 = 0$ — se toma de la función de probabilidad $p_X(k;\theta) = \theta^k(1-\theta)^{1-k},\ k = 0{,}1,\ 0 < \theta < 1$. Encuentre el EMV para θ.

$$L(\theta) = \prod_{i=1}^{8} \theta^{x_i}(1-\theta)^{1-x_i} = \theta^{\sum x_i}(1-\theta)^{8-\sum x_i}, \qquad \sum_{i=1}^{8} x_i = 5$$

$$L(\theta) = \theta^5(1-\theta)^3 \quad \Rightarrow \quad \ln L(\theta) = 5\ln\theta + 3\ln(1-\theta)$$

$$\frac{d\ln L}{d\theta} = \frac{5}{\theta} - \frac{3}{1-\theta} = 0 \ \Rightarrow\ 5(1-\theta) = 3\theta \ \Rightarrow\ \theta = \frac{5}{8}$$

$$\frac{d^2\ln L}{d\theta^2} = -\frac{5}{\theta^2} - \frac{3}{(1-\theta)^2} < 0 \quad \Rightarrow \quad \text{máximo}$$




```
# Ej 5.2.1: Bernoulli, 5 unos en n = 8
abrir("ej521-bernoulli")
curva(function(t) t^5 * (1 - t)^3, 0, 1, 5/
    8, ylab = "L(theta)")
titulo("L = theta^5 (1 - theta)^3,  EMV = 5
    /8")
dev.off()
```

Figura 1: *Verosimilitud de la muestra Bernoulli.*

Resultado. $\hat{\theta} = \dfrac{5}{8} = 0{,}625$ (la proporción muestral de unos).

Ejercicio 5.2.2

El número de fichas rojas y blancas en una urna es desconocido, pero la proporción p de fichas rojas es $1/3$ o $1/2$. Una muestra de tamaño 5, con reemplazo, produce: roja, blanca, blanca, roja, blanca. ¿Cuál es el EMV para p?

$$L(p) = p^2(1-p)^3, \qquad p \in \left\{\tfrac{1}{3}, \tfrac{1}{2}\right\}$$

$$L\left(\tfrac{1}{3}\right) = \left(\tfrac{1}{3}\right)^2\left(\tfrac{2}{3}\right)^3 = \frac{8}{243} = 0{,}03292$$

$$L\left(\tfrac{1}{2}\right) = \left(\tfrac{1}{2}\right)^5 = \frac{1}{32} = 0{,}03125$$

$$L\left(\tfrac{1}{3}\right) > L\left(\tfrac{1}{2}\right) \quad \Rightarrow \quad \hat{p} = \tfrac{1}{3}$$

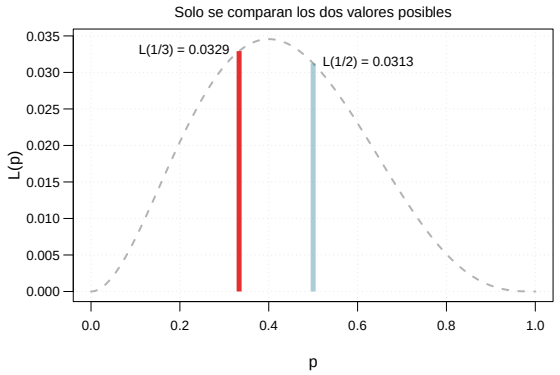


Figura 2: *Verosimilitud evaluada solo en los dos valores admisibles.*

```
# Ej 5.2.2: urna, p solo puede ser 1/3 o 1/
    2
abrir("ej522-urna")
L <- function(p) p^2 * (1 - p)^3
curve(L(x), 0, 1, n = 500, lwd = 2, col = "
    gray70", lty = 2, xlab = "p", ylab = "L
    (p)",
      panel.first = grid(col = "gray90"))
segments(c(1/3, 1/2), 0, c(1/3, 1/2), L(c(1
    /3, 1/2)), lwd = 5, lend = 1, col = c(
    rojo, base))
text(c(1/3, 1/2), L(c(1/3, 1/2)), c("L(1/3)
     = 0.0329", "L(1/2) = 0.0313"),
     pos = c(2, 4), cex = 0.8)
titulo("Solo se comparan los dos valores
    posibles")
dev.off()
```

Resultado. $\hat{p} = \dfrac{1}{3}$.

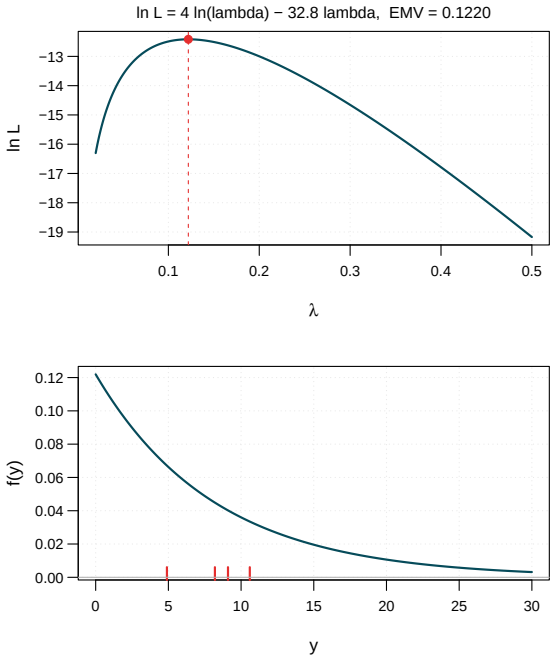
Ejercicio 5.2.3

Use la muestra $y_1 = 8{,}2$, $y_2 = 9{,}1$, $y_3 = 10{,}6$ y $y_4 = 4{,}9$ para calcular el EMV de λ en la pdf exponencial $f_Y(y;\lambda) = \lambda e^{-\lambda y},\ y \geq 0$.

$$L(\lambda) = \prod_{i=1}^{n} \lambda e^{-\lambda y_i} = \lambda^n e^{-\lambda \sum y_i} \quad \Rightarrow \quad \ln L(\lambda) = n \ln \lambda - \lambda \sum y_i$$

$$\frac{d \ln L}{d\lambda} = \frac{n}{\lambda} - \sum y_i = 0 \ \Rightarrow \ \hat{\lambda} = \frac{n}{\sum y_i} = \frac{1}{\bar{y}}$$

$$\sum y_i = 8{,}2 + 9{,}1 + 10{,}6 + 4{,}9 = 32{,}8 \quad \Rightarrow \quad \hat{\lambda} = \frac{4}{32{,}8} = 0{,}1220$$




```
# Ej 5.2.3: exponencial
abrir("ej523-exponencial", w = 5.5, h =
    6.4)
par(mfrow = c(2, 1))
y <- c(8.2, 9.1, 10.6, 4.9); lh <- 4 / sum(
    y)
curva(function(l) 4 * log(l) - l * sum(y),
    0.02, 0.5, lh, xlab = expression(lambda
    ))
titulo("ln L = 4 ln(lambda) - 32.8 lambda,
     EMV = 0.1220")
ajuste(function(x) dexp(x, lh), 0, 30, y)
dev.off()
```

Figura 3: *Log-verosimilitud (arriba) y densidad ajustada con los datos (abajo).*

Resultado. $\hat{\lambda} = \dfrac{1}{\bar{y}} = 0{,}1220.$

Ejercicio 5.2.4

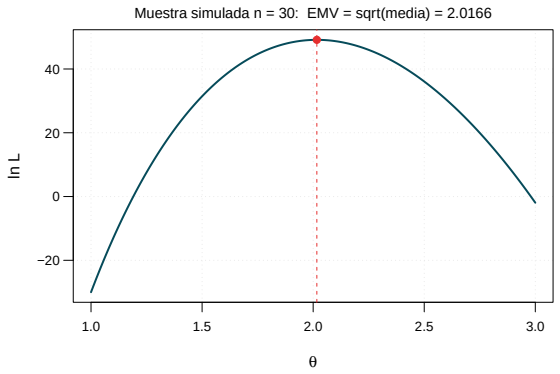
Suponga que una muestra aleatoria de tamaño n proviene del modelo $p_X(k;\theta) = \dfrac{\theta^{2k}e^{-\theta^2}}{k!}$, $k = 0,1,2,\ldots$ Encuentre una fórmula para el EMV $\hat{\theta}$.

$$L(\theta) = \prod_{i=1}^{n} \frac{\theta^{2k_i}e^{-\theta^2}}{k_i!} = \frac{\theta^{2\sum k_i}e^{-n\theta^2}}{\prod k_i!}$$

$$\ln L(\theta) = 2\ln\theta \sum k_i - n\theta^2 - \sum \ln k_i!$$

$$\frac{d\ln L}{d\theta} = \frac{2\sum k_i}{\theta} - 2n\theta = 0 \;\Rightarrow\; \theta^2 = \frac{\sum k_i}{n} = \bar{k}$$

$$\frac{d^2\ln L}{d\theta^2} = -\frac{2\sum k_i}{\theta^2} - 2n < 0$$




```
# Ej 5.2.4: p(k; theta) = theta^(2k) e^(-theta^2) / k!  (muestra simulada)
abrir("ej524-poisson-theta2")
set.seed(1); k <- rpois(30, 4)
curva(function(t) 2 * sum(k) * log(t) - 30 * t^2, 1, 3, sqrt(mean(k)))
titulo("Muestra simulada n = 30:  EMV = sqrt(media) = 2.0166")
dev.off()
```

Figura 4: *Ilustración con una muestra simulada* ($\theta^2 = 4$, $n = 30$).

Resultado. $\hat{\theta} = \sqrt{\bar{k}} = \sqrt{\dfrac{1}{n}\sum_{i=1}^{n} k_i}$ (es una Poisson con media θ^2).

Ejercicio 5.2.5

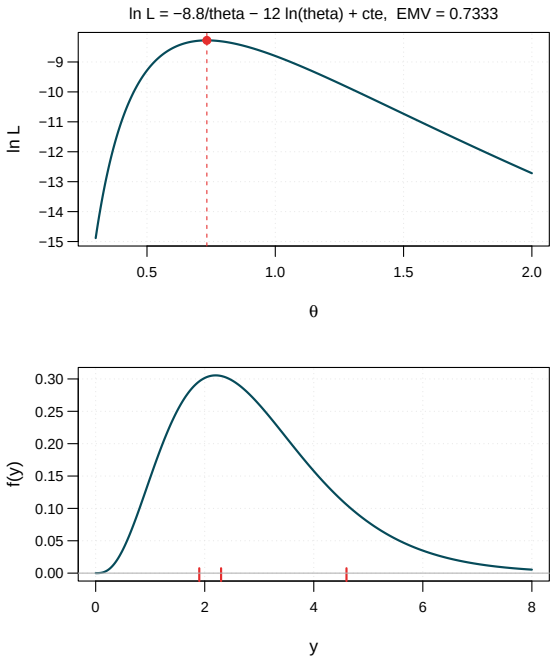
Dado que $y_1 = 2{,}3$, $y_2 = 1{,}9$ y $y_3 = 4{,}6$ es una muestra aleatoria de $f_Y(y;\theta) = \dfrac{y^3 e^{-y/\theta}}{6\theta^4}$, $y \geq 0$, calcule el EMV para θ.

$$L(\theta) = \prod_{i=1}^{n} \frac{y_i^3 e^{-y_i/\theta}}{6\theta^4} = \frac{\left(\prod y_i\right)^3 e^{-\sum y_i/\theta}}{6^n \theta^{4n}}$$

$$\ln L(\theta) = 3\sum \ln y_i - \frac{\sum y_i}{\theta} - n\ln 6 - 4n\ln\theta$$

$$\frac{d\ln L}{d\theta} = \frac{\sum y_i}{\theta^2} - \frac{4n}{\theta} = 0 \;\Rightarrow\; \hat\theta = \frac{\sum y_i}{4n} = \frac{\bar y}{4}$$

$$\sum y_i = 2{,}3 + 1{,}9 + 4{,}6 = 8{,}8 \quad \Rightarrow \quad \hat\theta = \frac{8{,}8}{4(3)} = 0{,}7333$$




```
# Ej 5.2.5: gamma con forma 4 y escala theta
abrir("ej525-gamma", w = 5.5, h = 6.4)
par(mfrow = c(2, 1))
y <- c(2.3, 1.9, 4.6); th <- sum(y) / 12
curva(function(t) -sum(y) / t - 12 * log(t), 0.3, 2, th)
titulo("ln L = -8.8/theta - 12 ln(theta) + cte,  EMV = 0.7333")
ajuste(function(x) x^3 * exp(-x / th) / (6 * th^4), 0, 8, y)
dev.off()
```

Figura 5: *Log-verosimilitud (arriba) y densidad ajustada (abajo).*

Resultado. $\hat\theta = \dfrac{\bar y}{4} = 0{,}7333$.

Ejercicio 5.2.6

Use el método de máxima verosimilitud para estimar θ en $f_Y(y;\theta) = \theta^2\sqrt{y}\,e^{-\theta\sqrt{y}},\ y \geq 0$. Evalúe $\hat{\theta}$ para la muestra $y_1 = 6{,}2$, $y_2 = 7{,}0$, $y_3 = 2{,}5$, $y_4 = 4{,}2$.

$$L(\theta) = \theta^{2n}\prod\sqrt{y_i}\;e^{-\theta\sum\sqrt{y_i}} \quad\Rightarrow\quad \ln L(\theta) = 2n\ln\theta + \tfrac{1}{2}\sum\ln y_i - \theta\sum\sqrt{y_i}$$

$$\frac{d\ln L}{d\theta} = \frac{2n}{\theta} - \sum\sqrt{y_i} = 0 \;\Rightarrow\; \hat{\theta} = \frac{2n}{\sum\sqrt{y_i}}$$

$$\sum\sqrt{y_i} = 2{,}4900 + 2{,}6458 + 1{,}5811 + 2{,}0494 = 8{,}7663$$

$$\hat{\theta} = \frac{2(4)}{8{,}7663} = 0{,}9126$$

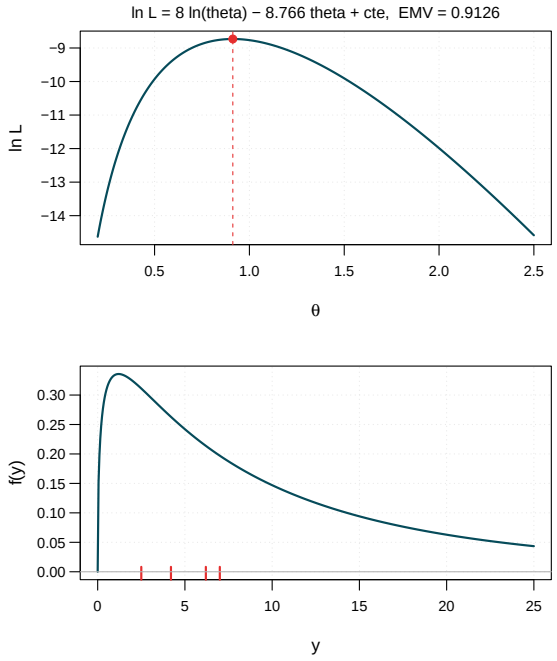


Figura 6: *Log-verosimilitud (arriba) y densidad ajustada (abajo).*

```
# Ej 5.2.6: f(y) = theta^2 sqrt(y) exp(-
    theta sqrt(y))
abrir("ej526-raiz", w = 5.5, h = 6.4)
par(mfrow = c(2, 1))
y <- c(6.2, 7.0, 2.5, 4.2); th <- 8 / sum(
    sqrt(y))
curva(function(t) 8 * log(t) - t * sum(sqrt
    (y)), 0.2, 2.5, th)
titulo("ln L = 8 ln(theta) - 8.766 theta +
    cte,  EMV = 0.9126")
ajuste(function(x) th^2 * sqrt(x) * exp(-th
     * sqrt(x)), 0, 25, y)
dev.off()
```

Resultado. $\hat{\theta} = \dfrac{2n}{\sum\sqrt{y_i}} = 0{,}9126.$

Ejercicio 5.2.7

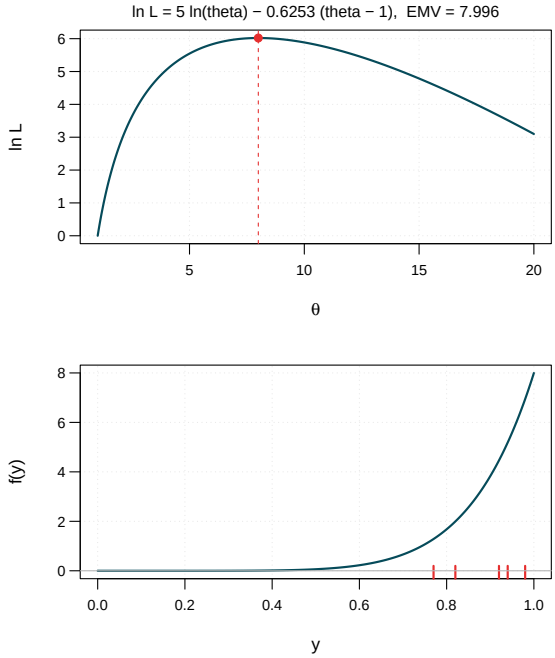
Un ingeniero modela la proporción completada de las tareas con la pdf $f_Y(y;\theta) = \theta y^{\theta-1}$, $0 \le y \le 1,\ \theta > 0$. Las proporciones completadas en su proyecto anterior fueron 0,77; 0,82; 0,92; 0,94 y 0,98. Estime θ.

$$L(\theta) = \theta^n \prod y_i^{\theta-1} \quad \Rightarrow \quad \ln L(\theta) = n\ln\theta + (\theta-1)\sum \ln y_i$$

$$\frac{d\ln L}{d\theta} = \frac{n}{\theta} + \sum \ln y_i = 0 \ \Rightarrow\ \hat\theta = -\frac{n}{\sum \ln y_i}$$

y_i	0,77	0,82	0,92	0,94	0,98	Σ
$\ln y_i$	$-0{,}2614$	$-0{,}1985$	$-0{,}0834$	$-0{,}0619$	$-0{,}0202$	$-0{,}6253$

$$\hat\theta = -\frac{5}{-0{,}6253} = 7{,}996$$




```
# Ej 5.2.7: f(y) = theta y^(theta - 1) en [0, 1]
abrir("ej527-proporciones", w = 5.5, h = 6.4)
par(mfrow = c(2, 1))
y <- c(0.77, 0.82, 0.92, 0.94, 0.98); th <- -5 / sum(log(y))
curva(function(t) 5 * log(t) + (t - 1) * sum(log(y)), 1, 20, th)
titulo("ln L = 5 ln(theta) - 0.6253 (theta - 1),  EMV = 7.996")
ajuste(function(x) th * x^(th - 1), 0, 1, y)
dev.off()
```

Figura 7: *Log-verosimilitud (arriba) y densidad ajustada (abajo).*

Resultado. $\hat\theta = -\dfrac{n}{\sum \ln y_i} = 7{,}996.$

2

SECCIÓN

Ajuste a datos agrupados

Ejercicios 5.2.8 – 5.2.9

Ejercicio 5.2.8

Los datos muestran el número de ocupantes en automóviles observados durante una hora en una intersección de Los Ángeles. Suponga una distribución geométrica $p_X(k;p) = (1-p)^{k-1}p$, $k = 1,2,\ldots$ Estime p y compare las frecuencias observadas y esperadas.

Ocupantes	1	2	3	4	5	6+
Frecuencia	678	227	56	28	8	14

$n = 1011$. La clase 6+ solo informa $X \geq 6$, con $P(X \geq 6) = (1-p)^5$:

$$L(p) = \prod_{k=1}^{5} \left[p(1-p)^{k-1}\right]^{n_k} \cdot \left[(1-p)^5\right]^{14}$$

$$\ln L(p) = \Big(\sum_{k=1}^{5} n_k\Big)\ln p + \Big(\sum_{k=1}^{5}(k-1)n_k + 5(14)\Big)\ln(1-p) = 997\ln p + 525\ln(1-p)$$

$$\frac{997}{p} - \frac{525}{1-p} = 0 \;\Rightarrow\; \hat{p} = \frac{997}{1522} = 0{,}6551$$

Frecuencias esperadas $E_k = 1011\,\hat{p}(1-\hat{p})^{k-1}$, $E_{6+} = 1011(1-\hat{p})^5$:

k	1	2	3	4	5	6+	Σ
Observada	678	227	56	28	8	14	1011
Esperada	662,3	228,4	78,8	27,2	9,4	4,9	1011
$(O-E)^2/E$	0,37	0,01	6,60	0,02	0,20	16,64	23,84

$$\chi^2 = 23{,}84, \qquad gl = 6-1-1 = 4, \qquad \text{valor-}p = 0{,}00009$$

Comparación: el ajuste es muy bueno para 1, 2, 4 y 5 ocupantes, pero hay menos autos con 3 de lo esperado y casi el triple de autos con 6 o más (14 frente a 4,9): la cola real es más pesada que la geométrica.

Nota: si se toma 6+ como exactamente 6, $\hat{p} = 1/\bar{k} = 1011/1536 = 0{,}6582$, casi igual.

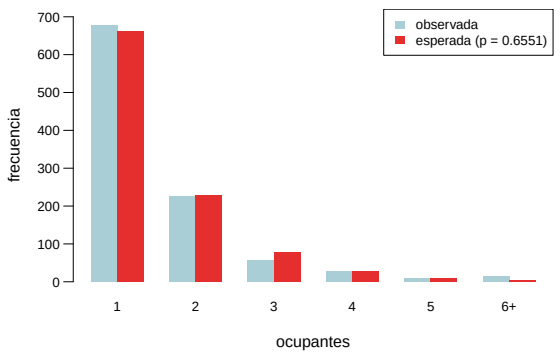


Figura 8: *Frecuencias observadas y esperadas.*

```
# Ej 5.2.8: ocupantes por auto, geometrica
    con la clase 6+ censurada
abrir("ej528-ocupantes")
obs <- c(678, 227, 56, 28, 8, 14); p <- 997
    / 1522
esp <- 1011 * c(p * (1 - p)^(0:4), (1 - p)
    ^5)
barplot(rbind(obs, esp), beside = TRUE,
    names.arg = c(1:5, "6+"), col = c(base,
    rojo),
        border = NA, xlab = "ocupantes",
            ylab = "frecuencia", ylim = c
            (0, 720))
legend("topright", c("observada", "esperada
    (p = 0.6551)"), fill = c(base, rojo),
        border = NA, bg = "white", cex =
            0.8)
dev.off()
```

Resultado. $\hat{p} = 0{,}6551$; la geométrica describe bien los autos con 1–2 ocupantes, pero subestima los de 6+ ($\chi^2 = 23{,}8$).

Ejercicio 5.2.9

En las temporadas de Grandes Ligas de Béisbol desde 1950 hasta 2008, hubo 59 juegos de nueve entradas en los cuales un equipo no logró ningún hit. Suponga una distribución Poisson $p_X(k;\lambda) = e^{-\lambda}\lambda^k/k!$. (a) Estime λ y compare las frecuencias observadas y esperadas. (b) ¿Le sorprende el acuerdo o desacuerdo observado? Explique.

No-hitters	0	1	2	3	4+
Frecuencia	6	19	12	13	9

(a) $n = 59$, clase 4+ censurada: $\ln L(\lambda) = \sum_{k=0}^{3} n_k\,(-\lambda + k\ln\lambda - \ln k!) + 9\ln P(X \geq 4)$

$$\frac{d\ln L}{d\lambda} = \frac{\sum_{k\leq 3} k\,n_k}{\lambda} - 50 + 9\,\frac{p_X(3;\lambda)}{P(X\geq 4)} = 0, \qquad \sum_{k\leq 3} k\,n_k = 19 + 24 + 39 = 82$$

$$\Rightarrow\ \hat\lambda = 2{,}085 \ \text{(solución numérica)}$$

k	0	1	2	3	4+	Σ
Observada	6	19	12	13	9	59
Esperada	7,34	15,29	15,94	11,08	9,35	59

$$\chi^2 = 2{,}46, \qquad gl = 3, \qquad \text{valor-}p = 0{,}48 \qquad \left(\text{con 4+} = 4:\ \hat\lambda = \tfrac{118}{59} = 2{,}00\right)$$

(b) **No sorprende el acuerdo.** Cada temporada tiene miles de partidos y cada uno tiene una probabilidad muy pequeña e independiente de ser no-hitter: eventos raros, donde la binomial se aproxima por una Poisson.

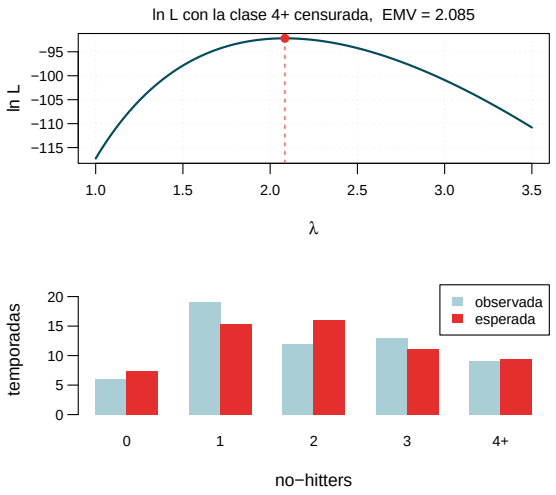


Figura 9: *Log-verosimilitud (arriba) y frecuencias observadas vs esperadas (abajo).*

```
# Ej 5.2.9: no-hitters por temporada,
    Poisson con la clase 4+ censurada
abrir("ej529-no-hitters", w = 5.5, h = 4.8)
par(mfrow = c(2, 1))
f <- c(6, 19, 12, 13, 9)
lnL <- function(l) sum(f[1:4] * dpois(0:3,
    l, log = TRUE)) +
  f[5] * ppois(3, l, lower.tail = FALSE,
      log.p = TRUE)
lh <- optimize(function(l) -lnL(l), c(0.5,
    5))$minimum
curva(Vectorize(lnL), 1, 3.5, lh, xlab =
    expression(lambda))
titulo("ln L con la clase 4+ censurada,
    EMV = 2.085")
esp <- 59 * c(dpois(0:3, lh), 1 - ppois(3,
    lh))
barplot(rbind(f, esp), beside = TRUE, names
    .arg = c(0:3, "4+"), col = c(base, rojo
    ),
        border = NA, xlab = "no-hitters",
            ylab = "temporadas", ylim = c
            (0, 22))
legend("topright", c("observada", "esperada
    "), fill = c(base, rojo), border = NA,
       bg = "white", cex = 0.8)
dev.off()
```

Resultado. $\hat\lambda = 2{,}085\ (\approx 2)$; buen acuerdo ($\chi^2 = 2{,}46$, valor-$p = 0{,}48$), esperable para eventos raros.

3

SECCIÓN

Soporte que depende del parámetro

Ejercicios 5.2.10 – 5.2.12

Ejercicio 5.2.10

(a) Con la muestra $Y_1 = 6{,}3$, $Y_2 = 1{,}8$, $Y_3 = 14{,}2$, $Y_4 = 7{,}6$, use máxima verosimilitud para estimar θ en la pdf uniforme $f_Y(y;\theta) = 1/\theta,\ 0 \le y \le \theta$. (b) Si la muestra proviene de la uniforme $f_Y(y;\theta_1,\theta_2) = \dfrac{1}{\theta_2 - \theta_1},\ \theta_1 \le y \le \theta_2$, encuentre los EMV de θ_1 y θ_2.

(a)

$$L(\theta) = \prod_{i=1}^{4} \frac{1}{\theta}\, \mathbb{1}(0 \le y_i \le \theta) = \begin{cases} \theta^{-4} & \theta \ge y_{\text{máx}} \\ 0 & \theta < y_{\text{máx}} \end{cases}$$

θ^{-4} es decreciente $\Rightarrow$ el máximo está en el menor θ admisible:

$$\hat{\theta} = y_{\text{máx}} = \text{máx}(6{,}3;\ 1{,}8;\ 14{,}2;\ 7{,}6) = 14{,}2$$

(b)

$$L(\theta_1,\theta_2) = \begin{cases} (\theta_2 - \theta_1)^{-n} & \theta_1 \le y_{\text{mín}},\ \theta_2 \ge y_{\text{máx}} \\ 0 & \text{en otro caso} \end{cases}$$

L crece al reducir $\theta_2 - \theta_1 \Rightarrow \theta_1$ lo más grande y θ_2 lo más pequeño posible:

$$\hat{\theta}_1 = y_{\text{mín}} = 1{,}8, \qquad \hat{\theta}_2 = y_{\text{máx}} = 14{,}2$$

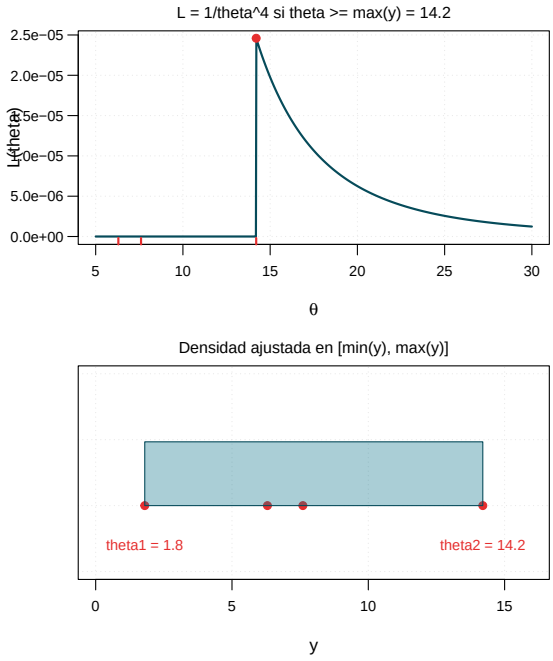


Figura 10: *Verosimilitud de la uniforme (arriba) y densidad ajustada de dos parámetros (abajo).*

```
# Ej 5.2.10: uniforme en [0, theta] y en [
    theta1, theta2]
abrir("ej5210-uniforme", w = 5.5, h = 6.4)
par(mfrow = c(2, 1))
y <- c(6.3, 1.8, 14.2, 7.6)
curve(ifelse(x >= 14.2, x^-4, 0), 5, 30, n
    = 1000, lwd = 2, col = azul,
      xlab = expression(theta), ylab = "L(
          theta)", panel.first = grid(col =
           "gray90"))
points(14.2, 14.2^-4, pch = 19, col = rojo)
rug(y, col = rojo, lwd = 2)
titulo("L = 1/theta^4 si theta >= max(y) =
    14.2")
plot(y, rep(0, 4), pch = 19, col = rojo,
    ylim = c(-0.5, 1), xlim = c(0, 16),
    yaxt = "n",
     xlab = "y", ylab = "", panel.first =
         grid(col = "gray90"))
rect(1.8, 0, 14.2, 1 / (14.2 - 1.8) * 6,
    col = base, border = azul)
text(c(1.8, 14.2), -0.3, c("theta1 = 1.8",
    "theta2 = 14.2"), col = rojo, cex =
    0.8)
titulo("Densidad ajustada en [min(y), max(y
    )]")
dev.off()
```

Resultado. (a) $\hat{\theta} = y_{\text{máx}} = 14{,}2$. (b) $\hat{\theta}_1 = y_{\text{mín}} = 1{,}8,\ \hat{\theta}_2 = y_{\text{máx}} = 14{,}2$.

Ejercicio 5.2.11

Encuentre el EMV de θ en $f_Y(y;\theta) = \dfrac{2y}{1-\theta^2}$, $\theta \le y \le 1$, si una muestra de tamaño 6 produjo: 0,70; 0,63; 0,92; 0,86; 0,43; 0,21.

$$L(\theta) = \frac{2^6 \prod y_i}{(1-\theta^2)^6} \mathbb{1}(\theta \le y_{\text{mín}})$$

$$\frac{d}{d\theta}(1-\theta^2)^{-6} = \frac{12\,\theta}{(1-\theta^2)^7} > 0 \quad (0 < \theta < 1) \quad \Rightarrow \quad L \text{ creciente en } \theta$$

$$\theta \le y_{\text{mín}} \quad \Rightarrow \quad \hat{\theta} = y_{\text{mín}} = 0{,}21$$

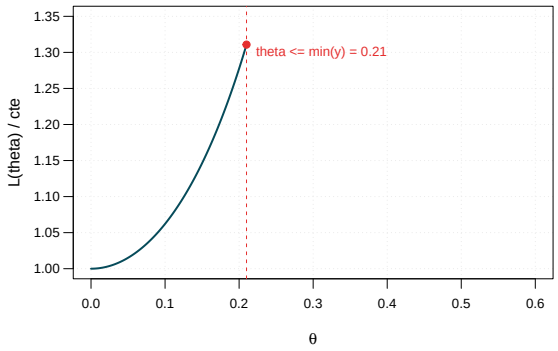


Figura 11: *$L(\theta)$ crece hasta el borde $\theta = y_{\text{mín}}$.*

```
# Ej 5.2.11: f(y) = 2y / (1 - theta^2) en [
    theta, 1]
abrir("ej5211-soporte")
curve(ifelse(x <= 0.21, (1 - x^2)^-6, NA),
    0, 0.21, n = 500, lwd = 2, col = azul,
      xlim = c(0, 0.6), ylim = c(1, 1.35),
          xlab = expression(theta), ylab =
          "L(theta) / cte",
      panel.first = grid(col = "gray90"))
points(0.21, (1 - 0.21^2)^-6, pch = 19, col
     = rojo)
abline(v = 0.21, lty = 2, col = rojo)
text(0.21, 1.3, "theta <= min(y) = 0.21",
    pos = 4, cex = 0.8, col = rojo)
dev.off()
```

Resultado. $\hat{\theta} = y_{\text{mín}} = 0{,}21$.

Ejercicio 5.2.12

Una muestra aleatoria de tamaño n se toma de $f_Y(y;\theta) = \dfrac{2y}{\theta^2},\ 0 \le y \le \theta$. Halle una expresión para el EMV $\hat{\theta}$.

$$L(\theta) = \prod_{i=1}^{n} \frac{2y_i}{\theta^2}\,\mathbb{1}(y_i \le \theta) = \frac{2^n \prod y_i}{\theta^{2n}}\,\mathbb{1}(\theta \ge y_{\text{máx}})$$

$$\frac{d\ln L}{d\theta} = -\frac{2n}{\theta} < 0 \quad \Rightarrow \quad L \text{ decreciente en } \theta \ge y_{\text{máx}}$$

$$\hat{\theta} = y_{\text{máx}} = \text{máx}(Y_1, \ldots, Y_n)$$

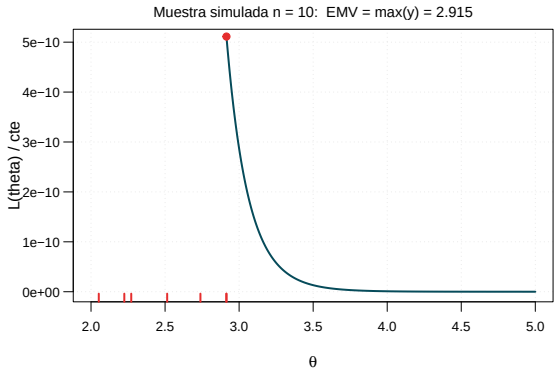


Figura 12: *Ilustración con una muestra simulada ($\theta = 3$, $n = 10$).*

```
# Ej 5.2.12: f(y) = 2y / theta^2 en [0, theta]  (muestra simulada)
abrir("ej5212-triangular")
set.seed(2); y <- 3 * sqrt(runif(10))
curve(ifelse(x >= max(y), x^-20, NA), 2, 5,
      n = 800, lwd = 2, col = azul,
       xlab = expression(theta), ylab = "L(
           theta) / cte", panel.first = grid
           (col = "gray90"))
points(max(y), max(y)^-20, pch = 19, col =
    rojo)
rug(y, col = rojo, lwd = 2)
titulo(sprintf("Muestra simulada n = 10:
    EMV = max(y) = %.3f", max(y)))
dev.off()
```

Resultado. $\hat{\theta} = Y_{\text{máx}}$.

4

SECCIÓN

Fórmulas generales del EMV

Ejercicios 5.2.13 – 5.2.16

Ejercicio 5.2.13

Si Y denota ingreso individual, la ley de Pareto afirma $P(Y \geq y) = \left(\frac{k}{y}\right)^{\theta}$, de donde $f_Y(y;\theta) = \theta k^{\theta} y^{-(\theta+1)},\ y \geq k,\ \theta \geq 1$. Suponga que k es conocido. Encuentre el EMV de θ usando una muestra aleatoria de tamaño 25.

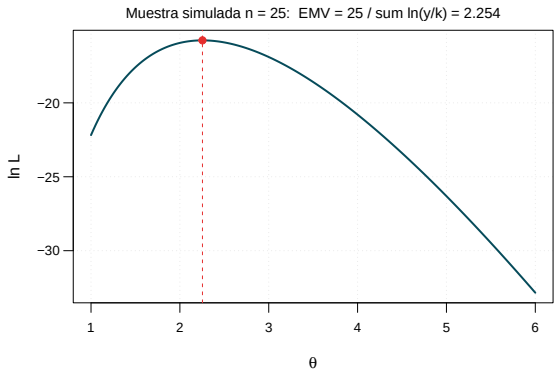
$$L(\theta) = \prod_{i=1}^{25} \theta k^{\theta} y_i^{-(\theta+1)} = \theta^{25} k^{25\theta} \Big(\prod y_i\Big)^{-(\theta+1)}$$

$$\ln L(\theta) = 25 \ln \theta + 25\,\theta \ln k - (\theta+1) \sum \ln y_i$$

$$\frac{d \ln L}{d\theta} = \frac{25}{\theta} + 25 \ln k - \sum \ln y_i = 0 \ \Rightarrow\ \hat{\theta} = \frac{25}{\sum_{i=1}^{25} \ln y_i - 25 \ln k} = \frac{25}{\sum_{i=1}^{25} \ln(y_i/k)}$$

$$\frac{d^2 \ln L}{d\theta^2} = -\frac{25}{\theta^2} < 0$$

Con la restricción $\theta \geq 1$: si el cociente resulta menor que 1, $\hat{\theta} = 1$.




```r
# Ej 5.2.13: Pareto con k conocido (muestra simulada, k = 1, theta = 2.5)
abrir("ej5213-pareto")
set.seed(3); y <- runif(25)^(-1 / 2.5); S <- sum(log(y))
curva(function(t) 25 * log(t) - (t + 1) * S, 1, 6, 25 / S)
titulo(sprintf("Muestra simulada n = 25: EMV = 25 / sum ln(y/k) = %.3f", 25 / S))
dev.off()
```

Figura 13: *Ilustración con una muestra simulada ($k = 1$, $\theta = 2{,}5$, $n = 25$).*

Resultado. $\hat{\theta} = \dfrac{25}{\sum_{i=1}^{25} \ln(y_i/k)}$ (o $\hat{\theta} = 1$ si ese valor es menor que 1).

Ejercicio 5.2.14

Para la binomial negativa $p_X(k;p,r) = \binom{k+r-1}{k}(1-p)^k p^r$, encuentre el EMV de p suponiendo r conocido.

Muestra $k_1,\ldots,k_n$:

$$L(p) = \prod_{i=1}^{n} \binom{k_i+r-1}{k_i}(1-p)^{k_i}p^r \quad \Rightarrow \quad \ln L(p) = \sum \ln \binom{k_i+r-1}{k_i} + \Big(\sum k_i\Big)\ln(1-p) + nr\ln p$$

$$\frac{d\ln L}{dp} = \frac{nr}{p} - \frac{\sum k_i}{1-p} = 0 \;\Rightarrow\; nr(1-p) = p\sum k_i$$

$$\hat{p} = \frac{nr}{nr+\sum k_i} = \frac{r}{r+\bar{k}}$$

$$\frac{d^2\ln L}{dp^2} = -\frac{nr}{p^2} - \frac{\sum k_i}{(1-p)^2} < 0$$

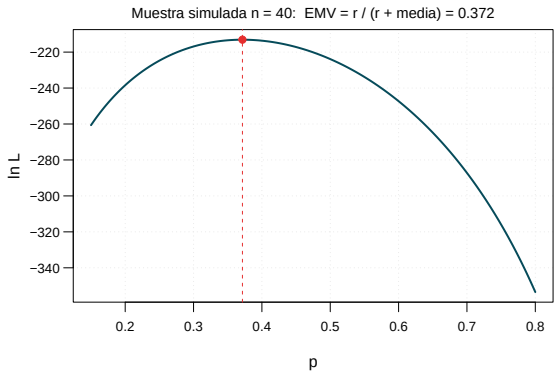


Figura 14: *Ilustración con una muestra simulada* $(r = 3, p = 0{,}4, n = 40)$.

```
# Ej 5.2.14: binomial negativa con r
    conocido (muestra simulada, r = 3, p =
    0.4)
abrir("ej5214-binomial-negativa")
set.seed(4); k <- rnbinom(40, size = 3,
    prob = 0.4)
curva(function(p) 120 * log(p) + sum(k) *
    log(1 - p), 0.15, 0.8, 120 / (120 + sum
    (k)),
      xlab = "p")
titulo(sprintf("Muestra simulada n = 40:
    EMV = r / (r + media) = %.3f", 120 /
    (120 + sum(k))))
dev.off()
```

Resultado. $\hat{p} = \dfrac{r}{r+\bar{k}}$ (para $n = 1$: $\hat{p} = \dfrac{r}{r+k}$).

Ejercicio 5.2.15

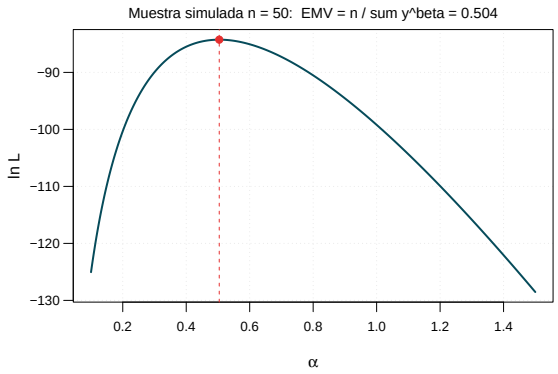
La pdf Weibull es $f_Y(y;\alpha,\beta) = \alpha\beta y^{\beta-1}e^{-\alpha y^\beta},\ y \geq 0, \alpha > 0, \beta > 0$. Encuentre el EMV de α suponiendo β conocida.

$$L(\alpha) = \alpha^n \beta^n \Big(\prod y_i\Big)^{\beta-1} e^{-\alpha \sum y_i^\beta}$$

$$\ln L(\alpha) = n\ln\alpha + n\ln\beta + (\beta-1)\sum \ln y_i - \alpha\sum y_i^\beta$$

$$\frac{d\ln L}{d\alpha} = \frac{n}{\alpha} - \sum y_i^\beta = 0 \ \Rightarrow\ \hat{\alpha} = \frac{n}{\sum_{i=1}^n y_i^\beta}$$

$$\frac{d^2 \ln L}{d\alpha^2} = -\frac{n}{\alpha^2} < 0$$




```
# Ej 5.2.15: Weibull con beta conocido (
    muestra simulada, beta = 2, alpha =
    0.5)
abrir("ej5215-weibull")
set.seed(5); y <- rweibull(50, shape = 2,
    scale = 0.5^(-1/2)); S <- sum(y^2)
curva(function(a) 50 * log(a) - a * S, 0.1,
     1.5, 50 / S, xlab = expression(alpha))
titulo(sprintf("Muestra simulada n = 50:
    EMV = n / sum y^beta = %.3f", 50 / S))
dev.off()
```

Figura 15: *Ilustración con una muestra simulada* ($\beta = 2$, $\alpha = 0{,}5$, $n = 50$).

Resultado. $\hat{\alpha} = \dfrac{n}{\sum_{i=1}^n y_i^\beta}$.

Ejercicio 5.2.16

Suponga una muestra aleatoria de tamaño n de una normal con media conocida μ pero varianza desconocida σ^2. Use máxima verosimilitud para encontrar una fórmula para $\hat{\sigma}^2$. Compare con el EMV hallado en el Ejemplo 5.2.5.

$$L(\sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i-\mu)^2}{2\sigma^2}} = (2\pi\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2}\sum(y_i-\mu)^2}$$

$$\ln L(\sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum(y_i-\mu)^2$$

$$\frac{d\ln L}{d\sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum(y_i-\mu)^2 = 0 \;\Rightarrow\; \hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(y_i-\mu)^2$$

Comparación con el Ejemplo 5.2.5 (μ y σ^2 desconocidas):

	μ conocida	μ desconocida
EMV	$\frac{1}{n}\sum(y_i-\mu)^2$	$\frac{1}{n}\sum(y_i-\bar{y})^2$
Esperanza	σ^2 (insesgado)	$\frac{n-1}{n}\sigma^2$ (sesgado)

Misma fórmula con $\bar{y}$ en lugar de μ. Como $\sum(y_i-\bar{y})^2 \le \sum(y_i-\mu)^2$, estimar la media hace que el EMV subestime σ^2.

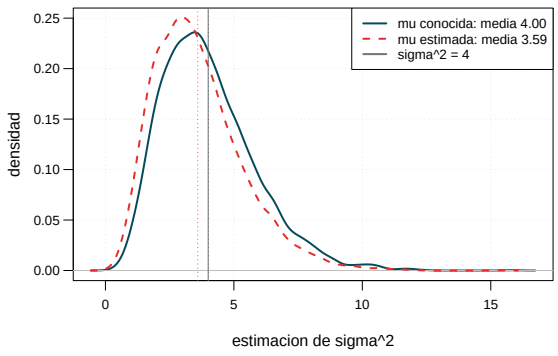


Figura 16: *5000 muestras simuladas con $n = 10$ y $\sigma^2 = 4$: medias 4,00 y 3,59.*

```
# Ej 5.2.16: varianza con mu conocida vs mu
    estimada (5000 muestras, n = 10, sigma
    ^2 = 4)
abrir("ej5216-varianza")
set.seed(6)
m <- replicate(5000, { y <- rnorm(10, 0, 2)
    ; c(mean(y^2), mean((y - mean(y))^2))
    })
plot(density(m[1, ]), lwd = 2, col = azul,
    main = "", xlab = "estimacion de sigma
    ^2", ylab = "densidad",
     ylim = c(0, 0.25), panel.first = grid(
         col = "gray90"))
lines(density(m[2, ]), lwd = 2, col = rojo,
     lty = 2)
abline(v = rowMeans(m), col = c(azul, rojo)
    , lty = 3)
abline(v = 4, col = gris)
legend("topright", c(sprintf("mu conocida:
    media %.2f", mean(m[1, ])),
                     sprintf("mu estimada:
                         media %.2f", mean(
                         m[2, ])), "sigma^2
                          = 4"),
       col = c(azul, rojo, gris), lty = c
           (1, 2, 1), lwd = 2, bg = "white"
           , cex = 0.8)
dev.off()
```

Resultado. $\hat{\sigma}^2 = \frac{1}{n}\sum(y_i-\mu)^2$ (insesgado); con μ desconocida se usa $\bar{y}$ y el EMV es sesgado: $E = \frac{n-1}{n}\sigma^2$.