MAESTRÍA EN CIENCIA DE DATOS

Análisis de Conglomerados

Ward.D2 y k-means

Base de datos: Heart Disease (Cleveland, UCI)
Distancias euclidianas, dendrograma, centroides y perfiles de riesgo

Elaborado por: Miguel Deza
Programa: Maestría en Ciencia de Datos – UNSA
Curso: Estadística en Ciencia de Datos
Docente: Carlos Antonio Abanto Valle

Fecha: 7 de noviembre de 2026

Índice

a) Por qué estandarizar . . . 2
b) Matriz de distancias euclidianas . . . 2
c) Ward.D2 . . . 3
d) Dendrograma y número de grupos . . . 4
e) Asignación y características de cada grupo . . . 4
f) k-means con $k = 3$ . . . 5
g) Centroides y perfiles de riesgo . . . 6
Comparación a) Ward.D2 vs. k-means . . . 7
Comparación b) Similitudes y diferencias entre enfoques . . . 8
Comparación c) Relación con enfermedad_cardiaca . . . 8

Todo el análisis está en `4_Analisis_de_Conglomerados.R` (R 4.6.1; paquete `cluster`), que lee `heart.csv` (297 pacientes, sin valores faltantes). En cada pregunta muestro el bloque de código, su salida de consola y la interpretación.

Variables

Uso `edad`, `presion_reposo`, `colesterol`, `frecuencia_cardiaca_max` y `depresion_st`, estandarizadas.

```
cor_df <- read.csv("heart.csv")
cor_df$enf  <- factor(cor_df$enfermedad_cardiaca, levels = c("No", "Si"))
cor_df$sexo <- factor(cor_df$sexo, levels = 0:1, labels = c("mujer", "hombre"))
cor_df$angina_ejercicio <- factor(cor_df$angina_ejercicio, levels = 0:1,
                                  labels = c("no", "si"))
vclu <- c("edad", "presion_reposo", "colesterol", "frecuencia_cardiaca_max", "depresion_st")
Y <- cor_df[, vclu]
round(rbind(media = colMeans(Y), desv_est = apply(Y, 2, sd)), 2)
Z <- scale(Y)
round(rbind(media = colMeans(Z), desv_est = apply(Z, 2, sd)), 2)
```

```
          edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
media    54.54         131.69      247.3                  149.60         1.06
desv_est  9.05          17.76       52.0                   22.94         1.17
         edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
media       0              0          0                       0            0
desv_est    1              1          1                       1            1
```

Pregunta a)

Explique por qué es necesario estandarizar las variables antes de realizar un análisis de conglomerados en este contexto.

La distancia euclidiana $d(x_i,x_j) = \sqrt{\sum_k (x_{ik} - x_{jk})^2}$ suma diferencias en unidades originales. El colesterol tiene $s = 52$ mg/dl y la depresión ST $s = 1{,}17$ mm: una diferencia típica de colesterol pesa unas $(52/1{,}17)^2 \approx 2000$ veces más que una de ST en d^2. Sin estandarizar, los grupos serían básicamente "colesterol alto / bajo". Lo comprobé: la correlación entre la distancia sin estandarizar y la diferencia de colesterol es 0,94 (figura de la pregunta b).

Resultado. Estandarizo $(z = (x - \bar{x})/s)$ para que las cinco variables clínicas contribuyan por igual a la distancia.

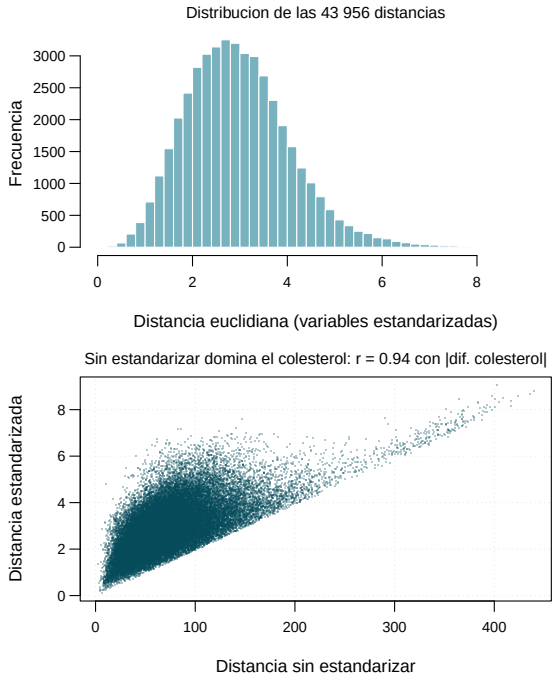
Pregunta b)

Calcule la matriz de distancias euclidianas entre los individuos a partir de las variables estandarizadas.

```
D <- dist(Z, method = "euclidean")
length(D)                                  # 297 * 296 / 2 pares
round(as.matrix(D)[1:6, 1:6], 3)
summary(as.vector(D))
```

```
[1] 43956
      1     2     3     4     5     6
1 0.000 2.402 1.757 3.569 2.907 2.393
2 2.402 0.000 2.829 5.396 4.624 4.140
3 1.757 2.829 0.000 4.296 3.657 2.905
4 3.569 5.396 4.296 0.000 2.156 3.211
5 2.907 4.624 3.657 2.156 0.000 1.943
6 2.393 4.140 2.905 3.211 1.943 0.000
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  0.123   2.179   2.877   2.965   3.626   9.049
```

La matriz es 297×297 simétrica con diagonal cero; tiene $\binom{297}{2} = 43\,956$ distancias distintas. Muestro los 6 primeros pacientes: el 2 y el 4 son los más distintos ($d = 5{,}40$) y el 1 y el 3 los más parecidos ($d = 1{,}76$). La distancia mediana es 2,88.




```r
D <- dist(Z, method = "euclidean")
length(D)                                  # 297 * 296 / 2 pares
round(as.matrix(D)[1:6, 1:6], 3)
summary(as.vector(D))
```

Figura 1: *Distribución de distancias (arriba) y distancia estandarizada vs. sin estandarizar (abajo).*

Pregunta c)

Aplique un análisis de conglomerados jerárquicos utilizando el método de Ward (ward.D2).

En cada paso Ward une los dos grupos que menos aumentan la suma de cuadrados dentro de grupos:

$$\Delta(A,B) = \frac{n_A n_B}{n_A + n_B} \, \|\bar{z}_A - \bar{z}_B\|^2$$

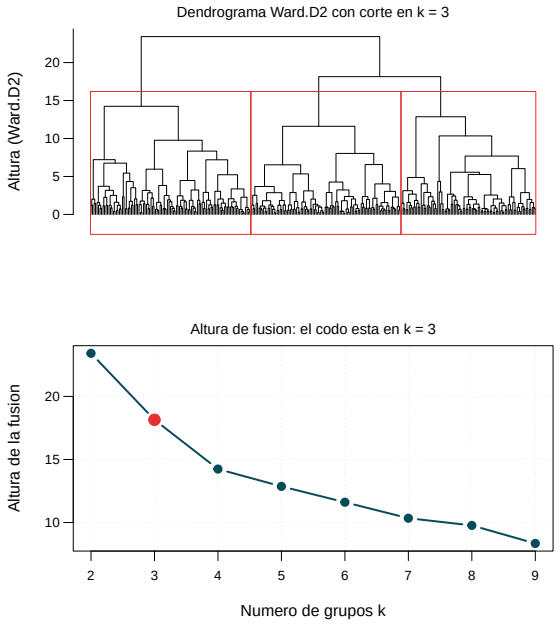
`ward.D2` trabaja con las distancias euclidianas sin elevar (las eleva internamente), que es la implementación correcta del criterio de Ward.

```r
hc <- hclust(D, method = "ward.D2")
alturas <- rev(hc$height)[1:8]
data.frame(k = 2:9, altura_fusion = round(alturas, 2),
           salto = round(c(-diff(alturas), NA), 2))
sil_hc <- sapply(2:6, function(k) mean(silhouette(cutree(hc, k), D)[, 3]))
round(setNames(sil_hc, paste0("k=", 2:6)), 3)
```

```
  k altura_fusion salto
1 2         23.42  5.27
2 3         18.15  3.91
3 4         14.24  1.37
4 5         12.87  1.26
5 6         11.61  1.27
6 7         10.34  0.57
7 8          9.77  1.43
8 9          8.34    NA
  k=2   k=3   k=4   k=5   k=6
0.199 0.146 0.147 0.139 0.134
```

Pregunta d)

Represente el dendrograma e indique el número de conglomerados que considera adecuado, justificando su elección.




```
abrir("clu-dendro", w = 6, h = 6.6)
par(mfrow = c(2, 1))
plot(hc, labels = FALSE, hang = -1, main = "", xlab
     = "", sub = "", ylab = "Altura (Ward.D2)")
rect.hclust(hc, k = 3, border = rojo)
titulo("Dendrograma Ward.D2 con corte en k = 3")
plot(2:9, alturas, type = "b", pch = 19, col = azul,
      lwd = 2, xlab = "Numero de grupos k",
     ylab = "Altura de la fusion", panel.first =
     grid(col = "gray90"))
points(3, alturas[2], pch = 19, cex = 1.6, col =
     rojo)
titulo("Altura de fusion: el codo esta en k = 3")
dev.off()
```

Figura 2: *Dendrograma Ward.D2 (arriba) y altura de las últimas fusiones (abajo).*

Elijo $k = 3$:

- Las dos últimas fusiones son los saltos grandes: 23,4 (de 2 a 1 grupo) y 18,2 (de 3 a 2). Desde $k = 4$ las fusiones bajan en pasos de apenas $\approx 1{,}3$: el codo está en $k = 3$.
- En el dendrograma, un corte a altura ≈ 16 cruza tres ramas largas y de tamaño parecido (107, 100 y 90 pacientes).
- La silueta media favorece algo a $k = 2$ (0,20 vs. 0,15). Aun así prefiero $k = 3$ porque separa un perfil clínico más (el de presión y colesterol altos, ver pregunta e), que con $k = 2$ se pierde.

Pregunta e)

Asigne cada individuo a un conglomerado y describa las principales características clínicas de cada grupo.

```
K <- 3
g_hc <- cutree(hc, k = K)
table(g_hc)
perfil <- function(g) {
  t(sapply(split(cor_df, g), function(d) c(n = nrow(d), colMeans(d[, vclu]),
    pct_hombre = 100 * mean(d$sexo == "hombre"),
    pct_angina = 100 * mean(d$angina_ejercicio == "si"),
    pct_enfermo = 100 * mean(d$enf == "Si"))))
}
round(perfil(g_hc), 1)
```

```
g_hc
  1   2   3
107 100  90
    n edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st pct_hombre
1 107 60.3          132.0      239.7                   131.5          2.0       76.6
2 100 48.0          124.9      215.4                   163.1          0.5       72.0
3  90 55.0          138.9      291.9                   156.0          0.6       52.2
  pct_angina pct_enfermo
1       51.4        72.9
2       16.0        24.0
3       28.9        38.9
```

	Grupo 1	Grupo 2	Grupo 3
n	107	100	90
Edad (años)	60,3	48,0	55,0
Presión reposo (mmHg)	132,0	124,9	**138,9**
Colesterol (mg/dl)	239,7	215,4	**291,9**
FC máxima (lpm)	**131,5**	163,1	156,0
Depresión ST (mm)	**2,0**	0,5	0,6
% hombres	76,6	72,0	52,2
% angina de esfuerzo	51,4	16,0	28,9
% con enfermedad	**72,9**	24,0	38,9

- **Grupo 1 – isquémico**: los mayores, con baja frecuencia cardíaca máxima y depresión ST alta (signos de isquemia en la prueba de esfuerzo); la mitad tiene angina.
- **Grupo 2 – joven y sano**: 48 años en promedio, buena capacidad cardíaca (163 lpm), ST casi normal y los valores más bajos de presión y colesterol.
- **Grupo 3 – metabólico**: colesterol muy alto (292) y presión alta, pero con prueba de esfuerzo casi normal; tiene la mayor proporción de mujeres.

Pregunta f)

Aplique el método de k-means considerando el mismo número de conglomerados seleccionado en el método jerárquico.

k-means minimiza $\sum_{g=1}^{3}\sum_{i\in g}\|z_i-\bar{z}_g\|^2$. Uso 50 arranques aleatorios (`nstart = 50`) para no quedarme en un mínimo local, y reetiqueto los grupos para que el grupo j sea el que más se parece al grupo j de Ward.

```r
set.seed(2026)
km <- kmeans(Z, centers = K, nstart = 50, iter.max = 100)
# reetiqueto: el grupo j de k-means es el que mas se solapa con el grupo j de Ward
eq <- apply(table(km$cluster, g_hc), 1, which.max)
km$cluster <- eq[km$cluster]; km$size <- km$size[order(eq)]
km$centers <- km$centers[order(eq), ]; rownames(km$centers) <- 1:K
km$size
round(km$centers, 2)                                   # centroides estandarizados
round(t(t(km$centers) * attr(Z, "scaled:scale") + attr(Z, "scaled:center")), 1)
c(R2_entre = km$betweenss / km$totss,
  silueta_km = mean(silhouette(km$cluster, D)[, 3]))
round(perfil(km$cluster), 1)
```

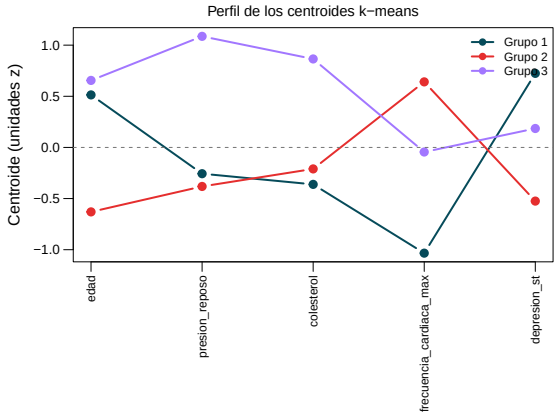
```
[1]  85 142  70
   edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
1  0.51          -0.26      -0.36                  -1.03         0.72
2 -0.63          -0.38      -0.21                   0.64        -0.52
```

```
3  0.66          1.09       0.87                  -0.04         0.19
  edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
1 59.2          127.1      228.6                  125.9          1.9
2 48.8          124.9      236.4                  164.3          0.4
3 60.5          151.0      292.3                  148.6          1.3
  R2_entre silueta_km
    0.3533     0.2276
    n edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st pct_hombre
1  85 59.2          127.1      228.6                  125.9          1.9       78.8
2 142 48.8          124.9      236.4                  164.3          0.4       68.3
3  70 60.5          151.0      292.3                  148.6          1.3       52.9
  pct_angina pct_enfermo
1       54.1        74.1
2       16.2        23.2
3       40.0        58.6
```

Los tres grupos explican el 35,3 % de la variabilidad total (SC_{entre}/SC_{total}).

Pregunta g)

Analice los centroides obtenidos e interprete los perfiles de cada grupo en términos de riesgo cardiovascular.




```
abrir("clu-centroides", w = 6, h = 4.6)
par(mar = c(9, 4, 1.8, 1))
matplot(t(km$centers), type = "b", pch = 19, lty =
    1, lwd = 2, col = pal[1:K],
       xaxt = "n", xlab = "", ylab = "Centroide (
    unidades z)")
axis(1, at = 1:5, labels = vclu, las = 2, cex.axis =
     0.75)
abline(h = 0, lty = 2, col = gris)
legend("topright", paste("Grupo", 1:K), col = pal[1:
    K], pch = 19, lwd = 2, cex = 0.75, bty = "n")
titulo("Perfil de los centroides k-means")
dev.off()
```

Figura 3: *Centroides de k-means en unidades z.*

Grupo	Edad	Presión	Colest.	FC máx.	ST	% enfermos
1 ($n = 85$)	59,2	127,1	228,6	**125,9**	**1,9**	**74,1**
2 ($n = 142$)	48,8	124,9	236,4	164,3	0,4	23,2
3 ($n = 70$)	60,5	**151,0**	**292,3**	148,6	1,3	58,6

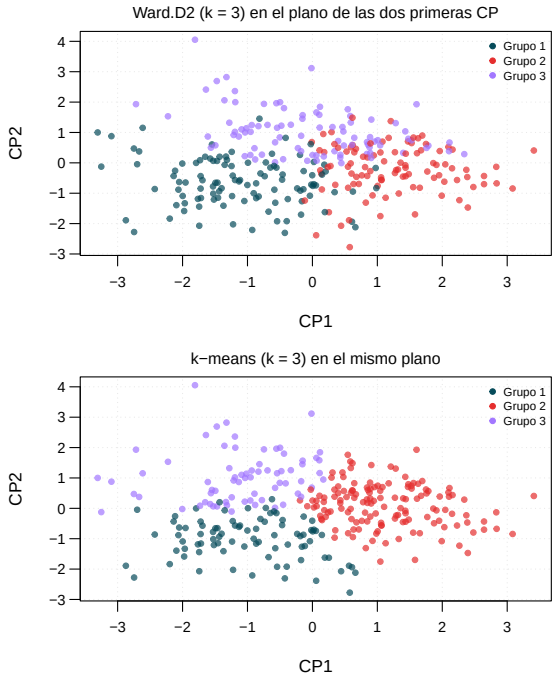
- **Grupo 1 – riesgo alto (isquémico)**: centroide con FC máxima a $-1{,}03$ desviaciones y ST a $+0{,}72$. Es la respuesta anormal al esfuerzo típica de enfermedad coronaria; 3 de cada 4 están enfermos.
- **Grupo 2 – riesgo bajo**: todos los valores por debajo de la media salvo la FC máxima ($+0{,}64$). Jóvenes con buena reserva cardíaca; 23 % de enfermos.
- **Grupo 3 – riesgo intermedio-alto (factores clásicos)**: presión ($+1{,}09$) y colesterol ($+0{,}87$) altos y mayor edad. Aún sin daño evidente en la prueba de esfuerzo, el 59 % ya está enfermo: es el grupo de prevención.

Pregunta Comparación a)

Compare los conglomerados obtenidos mediante los métodos ward.D2 y k-means.

```
tab_cmp <- table(Ward = g_hc, kmeans = km$cluster)
tab_cmp
ari <- function(a, b) {                          # indice de Rand ajustado
  t <- table(a, b); n <- sum(t); s <- sum(choose(t, 2))
  sa <- sum(choose(rowSums(t), 2)); sb <- sum(choose(colSums(t), 2))
  e <- sa * sb / choose(n, 2)
  (s - e) / ((sa + sb) / 2 - e)
}
c(ARI = ari(g_hc, km$cluster),
  acuerdo_max = sum(apply(tab_cmp, 1, max)) / sum(tab_cmp),
  silueta_ward = mean(silhouette(g_hc, D)[, 3]),
  silueta_kmeans = mean(silhouette(km$cluster, D)[, 3]))
```

```
    kmeans
Ward  1  2  3
   1 78 10 19
   2  7 91  2
   3  0 41 49
          ARI    acuerdo_max   silueta_ward silueta_kmeans
       0.4014         0.7340         0.1457         0.2276
```




```
abrir("clu-plano", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
pc <- prcomp(Z)$x
plot(pc[, 1], pc[, 2], pch = 19, cex = 0.7, col =
     adjustcolor(pal[g_hc], 0.7),
     xlab = "CP1", ylab = "CP2", panel.first = grid(
     col = "gray90"))
legend("topright", paste("Grupo", 1:K), pch = 19,
     col = pal[1:K], cex = 0.7, bty = "n")
titulo("Ward.D2 (k = 3) en el plano de las dos
     primeras CP")
plot(pc[, 1], pc[, 2], pch = 19, cex = 0.7, col =
     adjustcolor(pal[km$cluster], 0.7),
     xlab = "CP1", ylab = "CP2", panel.first = grid(
     col = "gray90"))
legend("topright", paste("Grupo", 1:K), pch = 19,
     col = pal[1:K], cex = 0.7, bty = "n")
titulo("k-means (k = 3) en el mismo plano")
dev.off()
```

Figura 4: *Los dos agrupamientos en el plano de las dos primeras CP de las 5 variables.*

- ✔ Coinciden en el 73,4 % de los pacientes (78 + 91 + 49 de 297). El índice de Rand ajustado es 0,40: acuerdo moderado.
- ✔ Los grupos 1 y 2 son casi los mismos (73 % y 91 % de coincidencia).
- ⇄ La diferencia está en el grupo 3: Ward lo forma con todo el colesterol alto (90 pacientes); k-means pasa 41 de ellos al grupo 2 y se queda con un grupo 3 más extremo (presión 151, colesterol 292). Por eso k-means queda con un grupo 2 más grande (142).

⚖ k-means logra grupos más compactos: silueta 0,23 frente a 0,15 de Ward.

Pregunta Comparación b)

Discuta las similitudes y diferencias entre ambos enfoques.

	Ward.D2 (jerárquico)	**k-means (no jerárquico)**
Criterio	Minimiza el aumento de SC dentro en cada fusión	Minimiza la SC dentro total
Número de grupos	Se decide después, mirando el dendrograma	Hay que fijarlo antes
Asignaciones	Definitivas: una fusión no se deshace	Se reasignan en cada iteración
Resultado	Determinista	Depende del arranque (uso 50)
Costo	$O(n^2)$ en memoria (matriz de distancias)	Lineal en n, escala a bases grandes
Aquí	Silueta 0,15; grupos 107/100/90	Silueta 0,23; grupos 85/142/70

Ambos comparten la distancia euclidiana, las variables estandarizadas y la misma función objetivo (suma de cuadrados dentro), por eso llegan a perfiles parecidos. En la práctica son complementarios: Ward sirve para elegir k y k-means para refinar las asignaciones.

Pregunta Comparación c)

Analice la relación entre los conglomerados obtenidos y la variable enfermedad_cardiaca.

```
t_hc <- table(Ward = g_hc, enf = cor_df$enf); t_km <- table(kmeans = km$cluster, enf = cor_df$
    enf)
cbind(t_hc, pct_Si = round(100 * prop.table(t_hc, 1)[, "Si"], 1))
cbind(t_km, pct_Si = round(100 * prop.table(t_km, 1)[, "Si"], 1))
chisq.test(t_hc)
chisq.test(t_km)
# V de Cramer
sqrt(chisq.test(t_km)$statistic / (sum(t_km) * (min(dim(t_km)) - 1)))
```

```
  No Si pct_Si
1 29 78   72.9
2 76 24   24.0
3 55 35   38.9
   No Si pct_Si
1  22 63   74.1
2 109 33   23.2
3  29 41   58.6

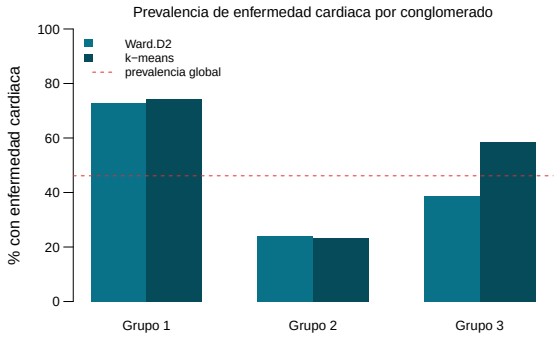
        Pearson's Chi-squared test

data:  t_hc
X-squared = 52, df = 2, p-value = 4e-12


        Pearson's Chi-squared test

data:  t_km
X-squared = 61, df = 2, p-value = 5e-14

X-squared
   0.4535
```




```r
t_hc <- table(Ward = g_hc, enf = cor_df$enf); t_km <-
     table(kmeans = km$cluster, enf = cor_df$enf)
cbind(t_hc, pct_Si = round(100 * prop.table(t_hc, 1)
    [, "Si"], 1))
cbind(t_km, pct_Si = round(100 * prop.table(t_km, 1)
    [, "Si"], 1))
chisq.test(t_hc)
chisq.test(t_km)
# V de Cramer
sqrt(chisq.test(t_km)$statistic / (sum(t_km) * (min(
    dim(t_km)) - 1)))
```

Figura 5: *Porcentaje de enfermos por grupo (línea roja: prevalencia global, 46,1 %).*

- ✔ La relación es fuerte en ambos métodos: $\chi^2_2 = 52$ (Ward) y $\chi^2_2 = 61$ (k-means), con $p < 10^{-11}$. La V de Cramer de k-means es 0,45 (asociación moderada a fuerte).
- ✔ El grupo 1 tiene 73–74 % de enfermos y el grupo 2, 23–24 %: una diferencia de 3 veces, sin haberle mostrado nunca la etiqueta al algoritmo.
- ⇄ En el grupo 3 los métodos difieren (39 % vs. 59 %): el grupo 3 más extremo de k-means concentra más enfermos, por eso su asociación es más fuerte.
- ⚖ Comparado con la regresión logística sobre esta misma base (AUC 0,86), el enfoque no supervisado separa menos, porque no usa sexo ni angina y no optimiza la predicción; a cambio entrega perfiles clínicos interpretables (isquémico, sano, metabólico).

Resultado. Los conglomerados, construidos solo con 5 variables clínicas, recuperan buena parte de la estructura de la enfermedad: el perfil “isquémico” (baja FC máxima, ST alta) concentra a los enfermos y el perfil “joven sano” a los sanos.