MAESTRÍA EN CIENCIA DE DATOS

Análisis de Componentes Principales

Reducción de dimensionalidad con la matriz de correlaciones

Base de datos: Student Performance (UCI)
Correlaciones, scree plot, cargas y regresión sobre componentes

Elaborado por: Miguel Deza
Programa: Maestría en Ciencia de Datos – UNSA
Curso: Estadística en Ciencia de Datos
Docente: Carlos Antonio Abanto Valle

Fecha: 7 de noviembre de 2026

Índice

a) Por qué estandarizar 2
b) Matriz de correlaciones 2
c) ACP con la matriz de correlaciones 4
d) Scree plot y número de componentes 5
e) Interpretación de CP1 y CP2 6
f) Individuos en el plano CP1–CP2 7
g) CP como variables explicativas 8

Todo el análisis está en `3_Componentes_Principales.R` (R 4.6.1; paquetes `corrplot` y `car`), que lee `student.csv` (395 estudiantes). En cada pregunta muestro el bloque de código, su salida de consola y la interpretación.

Variables

Uso las 11 variables cuantitativas del enunciado, todas como numéricas:

```
est <- read.csv("student.csv")
vacp <- c("edad", "tiempo_estudio", "inasistencias", "reprobaciones_previas",
          "educacion_madre", "educacion_padre", "salud", "tiempo_libre",
          "salidas_sociales", "alcohol_dias_semana", "alcohol_fin_semana")
X <- as.matrix(est[, vacp])
round(cbind(media = colMeans(X), desv_est = apply(X, 2, sd),
            min = apply(X, 2, min), max = apply(X, 2, max)), 2)
```

```
                    media desv_est min max
edad                16.70     1.28  15  22
tiempo_estudio       2.04     0.84   1   4
inasistencias        5.71     8.00   0  75
reprobaciones_previas 0.33    0.74   0   3
educacion_madre      2.75     1.09   0   4
educacion_padre      2.52     1.09   0   4
salud                3.55     1.39   1   5
tiempo_libre         3.24     1.00   1   5
salidas_sociales     3.11     1.11   1   5
alcohol_dias_semana  1.48     0.89   1   5
alcohol_fin_semana   2.29     1.29   1   5
```

Pregunta a)

Explique por qué es necesario estandarizar las variables antes de aplicar el ACP en este contexto.

El ACP busca las direcciones de máxima varianza, así que una variable con varianza grande domina las primeras componentes solo por su escala. Aquí `inasistencias` va de 0 a 75 con $s = 8{,}0$ ($s^2 = 64$), mientras que las escalas Likert 1–5 tienen $s \approx 1$ y `reprobaciones_previas` $s = 0{,}74$ ($s^2 = 0{,}55$). Sin estandarizar, la CP1 sería prácticamente "inasistencias" (64 de unas 76 unidades de varianza total, el 84 %). Además las unidades no son comparables (años, faltas, escalas ordinales). Con

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

todas tienen varianza 1 y el ACP sobre Z equivale a diagonalizar la matriz de correlaciones R.

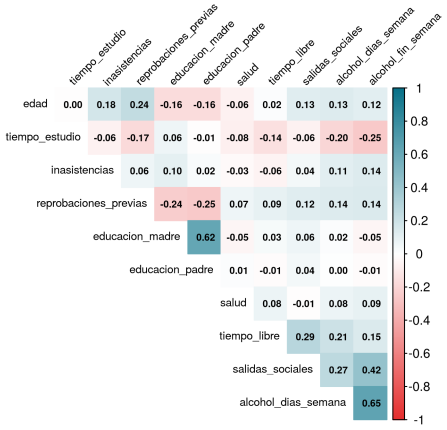
Resultado. Estandarizo para que cada variable pese lo mismo y las componentes reflejen correlaciones, no unidades.

Pregunta b)

Calcule la matriz de correlaciones entre las variables y comente brevemente la presencia de relaciones lineales relevantes.

```
R <- cor(X)
round(R, 2)
# test de esfericidad de Bartlett: H0: R = I
n <- nrow(X); p <- ncol(X)
chi2 <- -(n - 1 - (2 * p + 5) / 6) * log(det(R))
c(chi2 = chi2, gl = p * (p - 1) / 2, p_valor = pchisq(chi2, p * (p - 1) / 2, lower.tail = FALSE)
    )
```

```
                      edad tiempo_estudio inasistencias reprobaciones_previas
edad                  1.00           0.00          0.18                  0.24
tiempo_estudio        0.00           1.00         -0.06                 -0.17
inasistencias         0.18          -0.06          1.00                  0.06
reprobaciones_previas 0.24          -0.17          0.06                  1.00
educacion_madre      -0.16           0.06          0.10                 -0.24
educacion_padre      -0.16          -0.01          0.02                 -0.25
salud                -0.06          -0.08         -0.03                  0.07
tiempo_libre          0.02          -0.14         -0.06                  0.09
salidas_sociales      0.13          -0.06          0.04                  0.12
alcohol_dias_semana   0.13          -0.20          0.11                  0.14
alcohol_fin_semana    0.12          -0.25          0.14                  0.14
                     educacion_madre educacion_padre salud tiempo_libre
edad                           -0.16           -0.16 -0.06         0.02
tiempo_estudio                  0.06           -0.01 -0.08        -0.14
inasistencias                   0.10            0.02 -0.03        -0.06
reprobaciones_previas          -0.24           -0.25  0.07         0.09
educacion_madre                 1.00            0.62 -0.05         0.03
educacion_padre                 0.62            1.00  0.01        -0.01
salud                          -0.05            0.01  1.00         0.08
tiempo_libre                    0.03           -0.01  0.08         1.00
salidas_sociales                0.06            0.04 -0.01         0.29
alcohol_dias_semana             0.02            0.00  0.08         0.21
alcohol_fin_semana             -0.05           -0.01  0.09         0.15
                     salidas_sociales alcohol_dias_semana alcohol_fin_semana
edad                             0.13                0.13               0.12
tiempo_estudio                  -0.06               -0.20              -0.25
inasistencias                    0.04                0.11               0.14
reprobaciones_previas            0.12                0.14               0.14
educacion_madre                  0.06                0.02              -0.05
educacion_padre                  0.04                0.00              -0.01
salud                           -0.01                0.08               0.09
tiempo_libre                     0.29                0.21               0.15
salidas_sociales                 1.00                0.27               0.42
alcohol_dias_semana              0.27                1.00               0.65
alcohol_fin_semana               0.42                0.65               1.00
      chi2          gl    p_valor
 7.013e+02  5.500e+01 7.286e-113
```




```
png("img/acp-corplot.png", width = 6, height = 6,
    units = "in", res = 300)
corrplot(R, method = "color", type = "upper",
    addCoef.col = "black", number.cex = 0.6,
        tl.col = "black", tl.cex = 0.7, tl.srt =
    45, diag = FALSE,
        col = colorRampPalette(c(rojo, "white",
    teal))(200))
dev.off()
```

Figura 1: *Matriz de correlaciones (triángulo superior).*

Relaciones más relevantes:

- **alcohol días de semana – fin de semana**: $r = 0{,}65$, la más fuerte.

- **educación de la madre – del padre**: $r = 0{,}62$.
- **salidas sociales** con alcohol fin de semana $(0{,}42)$, tiempo libre $(0{,}29)$ y alcohol semana $(0{,}27)$: un bloque de "vida social".
- **reprobaciones** con educación de los padres $(-0{,}24, -0{,}25)$ y con edad $(+0{,}24)$; **tiempo de estudio** con alcohol fin de semana $(-0{,}25)$.

El resto está por debajo de $|0{,}2|$ y `salud` casi no se relaciona con nada. El test de esfericidad de Bartlett ($\chi^2_{55} = 701{,}3$, $p \approx 10^{-113}$) rechaza $R = I$: hay correlación suficiente para que el ACP tenga sentido, aunque las correlaciones moderadas anticipan que la varianza se repartirá en varias componentes.

Pregunta c)

Aplique el Análisis de Componentes Principales utilizando la matriz de correlaciones.

$$R\,\mathbf{a}_k = \lambda_k\,\mathbf{a}_k, \qquad \sum_{k=1}^{11} \lambda_k = \operatorname{tr}(R) = 11, \qquad \mathrm{CP}_k = Z\,\mathbf{a}_k$$

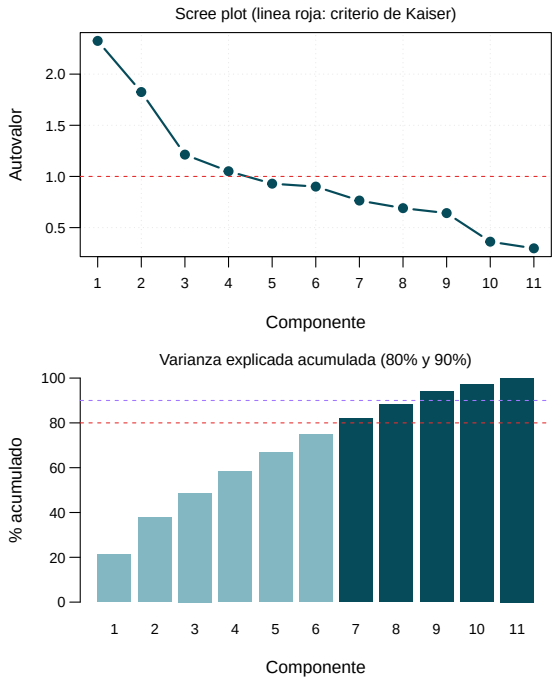
```
acp <- prcomp(X, center = TRUE, scale. = TRUE)   # equivale a usar la matriz R
vp <- acp$sdev^2
tab_vp <- data.frame(CP = paste0("CP", 1:p), autovalor = vp, var_pct = 100 * vp / sum(vp),
                     acumulada = 100 * cumsum(vp) / sum(vp))
print(tab_vp, digits = 3, row.names = FALSE)
c(Kaiser = sum(vp > 1), CP_80 = which(cumsum(vp) / sum(vp) >= 0.80)[1],
  CP_90 = which(cumsum(vp) / sum(vp) >= 0.90)[1])
```

```
   CP autovalor var_pct acumulada
  CP1     2.325   21.13      21.1
  CP2     1.825   16.59      37.7
  CP3     1.213   11.03      48.8
  CP4     1.051    9.55      58.3
  CP5     0.929    8.45      66.8
  CP6     0.901    8.19      74.9
  CP7     0.764    6.95      81.9
  CP8     0.690    6.27      88.2
  CP9     0.642    5.83      94.0
 CP10     0.362    3.29      97.3
 CP11     0.297    2.70     100.0
Kaiser  CP_80  CP_90
     4      7      9
```

Con `prcomp(scale. = TRUE)` los autovalores son los de R (suman 11) y los vectores `rotation` son las cargas $\mathbf{a}_k$.

Pregunta d)

Presente el scree plot e indique cuántos componentes deberían retenerse según la varianza explicada acumulada (80 % o 90 %).




```r
abrir("acp-scree", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
plot(vp, type = "b", pch = 19, col = azul, lwd = 2,
     xaxt = "n", xlab = "Componente",
     ylab = "Autovalor", panel.first = grid(col = "
     gray90"))
axis(1, at = 1:p); abline(h = 1, lty = 2, col = rojo
     )
titulo("Scree plot (linea roja: criterio de Kaiser)"
     )
acum <- 100 * cumsum(vp) / sum(vp)
barplot(acum, names.arg = 1:p, col = ifelse(acum <
     80, adjustcolor(teal, 0.5), azul),
        border = NA, ylim = c(0, 100), xlab = "
     Componente", ylab = "% acumulado")
abline(h = c(80, 90), lty = 2, col = c(rojo, lila))
titulo("Varianza explicada acumulada (80% y 90%)")
dev.off()
```

Figura 2: *Scree plot (arriba) y varianza acumulada con las líneas de 80 % y 90 % (abajo).*

Criterio	Componentes	Varianza retenida
Varianza acumulada $\geq$ 80 %	**7**	81,9 %
Varianza acumulada $\geq$ 90 %	9	94,0 %
Kaiser ($\lambda_k > 1$)	4	58,3 %
Codo del scree plot	3	48,8 %

Retengo **7 componentes** (criterio del 80 %): con 9 llegaría al 94 %, pero pasaría de 11 a 9 variables, que casi no reduce la dimensión. La curva cae despacio después de CP2, consecuencia de las correlaciones bajas: este conjunto no se comprime bien en pocas componentes.

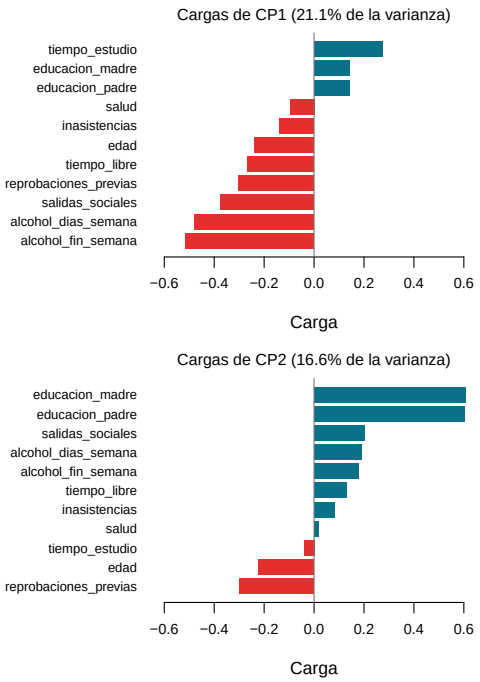
Resultado. 7 CP según el 80 % (81,9 %); 9 según el 90 %.

Pregunta e)

Interprete los dos primeros componentes en términos de las variables originales, analizando los signos y magnitudes de las cargas.

```
round(acp$rotation[, 1:4], 3)
round(cor(X, acp$x[, 1:2]), 3)   # correlacion variable-componente
```

```
                      PC1    PC2    PC3    PC4
edad                -0.238 -0.222 -0.492  0.129
tiempo_estudio       0.275 -0.040 -0.197  0.454
inasistencias       -0.138  0.080 -0.608 -0.367
reprobaciones_previas -0.302 -0.299 -0.052 -0.093
educacion_madre      0.144  0.605 -0.155 -0.003
educacion_padre      0.143  0.601 -0.068 -0.097
salud               -0.096  0.017  0.436 -0.502
tiempo_libre        -0.265  0.128  0.359  0.388
salidas_sociales    -0.374  0.203 -0.006  0.461
alcohol_dias_semana -0.480  0.191 -0.004 -0.072
alcohol_fin_semana  -0.516  0.177 -0.006 -0.067
                      PC1    PC2
edad                -0.363 -0.300
tiempo_estudio       0.419 -0.055
inasistencias       -0.210  0.109
reprobaciones_previas -0.461 -0.404
educacion_madre      0.220  0.817
educacion_padre      0.218  0.813
salud               -0.147  0.023
tiempo_libre        -0.404  0.174
salidas_sociales    -0.571  0.274
alcohol_dias_semana -0.731  0.258
alcohol_fin_semana  -0.787  0.239
```




```
round(acp$rotation[, 1:4], 3)
round(cor(X, acp$x[, 1:2]), 3)   # correlacion
    variable-componente
```

Figura 3: *Cargas de las dos primeras componentes.*

CP1 (21,1 %) – "estilo de vida social / riesgo": cargas negativas grandes en alcohol fin de semana ($-0{,}52$), alcohol semana ($-0{,}48$), salidas sociales ($-0{,}37$), reprobaciones ($-0{,}30$), tiempo libre ($-0{,}27$) y edad ($-0{,}24$), y positiva en tiempo de estudio ($+0{,}28$). Un CP1 *bajo* es un alumno que

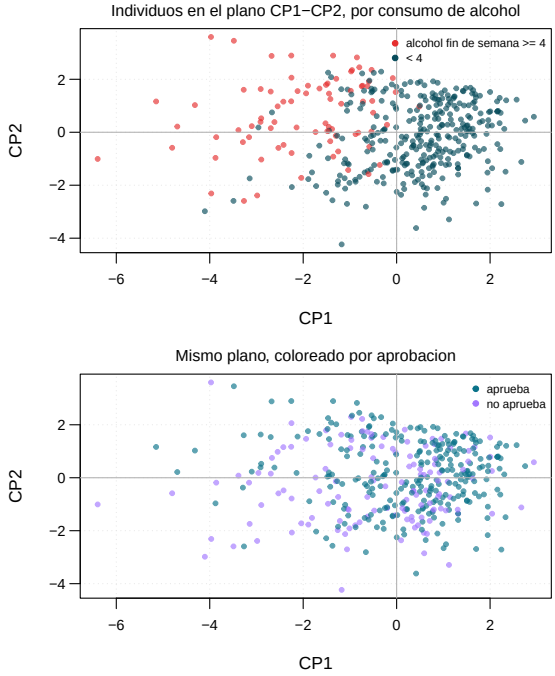
bebe, sale mucho, estudia poco, es mayor y ha reprobado; un CP1 *alto* es el perfil estudioso. (El signo global es arbitrario.)

- **CP2 (16,6 %) – "capital educativo familiar"**: dominada por educación de la madre ($+0{,}61$) y del padre ($+0{,}60$), contra reprobaciones ($-0{,}30$) y edad ($-0{,}22$). Un CP2 alto es un alumno de padres con educación superior y sin repitencia.

`salud` e `inasistencias` casi no cargan en ninguna de las dos; aparecen en CP3 (inasistencias $-0{,}61$, salud $+0{,}44$).

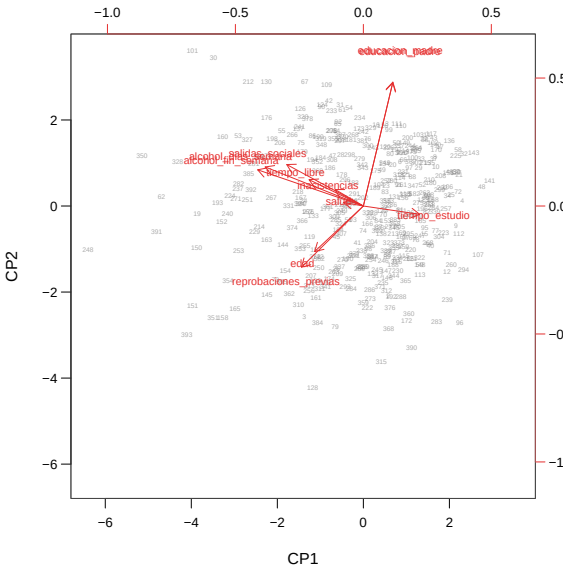
Pregunta f)

Represente gráficamente los individuos en el plano definido por los dos primeros componentes e identifique posibles patrones o agrupamientos.




```
abrir("acp-individuos", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
z <- acp$x
col_alc <- adjustcolor(ifelse(est$alcohol_fin_semana
     >= 4, rojo, azul), 0.65)
plot(z[, 1], z[, 2], pch = 19, cex = 0.6, col = col_
    alc, xlab = "CP1", ylab = "CP2",
     panel.first = grid(col = "gray90"))
abline(h = 0, v = 0, col = "gray70")
legend("topright", c("alcohol fin de semana >= 4", "
    < 4"), pch = 19, col = c(rojo, azul),
       cex = 0.7, bty = "n")
titulo("Individuos en el plano CP1-CP2, por consumo
    de alcohol")
col_ap <- adjustcolor(ifelse(est$aprueba == 1, teal,
     lila), 0.65)
plot(z[, 1], z[, 2], pch = 19, cex = 0.6, col = col_
    ap, xlab = "CP1", ylab = "CP2",
     panel.first = grid(col = "gray90"))
abline(h = 0, v = 0, col = "gray70")
legend("topright", c("aprueba", "no aprueba"), pch =
     19, col = c(teal, lila), cex = 0.7, bty = "n")
titulo("Mismo plano, coloreado por aprobacion")
dev.off()
```

Figura 4: *Puntajes de los 395 alumnos en CP1–CP2.*




```
abrir("acp-biplot", w = 6, h = 6)
biplot(acp, choices = 1:2, scale = 0, cex = c(0.4,
     0.7), col = c(adjustcolor(gris, 0.6), rojo),
       xlab = "CP1", ylab = "CP2")
dev.off()
```

Figura 5: *Biplot: individuos (gris) y cargas (flechas).*

- No hay grupos separados: la nube es continua y asimétrica, con una cola hacia CP1 negativo.
- Esa cola son los alumnos con alto consumo de alcohol el fin de semana (rojo): su CP1 medio es $-1{,}98$ frente a $0{,}50$ del resto. El biplot muestra las flechas de alcohol y salidas apuntando justo hacia ella.
- Por aprobación los puntos se mezclan, pero los aprobados están algo desplazados hacia arriba y a la derecha (CP1 medio $0{,}23$ vs. $-0{,}47$; CP2 $0{,}15$ vs. $-0{,}30$): estudiar más, beber menos y tener padres más educados va con aprobar.

Pregunta g)

Discuta si los componentes principales obtenidos podrían ser utilizados posteriormente como variables explicativas en un modelo de regresión.

Sí: es la *regresión sobre componentes principales*. Lo probé con las 7 CP retenidas para explicar la nota final:

```
k <- which(cumsum(vp) / sum(vp) >= 0.80)[1]
dat_pc <- data.frame(nota_final = est$nota_final, acp$x[, 1:k])
m_pc <- lm(nota_final ~ ., data = dat_pc)
round(summary(m_pc)$coefficients, 4)
c(R2aj_CP = summary(m_pc)$adj.r.squared,
  R2aj_originales = summary(lm(est$nota_final ~ X))$adj.r.squared,
  max_VIF_CP = max(vif(m_pc)))
```

```
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  10.4152     0.2141 48.6357   0.0000
PC1           0.6470     0.1406  4.6009   0.0000
PC2           0.8017     0.1587  5.0510   0.0000
PC3          -0.0276     0.1947 -0.1420   0.8872
PC4           0.0444     0.2092  0.2123   0.8320
PC5           0.5998     0.2224  2.6967   0.0073
PC6           0.1082     0.2259  0.4791   0.6321
PC7           0.9592     0.2453  3.9107   0.0001
        R2aj_CP R2aj_originales      max_VIF_CP
         0.1370          0.1531          1.0000
```

- ⊕ **Ventaja**: las CP son ortogonales (VIF $= 1$ exacto), así que eliminan cualquier multicolinealidad y cada coeficiente se estima de forma independiente.
- ⊕ CP1 y CP2 resultan significativas y con signo esperado: más "estilo estudioso" y más capital educativo, mejor nota.
- ⊖ **Desventaja 1**: las CP se eligen por varianza de las X, no por su relación con Y. Aquí CP5 y CP7, de poca varianza, son significativas, y CP3–CP4 no aportan.
- ⊖ **Desventaja 2**: interpretar "+1 en CP7" es difícil, y con 7 de 11 dimensiones se pierde algo de ajuste (R^2_{aj}: 0,137 frente a 0,153 con las 11 variables originales).
- ⊖ En esta base la multicolinealidad no era un problema (en el ejercicio de regresión lineal sobre esta base los VIF fueron $< 1{,}8$), por lo que el beneficio principal del ACP no aplica.

Resultado. Se pueden usar y garantizan ortogonalidad, pero aquí convienen poco: las correlaciones son bajas, se pierde interpretabilidad y ajuste. Las CP serían útiles con muchas variables muy correlacionadas o con p cercano a n; una alternativa es PLS, que elige componentes pensando en Y.