MAESTRÍA EN CIENCIA DE DATOS

Regresión Lineal Múltiple y Selección de Variables

Método backward con AIC

Base de datos: Student Performance (UCI)
Ajuste por MCO, supuestos, VIF y selección backward

Elaborado por: Miguel Deza
Programa: Maestría en Ciencia de Datos – UNSA
Curso: Estadística en Ciencia de Datos
Docente: Carlos Antonio Abanto Valle

Fecha: 7 de noviembre de 2026

Índice

a) Ajuste por MCO y variables significativas . . . 2
b) Interpretación de tiempo_estudio, inasistencias y reprobaciones_previas . . . 3
c) R^2 y R^2 ajustado . . . 4
d) Supuestos del modelo . . . 4
e) Multicolinealidad (VIF) . . . 6
Backward a) Variables eliminadas y modelo final . . . 6
Backward b) Comparación de AIC y parsimonia . . . 8
Backward c) R^2 ajustado del modelo final . . . 9
Backward d) Supuestos del modelo seleccionado . . . 9

Todo el análisis está en `1_Regresion_Lineal_Multiple.R` (R 4.6.1; paquetes `car` y `lmtest`), que lee `student.csv` (395 estudiantes). En cada pregunta muestro el bloque de código, su salida de consola y la interpretación.

Datos y modelo

$$\begin{aligned}\text{nota_final}_i = \beta_0 &+ \beta_1\,\text{edad}_i + \beta_2\,\text{tiempo_estudio}_i + \beta_3\,\text{inasistencias}_i + \beta_4\,\text{reprobaciones_previas}_i \\ &+ \beta_5\,\text{educacion_madre}_i + \beta_6\,\text{educacion_padre}_i + \beta_7\,\text{internet_casa}_i \\ &+ \beta_8\,\text{apoyo_familiar}_i + \varepsilon_i, \qquad \varepsilon_i \sim N(0,\sigma^2)\end{aligned}$$

Las variables binarias `internet_casa` y `apoyo_familiar` entran como factores con nivel de referencia *no*.

```
est <- read.csv("student.csv")
est$internet_casa  <- factor(est$internet_casa,  levels = c("no", "yes"))
est$apoyo_familiar <- factor(est$apoyo_familiar, levels = c("no", "yes"))
vars <- c("nota_final", "edad", "tiempo_estudio", "inasistencias",
          "reprobaciones_previas", "educacion_madre", "educacion_padre")
summary(est[, vars])
table(nota_final_cero = est$nota_final == 0)
```

```
   nota_final        edad      tiempo_estudio inasistencias   reprobaciones_previas
 Min.   : 0.0   Min.   :15.0   Min.   :1.00   Min.   : 0.00   Min.   :0.000
 1st Qu.: 8.0   1st Qu.:16.0   1st Qu.:1.00   1st Qu.: 0.00   1st Qu.:0.000
 Median :11.0   Median :17.0   Median :2.00   Median : 4.00   Median :0.000
 Mean   :10.4   Mean   :16.7   Mean   :2.04   Mean   : 5.71   Mean   :0.334
 3rd Qu.:14.0   3rd Qu.:18.0   3rd Qu.:2.00   3rd Qu.: 8.00   3rd Qu.:0.000
 Max.   :20.0   Max.   :22.0   Max.   :4.00   Max.   :75.00   Max.   :3.000
 educacion_madre educacion_padre
 Min.   :0.00    Min.   :0.00
 1st Qu.:2.00    1st Qu.:2.00
 Median :3.00    Median :2.00
 Mean   :2.75    Mean   :2.52
 3rd Qu.:4.00    3rd Qu.:3.00
 Max.   :4.00    Max.   :4.00
nota_final_cero
FALSE  TRUE
  357    38
```

La nota va de 0 a 20 y hay **38 notas iguales a 0**. Las revisé: los 38 tienen 0 inasistencias, es decir, son alumnos que no rindieron la evaluación final (abandono), no notas bajas "normales". Las mantengo en el ajuste porque el enunciado pide el modelo sobre la base completa, pero este detalle explica casi todos los problemas de supuestos que aparecen después.

Pregunta a)

Ajuste el modelo de regresión lineal múltiple utilizando mínimos cuadrados ordinarios. Presente la tabla de estimación de los parámetros e identifique las variables estadísticamente significativas al nivel $\alpha = 0{,}05$.

```
m_full <- lm(nota_final ~ edad + tiempo_estudio + inasistencias +
               reprobaciones_previas + educacion_madre + educacion_padre +
               internet_casa + apoyo_familiar, data = est)
summary(m_full)
```

```

Call:
lm(formula = nota_final ~ edad + tiempo_estudio + inasistencias +
    reprobaciones_previas + educacion_madre + educacion_padre +
    internet_casa + apoyo_familiar, data = est)

Residuals:
    Min      1Q  Median      3Q     Max
-12.346  -2.005   0.228   2.963   8.804
```

```
Coefficients:
                    Estimate Std. Error t value     Pr(>|t|)
(Intercept)          14.0789     3.1706    4.44 0.0000117344 ***
edad                 -0.3060     0.1784   -1.72        0.087 .
tiempo_estudio        0.2784     0.2625    1.06        0.290
inasistencias         0.0322     0.0275    1.17        0.242
reprobaciones_previas -1.8940     0.3090   -6.13 0.0000000022 ***
educacion_madre       0.5841     0.2560    2.28        0.023 *
educacion_padre      -0.0534     0.2550   -0.21        0.834
internet_casayes      0.5522     0.5879    0.94        0.348
apoyo_familiaryes    -0.9844     0.4542   -2.17        0.031 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.22 on 386 degrees of freedom
Multiple R-squared:  0.168,     Adjusted R-squared:  0.151
F-statistic: 9.77 on 8 and 386 DF,  p-value: 2.23e-12
```

Variable	$\hat{\beta}$	EE	t	p	¿Signif.?
Intercepto	14,079	3,171	4,44	$< 0{,}001$	sí
edad	$-0{,}306$	0,178	$-1{,}72$	0,087	no
tiempo_estudio	0,278	0,263	1,06	0,290	no
inasistencias	0,032	0,028	1,17	0,242	no
reprobaciones_previas	$-1{,}894$	0,309	$-6{,}13$	$< 0{,}001$	**sí**
educacion_madre	0,584	0,256	2,28	0,023	**sí**
educacion_padre	$-0{,}053$	0,255	$-0{,}21$	0,834	no
internet_casa (sí)	0,552	0,588	0,94	0,348	no
apoyo_familiar (sí)	$-0{,}984$	0,454	$-2{,}17$	0,031	**sí**

El test F global ($F_{8,386} = 9{,}77$, $p = 2{,}2 \times 10^{-12}$) rechaza que todos los β_j sean cero.

Resultado. Al 5 % son significativas **reprobaciones_previas**, **educacion_madre** y **apoyo_familiar**; edad queda al borde ($p = 0{,}087$).

Pregunta b)

Interprete los coeficientes asociados a las variables tiempo_estudio, inasistencias y reprobaciones_previas, manteniendo constantes las demás covariables.

- **tiempo_estudio** ($\hat{\beta}_2 = 0{,}278$): subir un nivel en la escala de estudio semanal (1: < 2 h … 4: > 10 h) se asocia con 0,28 puntos más en la nota final, con lo demás fijo. El efecto no es significativo ($p = 0{,}29$): no puedo descartar que sea cero.
- **inasistencias** ($\hat{\beta}_3 = 0{,}032$): cada falta adicional se asocia con 0,03 puntos *más*, también no significativo ($p = 0{,}24$). El signo contraintuitivo viene de los 38 alumnos con nota 0 y 0 faltas: la base registra 0 inasistencias para quien abandonó, y eso arrastra la pendiente hacia arriba.
- **reprobaciones_previas** ($\hat{\beta}_4 = -1{,}894$): cada curso reprobado antes se asocia con 1,89 puntos menos en la nota final (casi 10 % de la escala), manteniendo constantes las demás covariables. Es el efecto más fuerte y claro del modelo ($t = -6{,}13$).

Pregunta c)

Reporte el coeficiente de determinación R^2 y el R^2 ajustado. Explique por qué el R^2 ajustado es más apropiado en este contexto.

```
s <- summary(m_full)
c(R2 = s$r.squared, R2_ajustado = s$adj.r.squared,
  n = nobs(m_full), p = length(coef(m_full)) - 1)
```

```
        R2 R2_ajustado          n          p
    0.1684      0.1512   395.0000     8.0000
```

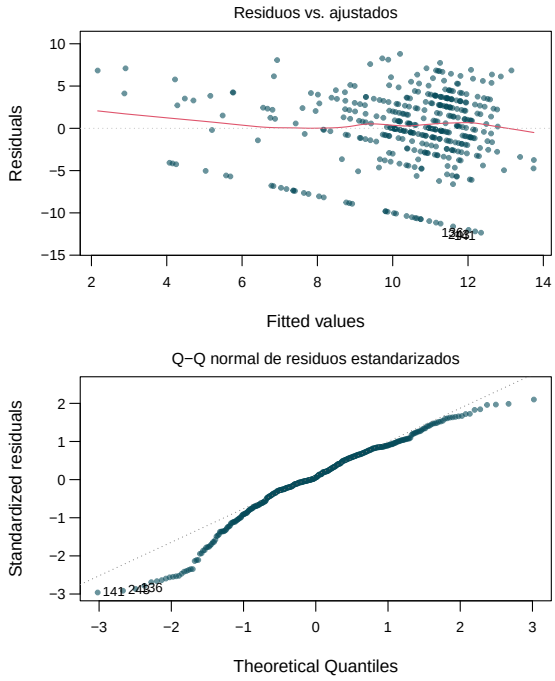
$$R^2 = 1 - \frac{SCE}{SCT} = 0{,}1684, \qquad R^2_{aj} = 1 - (1 - R^2)\frac{n-1}{n-p-1} = 1 - (0{,}8316)\frac{394}{386} = 0{,}1512$$

El modelo explica cerca del 17 % de la variabilidad de la nota final. El R^2 nunca baja al agregar variables, aunque sean ruido; el R^2_{aj} penaliza cada parámetro extra con $(n-1)/(n-p-1)$. Como aquí 5 de las 8 covariables no son significativas, el R^2_{aj} es el que permite comparar honestamente con modelos más pequeños (como el que sale del backward).

Resultado. $R^2 = 0{,}168$ y $R^2_{aj} = 0{,}151$: el modelo tiene poder explicativo bajo.

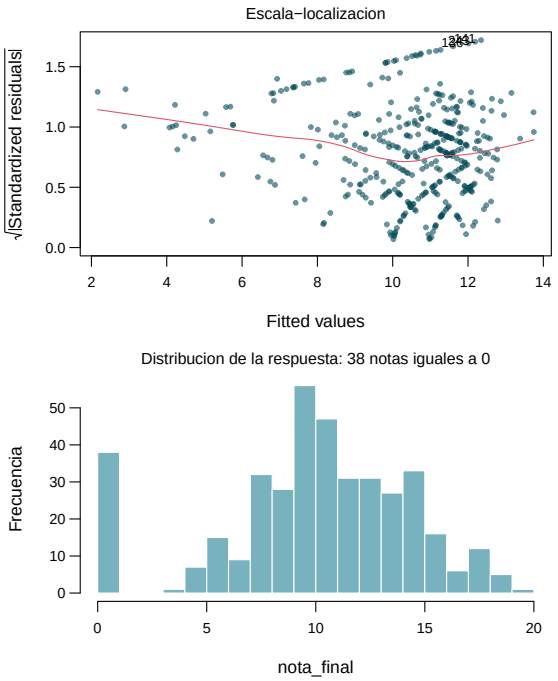
Pregunta d)

Evalúe los principales supuestos del modelo lineal (linealidad, normalidad de los residuos y homocedasticidad), incluyendo gráficos de diagnóstico y comentarios.




```
abrir("rlm-diag1", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
plot(m_full, which = 1, col = adjustcolor(azul, 0.6)
     , pch = 19, cex = 0.6,
     caption = "", sub.caption = "")
titulo("Residuos vs. ajustados")
plot(m_full, which = 2, col = adjustcolor(azul, 0.6)
     , pch = 19, cex = 0.6,
     caption = "", sub.caption = "")
titulo("Q-Q normal de residuos estandarizados")
dev.off()
```

Figura 1: *Residuos vs. ajustados (arriba) y Q-Q normal (abajo).*




```r
abrir("rlm-diag2", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
plot(m_full, which = 3, col = adjustcolor(azul, 0.6)
     , pch = 19, cex = 0.6,
     caption = "", sub.caption = "")
titulo("Escala-localizacion")
hist(est$nota_final, breaks = 0:20, col =
     adjustcolor(teal, 0.55), border = "white",
     main = "", xlab = "nota_final", ylab = "
     Frecuencia")
titulo("Distribucion de la respuesta: 38 notas
     iguales a 0")
dev.off()
```

Figura 2: *Escala-localización (arriba) y distribución de la nota final (abajo).*

```r
shapiro.test(residuals(m_full))      # normalidad
bptest(m_full)                       # homocedasticidad (Breusch-Pagan)
resettest(m_full, power = 2:3)       # linealidad / forma funcional (RESET)
```

```
        Shapiro-Wilk normality test

data:  residuals(m_full)
W = 0.96, p-value = 0.00000001


        studentized Breusch-Pagan test

data:  m_full
BP = 19, df = 8, p-value = 0.02


        RESET test

data:  m_full
RESET = 4.1, df1 = 2, df2 = 384, p-value = 0.02
```

Supuesto	Prueba	p	Conclusión
Linealidad	RESET (potencias 2 y 3)	0,020	se rechaza al 5 %
Normalidad	Shapiro-Wilk	1×10^{-8}	se rechaza
Homocedasticidad	Breusch-Pagan	0,020	se rechaza al 5 %

En el gráfico de residuos vs. ajustados aparece una **banda diagonal** de puntos con residuos de -5 a -13: son los 38 ceros (residuo $= 0 - \hat{y}_i$). Esa banda inclina la curva LOESS (no linealidad), produce la cola izquierda pesada del Q-Q y hace que la dispersión cambie con $\hat{y}$. Fuera de ella la nube es bastante homogénea. Los estimadores MCO siguen siendo insesgados, pero los errores estándar y los valores p deben leerse con cautela.

Resultado. Ninguno de los tres supuestos se cumple al 5 %, y la causa principal es la masa de ceros en la respuesta.

Pregunta e)

Analice la posible presencia de multicolinealidad utilizando el factor de inflación de la varianza (VIF).

```
vif(m_full)
```

```
                edad        tiempo_estudio         inasistencias reprobaciones_previas
               1.145                 1.073                 1.072                 1.168
     educacion_madre       educacion_padre         internet_casa         apoyo_familiar
               1.737                 1.703                 1.066                 1.086
```

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

Todos los VIF están entre 1,07 y 1,74, muy por debajo de los umbrales usuales (5 o 10). Los más altos son `educacion_madre` (1,74) y `educacion_padre` (1,70), que tienen correlación 0,62 entre sí; aun así la varianza de sus coeficientes solo se infla un 70 %.

Resultado. No hay multicolinealidad preocupante. Que `educacion_padre` no sea significativa no se debe a colinealidad, sino a que su efecto ya lo recoge `educacion_madre`.

Pregunta Backward a)

Aplique backward elimination con AIC partiendo del modelo completo. Indique qué variables son eliminadas y presente el modelo final seleccionado.

```
m_back <- step(m_full, direction = "backward", k = 2)
```

```
Start:  AIC=1147
nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
    educacion_madre + educacion_padre + internet_casa + apoyo_familiar

                       Df Sum of Sq  RSS  AIC
- educacion_padre       1         1 6878 1145
- internet_casa         1        16 6893 1145
- tiempo_estudio        1        20 6897 1146
- inasistencias         1        24 6902 1146
<none>                             6877 1147
- edad                  1        52 6930 1148
- apoyo_familiar        1        84 6961 1149
- educacion_madre       1        93 6970 1150
- reprobaciones_previas 1       669 7547 1181

Step:  AIC=1145
nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
    educacion_madre + internet_casa + apoyo_familiar

                       Df Sum of Sq  RSS  AIC
- internet_casa         1        16 6894 1143
- tiempo_estudio        1        21 6899 1144
- inasistencias         1        25 6903 1144
<none>                             6878 1145
- edad                  1        52 6930 1146
- apoyo_familiar        1        86 6964 1148
- educacion_madre       1       125 7003 1150
```

```
- reprobaciones_previas  1       676 7554 1180

Step:  AIC=1144
nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
    educacion_madre + apoyo_familiar

                        Df Sum of Sq  RSS  AIC
- tiempo_estudio         1        23 6917 1143
- inasistencias          1        29 6923 1143
<none>                               6894 1143
- edad                   1        58 6952 1145
- apoyo_familiar         1        83 6976 1146
- educacion_madre        1       143 7037 1150
- reprobaciones_previas  1       675 7569 1178

Step:  AIC=1143
nota_final ~ edad + inasistencias + reprobaciones_previas + educacion_madre +
    apoyo_familiar

                        Df Sum of Sq  RSS  AIC
- inasistencias          1        26 6943 1142
<none>                               6917 1143
- edad                   1        53 6970 1144
- apoyo_familiar         1        72 6989 1145
- educacion_madre        1       145 7062 1149
- reprobaciones_previas  1       739 7655 1181

Step:  AIC=1142
nota_final ~ edad + reprobaciones_previas + educacion_madre +
    apoyo_familiar

                        Df Sum of Sq  RSS  AIC
<none>                               6943 1142
- edad                   1        42 6985 1143
- apoyo_familiar         1        70 7012 1144
- educacion_madre        1       165 7108 1150
- reprobaciones_previas  1       727 7669 1180
```

Paso	Variable eliminada	AIC tras eliminarla
0	(modelo completo)	1146,5
1	educacion_padre	1144,6
2	internet_casa	1143,5
3	tiempo_estudio	1142,8
4	inasistencias	1142,3

En el paso 5 quitar cualquier variable sube el AIC (edad: 1143, apoyo_familiar: 1144), así que el algoritmo se detiene. `step()` reporta el AIC sin las constantes de la verosimilitud (`extractAIC`); las diferencias son las mismas que con `AIC()`.

```r
summary(m_back)
c(AIC_completo = AIC(m_full), AIC_reducido = AIC(m_back))
c(R2aj_completo = summary(m_full)$adj.r.squared,
  R2aj_reducido = summary(m_back)$adj.r.squared)
anova(m_back, m_full)               # F parcial de las variables eliminadas
```

```
Call:
lm(formula = nota_final ~ edad + reprobaciones_previas + educacion_madre +
    apoyo_familiar, data = est)

Residuals:
   Min     1Q Median     3Q    Max
-12.56  -2.04   0.21   3.04   9.10

Coefficients:
```

```
                     Estimate Std. Error t value      Pr(>|t|)
(Intercept)            14.354      3.035    4.73 0.00000314207 ***
edad                   -0.267      0.174   -1.54        0.1254
reprobaciones_previas  -1.924      0.301   -6.39 0.00000000048 ***
educacion_madre         0.621      0.204    3.04        0.0025 **
apoyo_familiaryes      -0.884      0.446   -1.98        0.0484 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.22 on 390 degrees of freedom
Multiple R-squared:  0.16,      Adjusted R-squared:  0.152
F-statistic: 18.6 on 4 and 390 DF,  p-value: 4.94e-14

AIC_completo AIC_reducido
        2270         2265
R2aj_completo R2aj_reducido
       0.1512        0.1519
Analysis of Variance Table

Model 1: nota_final ~ edad + reprobaciones_previas + educacion_madre +
    apoyo_familiar
Model 2: nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
    educacion_madre + educacion_padre + internet_casa + apoyo_familiar
  Res.Df  RSS Df Sum of Sq    F Pr(>F)
1    390 6943
2    386 6877  4      65.4 0.92   0.45
```

$$\widehat{\text{nota_final}} = 14{,}354 - 0{,}267\,\text{edad} - 1{,}924\,\text{reprobaciones_previas} + 0{,}621\,\text{educacion_madre} - 0{,}884\,\text{apoyo_familiar}_{\text{sí}}$$

Resultado. Se eliminan educacion_padre, internet_casa, tiempo_estudio e inasistencias. El modelo final conserva edad, reprobaciones_previas, educacion_madre y apoyo_familiar.

Pregunta Backward b)

Compare el AIC del modelo completo con el del modelo reducido y comente si la reducción implica una mejora en términos de parsimonia.

$$\text{AIC} = -2\ln L + 2k$$

$$\text{AIC}_{\text{completo}} = 2269{,}5\ (k=10), \qquad \text{AIC}_{\text{reducido}} = 2265{,}2\ (k=6), \qquad \Delta = 4{,}3$$

Con 4 parámetros menos el AIC baja 4,3 unidades: el modelo reducido pierde muy poco ajuste (la SCE pasa de 6877 a 6943) a cambio de ser más simple. El test F parcial de las 4 variables eliminadas ($F_{4,386} = 0{,}92$, $p = 0{,}45$) confirma que en conjunto no aportan.

Resultado. Sí hay mejora en parsimonia: menor AIC con la mitad de covariables y sin pérdida significativa de ajuste.

Pregunta Backward c)

Analice el coeficiente de determinación ajustado del modelo final y discuta los cambios respecto al modelo inicial.

Modelo	covariables	R^2	R^2_{aj}
Completo	8	0,1684	0,1512
Reducido (backward)	4	0,1600	0,1519

El R^2 baja (0,168 $\rightarrow$ 0,160) porque siempre baja al quitar variables, pero el R^2_{aj} sube ligeramente (0,1512 $\rightarrow$ 0,1519): las variables eliminadas no compensaban los grados de libertad que consumían. Además, `edad` y `apoyo_familiar` quedan con errores estándar algo menores.

Resultado. El R^2_{aj} se mantiene (incluso sube un poco) con la mitad de variables; el modelo reducido explica lo mismo con menos.

Pregunta Backward d)

Evalúe los supuestos del modelo seleccionado e interprete los resultados.

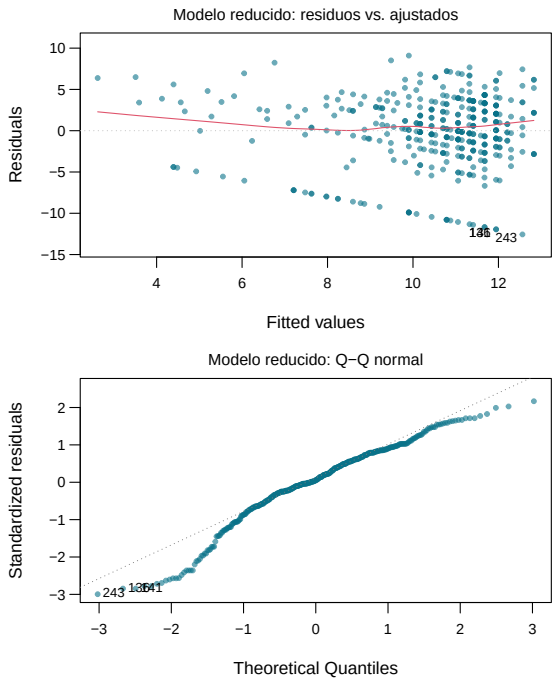


Figura 3: *Diagnóstico del modelo reducido.*

```
abrir("rlm-diag-final", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
plot(m_back, which = 1, col = adjustcolor(teal, 0.6)
     , pch = 19, cex = 0.6,
     caption = "", sub.caption = "")
titulo("Modelo reducido: residuos vs. ajustados")
plot(m_back, which = 2, col = adjustcolor(teal, 0.6)
     , pch = 19, cex = 0.6,
     caption = "", sub.caption = "")
titulo("Modelo reducido: Q-Q normal")
dev.off()
```

```
shapiro.test(residuals(m_back))
bptest(m_back)
resettest(m_back, power = 2:3)
vif(m_back)
```

```
        Shapiro-Wilk normality test
```

```
data:  residuals(m_back)
W = 0.96, p-value = 0.000000004


        studentized Breusch-Pagan test

data:  m_back
BP = 3.7, df = 4, p-value = 0.5


        RESET test

data:  m_back
RESET = 3.7, df1 = 2, df2 = 388, p-value = 0.03

                edad reprobaciones_previas       educacion_madre        apoyo_familiar
               1.091                 1.110                 1.102                 1.049
```

Prueba	Completo	Reducido	Conclusión (reducido)
RESET (linealidad)	0,020	0,030	se rechaza al 5 %
Shapiro-Wilk (normalidad)	1×10^{-8}	4×10^{-9}	se rechaza
Breusch-Pagan (homocedasticidad)	0,020	0,50	**se cumple**
VIF máximo	1,74	1,11	sin multicolinealidad

Al quitar variables desaparece la heterocedasticidad, pero la banda de ceros sigue ahí y mantiene la falta de normalidad y el RESET significativo. Para comprobar que esa es la causa, reajusté el modelo final sin los 38 ceros:

```r
# los 38 ceros corresponden a alumnos que no rindieron la evaluacion final
m_sin0 <- lm(formula(m_back), data = subset(est, nota_final > 0))
round(cbind(con_ceros = coef(m_back), sin_ceros = coef(m_sin0)), 3)
c(R2aj_sin_ceros = summary(m_sin0)$adj.r.squared,
  shapiro_p = shapiro.test(residuals(m_sin0))$p.value,
  bp_p = unname(bptest(m_sin0)$p.value))
```

```
                    con_ceros sin_ceros
(Intercept)            14.354    13.885
edad                   -0.267    -0.166
reprobaciones_previas  -1.924    -1.211
educacion_madre         0.621     0.432
apoyo_familiaryes      -0.884    -0.767
R2aj_sin_ceros    shapiro_p          bp_p
        0.1089       0.1007        0.0291
```

Sin los ceros los residuos pasan Shapiro-Wilk ($p = 0{,}10$) y todos los signos se mantienen; el efecto de `reprobaciones_previas` baja de $-1{,}92$ a $-1{,}21$ porque parte de él era "reprobar $\Rightarrow$ abandonar".

Resultado. El modelo reducido cumple homocedasticidad y no tiene multicolinealidad; la no normalidad se debe a los alumnos que abandonaron. Concluyo que **reprobaciones previas** es el factor de mayor peso (negativo), seguido de la **educación de la madre** (positivo); el apoyo familiar tiene signo negativo, que leo como causalidad inversa (las familias apoyan más a quien ya va mal). Un modelo en dos partes (abandono sí/no + nota si rinde) trataría mejor los ceros.