MAESTRÍA EN CIENCIA DE DATOS

Regresión Logística Binaria

Odds ratios, matriz de confusión y curva ROC

Base de datos: Heart Disease (Cleveland, UCI)
Máxima verosimilitud, razón de verosimilitudes, ROC/AUC

Elaborado por: Miguel Deza
Programa: Maestría en Ciencia de Datos – UNSA
Curso: Estadística en Ciencia de Datos
Docente: Carlos Antonio Abanto Valle

Fecha: 7 de noviembre de 2026

Índice

a) Ajuste por máxima verosimilitud 3
b) Tabla de estimación y significancia 3
c) Interpretación de edad, angina_ejercicio y depresion_st 4
d) Odds ratios e IC 95 % 4
e) Calidad del ajuste: razón de verosimilitudes y matriz de confusión 5
f) Curva ROC y AUC 6
g) Limitaciones y extensiones 7

Todo el análisis está en `2_Regresion_Logistica_Binaria.R` (R 4.6.1; paquetes `lmtest` y `pROC`), que lee `heart.csv` (297 pacientes, sin valores faltantes). En cada pregunta muestro el bloque de código, su salida de consola y la interpretación.

Datos y modelo

$$\log \frac{P(Y_i = 1 \mid x_i)}{1 - P(Y_i = 1 \mid x_i)} = \beta_0 + \beta_1\, \text{edad}_i + \beta_2\, \text{sexo}_i + \beta_3\, \text{colesterol}_i + \beta_4\, \text{presion_reposo}_i$$
$$+ \beta_5\, \text{frecuencia_cardiaca_max}_i + \beta_6\, \text{angina_ejercicio}_i + \beta_7\, \text{depresion_st}_i$$

con $Y_i = 1$ si el paciente tiene enfermedad cardíaca. `sexo` (referencia: mujer) y `angina_ejercicio` (referencia: no) entran como factores.

```
cor_df <- read.csv("heart.csv")
cor_df$enf  <- factor(cor_df$enfermedad_cardiaca, levels = c("No", "Si"))
cor_df$sexo <- factor(cor_df$sexo, levels = 0:1, labels = c("mujer", "hombre"))
cor_df$angina_ejercicio <- factor(cor_df$angina_ejercicio, levels = 0:1,
                                  labels = c("no", "si"))
table(cor_df$enf)
```

```
 No  Si
160 137
```

Las clases están casi balanceadas: 137 enfermos (46,1 %) y 160 sanos.

Justificación de las variables. Antes de ajustar comparé cada covariable entre enfermos y sanos:

```
num <- c("edad", "colesterol", "presion_reposo", "frecuencia_cardiaca_max", "depresion_st")
t(sapply(num, function(v) {
  x <- cor_df[[v]]
  c(media_No = mean(x[cor_df$enf == "No"]), media_Si = mean(x[cor_df$enf == "Si"]),
    p_t = t.test(x ~ cor_df$enf)$p.value)
}))
prop.table(table(cor_df$sexo, cor_df$enf), 1)
prop.table(table(cor_df$angina_ejercicio, cor_df$enf), 1)
c(p_sexo = chisq.test(table(cor_df$sexo, cor_df$enf))$p.value,
  p_angina = chisq.test(table(cor_df$angina_ejercicio, cor_df$enf))$p.value)
```

```
                      media_No media_Si       p_t
edad                   52.6437   56.759 6.204e-05
colesterol            243.4938  251.854 1.650e-01
presion_reposo        129.1750  134.635 8.808e-03
frecuencia_cardiaca_max 158.5813  139.109 6.108e-14
depresion_st            0.5988    1.589 3.429e-13

            No     Si
  mujer  0.7396 0.2604
  hombre 0.4428 0.5572

        No     Si
  no 0.6850 0.3150
  si 0.2371 0.7629
   p_sexo  p_angina
2.946e-06 9.511e-13
```

Seis de las siete variables difieren claramente entre grupos: los enfermos son mayores, con más presión, menor frecuencia cardíaca máxima, mayor depresión ST, más hombres (56 % vs. 26 % de enfermos) y más angina de esfuerzo (76 % vs. 32 %). El colesterol no difiere de forma marginal ($p = 0{,}17$), pero lo mantengo porque es un factor de riesgo clásico y puede aportar ajustado por las demás. Todas son medidas clínicas baratas, disponibles antes de un cateterismo.

Pregunta a)

Ajuste el modelo de regresión logística binaria mediante el método de máxima verosimilitud.

$$\ln L(\boldsymbol{\beta}) = \sum_{i=1}^{n} \left[y_i \, x_i^{\top} \boldsymbol{\beta} - \ln\!\left(1 + e^{x_i^{\top} \boldsymbol{\beta}}\right) \right], \qquad \frac{\partial \ln L}{\partial \boldsymbol{\beta}} = \sum_{i=1}^{n} x_i \left(y_i - \pi_i \right) = \mathbf{0}$$

No tiene solución cerrada: `glm()` la resuelve por Fisher scoring (IRLS), que convergió en 5 iteraciones.

```
m_log <- glm(enf ~ edad + sexo + colesterol + presion_reposo +
               frecuencia_cardiaca_max + angina_ejercicio + depresion_st,
             family = binomial(link = "logit"), data = cor_df)
summary(m_log)
```

```
Call:
glm(formula = enf ~ edad + sexo + colesterol + presion_reposo +
    frecuencia_cardiaca_max + angina_ejercicio + depresion_st,
    family = binomial(link = "logit"), data = cor_df)

Coefficients:
                       Estimate Std. Error z value  Pr(>|z|)
(Intercept)             -2.38311    2.06517   -1.15    0.2485
edad                     0.01987    0.01952    1.02    0.3087
sexohombre               1.65158    0.36303    4.55 0.0000054 ***
colesterol               0.00616    0.00301    2.04    0.0411 *
presion_reposo           0.01424    0.00911    1.56    0.1182
frecuencia_cardiaca_max -0.02960    0.00836   -3.54    0.0004 ***
angina_ejerciciosi       1.32464    0.33709    3.93 0.0000851 ***
depresion_st             0.58259    0.14784    3.94 0.0000813 ***
---
Signif. codes:  0 ’***’ 0.001 ’**’ 0.01 ’*’ 0.05 ’.’ 0.1 ’ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 409.95  on 296  degrees of freedom
Residual deviance: 274.16  on 289  degrees of freedom
AIC: 290.2

Number of Fisher Scoring iterations: 5
```

Resultado. La devianza baja de 409,95 (modelo nulo) a 274,16 con 7 parámetros adicionales; AIC $= 290{,}2$.

Pregunta b)

Presente la tabla de estimación de los parámetros e identifique las variables estadísticamente significativas al nivel $\alpha = 0{,}05$.

Variable	$\hat{\beta}$	EE	z	p	¿Signif.?
Intercepto	$-2{,}383$	2,065	$-1{,}15$	0,249	no
edad	0,0199	0,0195	1,02	0,309	no
sexo (hombre)	1,652	0,363	4,55	$< 0{,}001$	**sí**
colesterol	0,0062	0,0030	2,04	0,041	**sí**
presion_reposo	0,0142	0,0091	1,56	0,118	no
frecuencia_cardiaca_max	$-0{,}0296$	0,0084	$-3{,}54$	$< 0{,}001$	**sí**
angina_ejercicio (sí)	1,325	0,337	3,93	$< 0{,}001$	**sí**
depresion_st	0,583	0,148	3,94	$< 0{,}001$	**sí**

Edad y presión en reposo sí diferían entre grupos por separado, pero dejan de ser significativas al ajustar: su información ya la cargan la frecuencia cardíaca máxima (que baja con la edad) y la depresión ST.

Resultado. Significativas al 5 %: **sexo, colesterol, frecuencia_cardiaca_max, angina_ejercicio y depresion_st**.

Pregunta c)

Interprete los coeficientes asociados a las variables edad, angina_ejercicio y depresion_st en términos de odds ratios.

$$OR_j = e^{\hat{\beta}_j} = \frac{\text{odds}(x_j + 1)}{\text{odds}(x_j)}$$

- **edad**: $e^{0{,}0199} = 1{,}020$. Cada año adicional multiplica los odds de enfermedad por 1,02 (+2 %); en 10 años, $e^{10(0{,}0199)} = 1{,}22$ (+22 %), con las demás variables fijas. No es significativo ($p = 0{,}31$).
- **angina_ejercicio**: $e^{1{,}325} = 3{,}76$. Un paciente con angina inducida por ejercicio tiene odds de enfermedad 3,8 veces mayores que uno sin angina, a igualdad del resto.
- **depresion_st**: $e^{0{,}583} = 1{,}79$. Cada milímetro adicional de depresión del segmento ST multiplica los odds por 1,79 (+79 %).

Pregunta d)

Calcule e interprete los odds ratios y sus intervalos de confianza al 95 %.

```
or <- exp(cbind(OR = coef(m_log), confint(m_log)))   # IC por verosimilitud perfil
round(or, 4)
```

```
                            OR  2.5 %  97.5 %
(Intercept)             0.0923 0.0015  5.1629
edad                    1.0201 0.9819  1.0603
sexohombre              5.2152 2.6183 10.9252
colesterol              1.0062 1.0003  1.0123
presion_reposo          1.0143 0.9965  1.0329
frecuencia_cardiaca_max 0.9708 0.9545  0.9864
angina_ejerciciosi      3.7608 1.9572  7.3753
depresion_st            1.7907 1.3534  2.4232
```

Los intervalos son por verosimilitud perfil (`confint` de un `glm`), mejores que $e^{\hat{\beta} \pm 1{,}96\, EE}$ cuando la log-verosimilitud no es simétrica.

Variable	OR	IC 95 %	Lectura
sexo (hombre)	5,22	[2,62 ; 10,93]	odds 5 veces mayores en hombres
angina_ejercicio (sí)	3,76	[1,96 ; 7,38]	odds casi 4 veces mayores
depresion_st	1,79	[1,35 ; 2,42]	+79 % por mm
colesterol	1,006	[1,0003 ; 1,012]	+6,4 % cada 10 mg/dl
frecuencia_cardiaca_max	0,971	[0,955 ; 0,986]	-26 % cada 10 lpm ($0{,}971^{10} = 0{,}74$)
presion_reposo	1,014	[0,997 ; 1,033]	incluye 1: no concluyente
edad	1,020	[0,982 ; 1,060]	incluye 1: no concluyente

Resultado. Los IC que no contienen al 1 coinciden con las variables significativas. Los factores de riesgo más fuertes son ser hombre y tener angina de esfuerzo; una frecuencia cardíaca máxima alta es protectora.

Pregunta e)

Evalúe la calidad del ajuste utilizando la razón de verosimilitudes, la matriz de confusión y la tasa de clasificación correcta (umbral 0,5); interprete exactitud, sensibilidad y especificidad en el contexto del diagnóstico.

```
m_nulo <- glm(enf ~ 1, family = binomial, data = cor_df)
lrtest(m_nulo, m_log)
c(R2_McFadden = 1 - as.numeric(logLik(m_log) / logLik(m_nulo)))
```

```
Likelihood ratio test

Model 1: enf ~ 1
Model 2: enf ~ edad + sexo + colesterol + presion_reposo + frecuencia_cardiaca_max +
    angina_ejercicio + depresion_st
  #Df LogLik Df Chisq Pr(>Chisq)
1   1   -205
2   8   -137  7   136     <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
R2_McFadden
     0.3312
```

$$G^2 = -2\big[\ln L_0 - \ln L_1\big] = 409{,}95 - 274{,}16 = 135{,}8 \;\sim\; \chi^2_7, \qquad p < 2\times 10^{-16}$$

Rechazo $H_0 : \beta_1 = \cdots = \beta_7 = 0$: el modelo explica significativamente más que solo la prevalencia. El R^2 de McFadden (0,33) está en el rango que se considera un buen ajuste (0,2–0,4).

```
p_hat <- fitted(m_log)
pred  <- factor(ifelse(p_hat >= 0.5, "Si", "No"), levels = c("No", "Si"))
mc <- table(Real = cor_df$enf, Predicha = pred)
mc
VN <- mc["No", "No"]; FP <- mc["No", "Si"]; FN <- mc["Si", "No"]; VP <- mc["Si", "Si"]
c(Exactitud = (VP + VN) / sum(mc), Sensibilidad = VP / (VP + FN),
  Especificidad = VN / (VN + FP), Tasa_error = (FP + FN) / sum(mc))
```

```
    Predicha
Real  No  Si
  No 133  27
  Si  37 100
   Exactitud  Sensibilidad Especificidad    Tasa_error
      0.7845        0.7299        0.8313        0.2155
```

	Clase predicha	
Clase real	No	Sí
No	VN = 133	FP = 27
Sí	FN = 37	VP = 100

$$\text{Exactitud} = \frac{100 + 133}{297} = 0{,}785$$

$$\text{Sensibilidad} = \frac{100}{100 + 37} = 0{,}730, \qquad \text{Especificidad} = \frac{133}{133 + 27} = 0{,}831$$

- **Exactitud 78,5 %**: clasifica bien a casi 4 de cada 5 pacientes (la regla trivial "todos sanos" acertaría 53,9 %).
- **Sensibilidad 73,0 %**: detecta 100 de 137 enfermos; **37 enfermos quedan como sanos**. En diagnóstico cardíaco este es el error caro, porque un enfermo no detectado no recibe tratamiento.
- **Especificidad 83,1 %**: 27 sanos serían derivados a pruebas adicionales sin necesidad; es un costo, pero menor.

Resultado. El modelo ajusta significativamente ($G^2 = 135{,}8$) y clasifica bien el 78,5 %. Con umbral 0,5 es más específico que sensible; para tamizaje convendría bajar el umbral (ver pregunta f).

Pregunta f)

Analice la capacidad predictiva del modelo mediante la curva ROC e interprete el área bajo la curva (AUC).

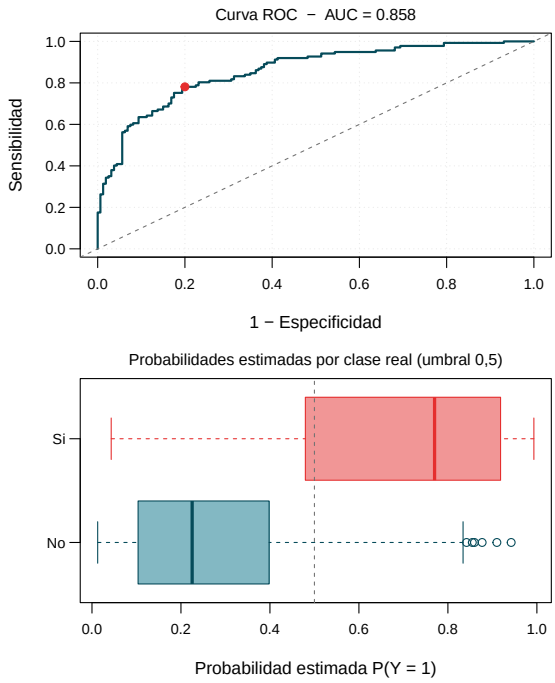


Figura 1: *Curva ROC con el punto de Youden (arriba) y probabilidades estimadas por clase (abajo).*

```
roc_log <- roc(cor_df$enf, p_hat, levels = c("No", "
    Si"), direction = "<", quiet = TRUE)
auc(roc_log)
ci.auc(roc_log)
coords(roc_log, "best", best.method = "youden",
       ret = c("threshold", "sensitivity", "
    specificity"))
```

```
roc_log <- roc(cor_df$enf, p_hat, levels = c("No", "Si"), direction = "<", quiet = TRUE)
auc(roc_log)
ci.auc(roc_log)
coords(roc_log, "best", best.method = "youden",
       ret = c("threshold", "sensitivity", "specificity"))
```

```
Area under the curve: 0.858
95% CI: 0.816-0.9 (DeLong)
  threshold sensitivity specificity
1    0.4431       0.781         0.8
```

AUC $= 0{,}858$ (IC 95 % DeLong: 0,816–0,900): si tomo al azar un enfermo y un sano, en el 85,8 % de los casos el modelo le asigna mayor probabilidad al enfermo. Es una discriminación *buena* (0,8–0,9) y el IC está lejos de 0,5. El umbral de Youden (0,443) sube la sensibilidad a 78,1 % con especificidad de 80 %, un mejor equilibrio para tamizaje que 0,5.

Resultado. AUC $= 0{,}858$: el modelo discrimina bien entre enfermos y sanos.

Pregunta g)

Discuta las limitaciones del modelo y proponga posibles extensiones.

Todas las métricas anteriores se calcularon sobre los mismos 297 pacientes del ajuste, lo que las hace optimistas. Lo verifiqué con validación cruzada de 10 pliegues:

```
set.seed(2026)
pliegue <- sample(rep(1:10, length.out = nrow(cor_df)))
p_cv <- numeric(nrow(cor_df))
for (k in 1:10) {
  fit <- update(m_log, data = cor_df[pliegue != k, ])
  p_cv[pliegue == k] <- predict(fit, cor_df[pliegue == k, ], type = "response")
}
c(AUC_cv = as.numeric(auc(roc(cor_df$enf, p_cv, levels = c("No", "Si"),
                              direction = "<", quiet = TRUE))),
  Exactitud_cv = mean((p_cv >= 0.5) == (cor_df$enf == "Si")))
```

```
      AUC_cv Exactitud_cv
      0.8360       0.7609
```

Fuera de muestra el AUC baja de 0,858 a 0,836 y la exactitud de 78,5 % a 76,1 %: hay algo de sobreajuste, pero el modelo generaliza razonablemente.

Limitaciones

- Solo 297 pacientes de un único hospital (Cleveland): poca validez externa.
- Supone que el logit es lineal en cada variable continua (edad, colesterol, frecuencia cardíaca, depresión ST) y no incluye interacciones (por ejemplo, sexo $\times$ edad).
- Deja fuera predictores muy informativos de la base: tipo de dolor torácico, vasos coloreados por fluoroscopía, talasemia y pendiente ST.
- Es un estudio transversal: los OR son asociaciones, no efectos causales.

Extensiones

- Agregar las variables omitidas y seleccionar con AIC/BIC o con regularización (lasso).
- Términos no lineales (splines en edad y frecuencia cardíaca) o un GAM.
- Usar `diagnostico_original` (0–4) en un modelo logístico ordinal de severidad.
- Elegir el umbral según el costo relativo FN/FP y validar en una cohorte externa.