Estadística en Ciencia de Datos

Ejercicio: Regresión Lineal Múltiple y Selección de Variables

Base de datos: *Student Performance* (UCI)

Contexto

Se dispone de información académica, familiar y socioeconómica de estudiantes de educación secundaria. El objetivo es analizar los factores que influyen en el desempeño académico final, medido por la `nota_final`.

Modelo de Regresión Lineal Múltiple

Considere el siguiente modelo de regresión lineal múltiple:

$$\begin{aligned} \text{nota_final}_i = \beta_0 &+ \beta_1\,\text{edad}_i + \beta_2\,\text{tiempo_estudio}_i + \beta_3\,\text{inasistencias}_i + \beta_4\,\text{reprobaciones_previas}_i \\ &+ \beta_5\,\text{educacion_madre}_i + \beta_6\,\text{educacion_padre}_i + \beta_7\,\text{internet_casa}_i \\ &+ \beta_8\,\text{apoyo_familiar}_i + \varepsilon_i, \\ \varepsilon_i &\sim \mathcal{N}(0, \sigma^2). \end{aligned} \tag{1}$$

Preguntas

a) Ajuste el modelo de regresión lineal múltiple utilizando mínimos cuadrados ordinarios. Presente la tabla de estimación de los parámetros e identifique las variables estadísticamente significativas al nivel $\alpha = 0{,}05$.

b) Interprete los coeficientes asociados a las variables `tiempo_estudio`, `inasistencias` y `reprobaciones_previas`, manteniendo constantes las demás covariables.

c) Reporte el coeficiente de determinación R^2 y el R^2 ajustado. Explique por qué el R^2 ajustado es más apropiado en este contexto.

d) Evalúe los principales supuestos del modelo lineal (linealidad, normalidad de los residuos y homocedasticidad), incluyendo gráficos de diagnóstico y comentarios.

e) Analice la posible presencia de multicolinealidad utilizando el factor de inflación de la varianza (VIF).

Selección de variables: método *Backward*

Aplique el método de eliminación hacia atrás (*backward elimination*) utilizando el criterio de información de Akaike (AIC), partiendo del modelo completo.

a) Indique qué variables son eliminadas en el proceso y presente el modelo final seleccionado.

b) Compare el valor del AIC del modelo completo con el del modelo reducido y comente si la reducción del modelo implica una mejora en términos de parsimonia.

c) Analice el coeficiente de determinación ajustado del modelo final y discuta los cambios respecto al modelo inicial.

d) Evalúe los supuestos del modelo seleccionado e interprete los resultados.

Indicaciones

- Trate las variables binarias como factores.
- Justifique cualquier decisión de exclusión de variables.
- Presente conclusiones claras y bien fundamentadas.

Estadística en Ciencia de Datos

Ejercicio: Regresión Logística Binaria

Base de datos: *Heart Disease* (Cleveland, UCI)

Contexto

La base de datos *Heart Disease* contiene información clínica y demográfica de pacientes sometidos a estudios cardiovasculares. El objetivo es modelar la probabilidad de presencia de enfermedad cardíaca a partir de un conjunto de variables explicativas.

Sea la variable respuesta

$$Y_i = \begin{cases} 1, & \text{si el paciente presenta enfermedad cardíaca,} \\ 0, & \text{en caso contrario.} \end{cases}$$

—

Modelo de Regresión Logística

Considere el siguiente modelo de regresión logística binaria:

$$\begin{aligned} \log\left(\frac{\mathbb{P}(Y_i = 1 \mid \mathbf{x}_i)}{1 - \mathbb{P}(Y_i = 1 \mid \mathbf{x}_i)}\right) = \beta_0 &+ \beta_1 \,\text{edad}_i + \beta_2 \,\text{sexo}_i + \beta_3 \,\text{colesterol}_i + \beta_4 \,\text{presion_reposo}_i \\ &+ \beta_5 \,\text{frecuencia_cardiaca_max}_i \\ &+ \beta_6 \,\text{angina_ejercicio}_i + \beta_7 \,\text{depresion_st}_i. \end{aligned} \tag{1}$$

—

Preguntas

a) Ajuste el modelo de regresión logística binaria mediante el método de máxima verosimilitud.

b) Presente la tabla de estimación de los parámetros e identifique las variables estadísticamente significativas al nivel $\alpha = 0{,}05$.

c) Interprete los coeficientes asociados a las variables `edad`, `angina_ejercicio` y `depresion_st` en términos de *odds ratios*.

d) Calcule e interprete los *odds ratios* y sus intervalos de confianza al 95 %.

e) Evalúe la calidad del ajuste del modelo utilizando:

- la razón de verosimilitudes,
- la matriz de confusión y la tasa de clasificación correcta.

f) Analice la capacidad predictiva del modelo mediante la curva ROC e interprete el área bajo la curva (AUC).

g) Discuta las limitaciones del modelo y proponga posibles extensiones.

—

Indicaciones técnicas

- Trate las variables binarias como factores.
- Justifique la inclusión de las variables explicativas.
- Acompañe los resultados con interpretación sustantiva.

—

Matriz de confusión y medidas de desempeño

Con el objetivo de evaluar el desempeño predictivo del modelo de regresión logística, se considera un umbral de clasificación de 0,5 para la probabilidad estimada de presencia de enfermedad cardíaca.

La *matriz de confusión* compara las clases reales con las clases predichas por el modelo y se define como sigue:

	Clase predicha	
Clase real	No	Sí
No	Verdaderos Negativos (VN)	Falsos Positivos (FP)
Sí	Falsos Negativos (FN)	Verdaderos Positivos (VP)

A partir de la matriz de confusión se definen las siguientes medidas de desempeño:

- **Exactitud (Accuracy):**

$$\text{Exactitud} = \frac{VP + VN}{VP + VN + FP + FN}.$$

- **Sensibilidad** (o tasa de verdaderos positivos):

$$\text{Sensibilidad} = \frac{VP}{VP + FN}.$$

- **Especificidad** (o tasa de verdaderos negativos):

$$\text{Especificidad} = \frac{VN}{VN + FP}.$$

Interprete los valores obtenidos para cada una de estas medidas y discuta su relevancia en el contexto del diagnóstico de enfermedad cardíaca. —

Objetivo pedagógico

Este ejercicio evalúa la capacidad del estudiante para:

- Formular modelos de regresión logística,
- Interpretar parámetros y odds ratios,
- Evaluar ajuste y desempeño predictivo,
- Conectar inferencia estadística y clasificación.

Estadística en Ciencia de Datos

Ejercicio: Análisis de Componentes Principales (ACP)

Base de datos: *Student Performance* (UCI)

Contexto

La base de datos *Student Performance* contiene información académica, familiar y socioeconómica de estudiantes de educación secundaria. Dado el gran número de variables explicativas potencialmente correlacionadas, resulta de interés aplicar técnicas de reducción de dimensionalidad.

El objetivo de este ejercicio es analizar la estructura de dependencia entre las variables mediante el *Análisis de Componentes Principales* (ACP).

—

Variables consideradas

Considere las siguientes variables cuantitativas:

- `edad`
- `tiempo_estudio`
- `inasistencias`
- `reprobaciones_previas`
- `educacion_madre`
- `educacion_padre`
- `salud`
- `tiempo_libre`
- `salidas_sociales`
- `alcohol_dias_semana`
- `alcohol_fin_semana`

Todas las variables deben ser tratadas como numéricas.

—

Preguntas

a) Explique por qué es necesario estandarizar las variables antes de aplicar el Análisis de Componentes Principales en este contexto.

b) Calcule la matriz de correlaciones entre las variables y comente brevemente la presencia de relaciones lineales relevantes.

c) Aplique el Análisis de Componentes Principales utilizando la matriz de correlaciones.

d) Presente el *scree plot* e indique cuántos componentes principales deberían retenerse según el criterio de la varianza explicada acumulada (80 % o 90 %).

e) Interprete los dos primeros componentes principales en términos de las variables originales, analizando los signos y magnitudes de las cargas (*loadings*).

f) Represente gráficamente los individuos en el plano definido por los dos primeros componentes principales e identifique posibles patrones o agrupamientos.

g) Discuta si los componentes principales obtenidos podrían ser utilizados posteriormente como variables explicativas en un modelo de regresión.

—

Indicaciones técnicas

- Utilice variables estandarizadas.
- Justifique el número de componentes retenidos.
- Acompañe la interpretación con gráficos adecuados.

—

Objetivo pedagógico

Este ejercicio evalúa la capacidad del estudiante para:

- Comprender la motivación del ACP,
- Aplicar correctamente la técnica,
- Interpretar componentes principales,
- Integrar reducción de dimensionalidad con modelos estadísticos.

Estadística en Ciencia de Datos

Ejercicio: Análisis de Conglomerados

Base de datos: *Heart Disease* (Cleveland, UCI)

Contexto

La base de datos *Heart Disease* contiene información clínica y demográfica de pacientes sometidos a estudios cardiovasculares. Más allá del enfoque supervisado (regresión logística), es de interés identificar *grupos homogéneos de pacientes* utilizando técnicas de *Análisis de Conglomerados*.

El objetivo de este ejercicio es explorar la estructura latente de los datos y caracterizar perfiles de riesgo cardiovascular.

—

Variables consideradas

Considere las siguientes variables cuantitativas:

- `edad`
- `presion_reposo`
- `colesterol`
- `frecuencia_cardiaca_max`
- `depresion_st`

Antes de aplicar los métodos de conglomerados, todas las variables deben ser **estandarizadas**.

—

Preguntas

a) Explique por qué es necesario estandarizar las variables antes de realizar un análisis de conglomerados en este contexto.

b) Calcule la matriz de distancias euclidianas entre los individuos a partir de las variables estandarizadas.

—

Conglomerados jerárquicos: método Ward.D2

c) Aplique un análisis de conglomerados jerárquicos utilizando el método de Ward (`ward.D2`).

d) Represente el dendrograma correspondiente e indique el número de conglomerados que considera adecuado, justificando su elección.

e) Asigne cada individuo a un conglomerado y describa las principales características clínicas de cada grupo.

—

Conglomerados no jerárquicos: método *k*-means

f) Aplique el método de k-means considerando el mismo número de conglomerados seleccionado en el método jerárquico.

g) Analice los centroides obtenidos e interprete los perfiles de cada grupo en términos de riesgo cardiovascular.

—

Comparación de métodos

a) Compare los conglomerados obtenidos mediante los métodos `ward.D2` y k-means.

b) Discuta las similitudes y diferencias entre ambos enfoques.

c) Analice la relación entre los conglomerados obtenidos y la variable `enfermedad_cardiaca`.

—

Indicaciones técnicas

- Utilice distancia euclidiana.
- Trabaje con variables estandarizadas.
- Acompañe el análisis con gráficos y tablas descriptivas.
- Interprete los conglomerados desde una perspectiva clínica.

—

Objetivo pedagógico

Este ejercicio permite evaluar la capacidad del estudiante para:

- Aplicar métodos jerárquicos y no jerárquicos de conglomerados,
- Interpretar dendrogramas y centroides,
- Comparar enfoques supervisados y no supervisados,
- Extraer perfiles clínicos relevantes a partir de los datos.