MAESTRÍA EN CIENCIA DE DATOS

Trabajo Final
Estadística en Ciencia de Datos
Modelos supervisados y no supervisados en R

Regresión lineal múltiple y selección backward · Regresión logística binaria
Componentes principales · Conglomerados Ward.D2 y k-means
Bases: Student Performance y Heart Disease (Cleveland), UCI

Elaborado por: Miguel Deza
Programa: Maestría en Ciencia de Datos – UNSA
Curso: Estadística en Ciencia de Datos
Docente: Carlos Antonio Abanto Valle

Fecha: 7 de noviembre de 2026

Índice

1. Regresión lineal múltiple y selección backward **3**
a) Ajuste por MCO y variables significativas . . . 4
b) Interpretación de tiempo_estudio, inasistencias y reprobaciones_previas . . . 5
c) R^2 y R^2 ajustado . . . 6
d) Supuestos del modelo . . . 6
e) Multicolinealidad (VIF) . . . 8
Backward a) Variables eliminadas y modelo final . . . 8
Backward b) Comparación de AIC y parsimonia . . . 10
Backward c) R^2 ajustado del modelo final . . . 11
Backward d) Supuestos del modelo seleccionado . . . 11

2. Regresión logística binaria **13**
a) Ajuste por máxima verosimilitud . . . 15
b) Tabla de estimación y significancia . . . 15
c) Interpretación de edad, angina_ejercicio y depresion_st . . . 16
d) Odds ratios e IC 95 % . . . 16
e) Calidad del ajuste: razón de verosimilitudes y matriz de confusión . . . 17
f) Curva ROC y AUC . . . 18
g) Limitaciones y extensiones . . . 19

3. Análisis de componentes principales **20**
a) Por qué estandarizar . . . 21
b) Matriz de correlaciones . . . 21
c) ACP con la matriz de correlaciones . . . 23
d) Scree plot y número de componentes . . . 24
e) Interpretación de CP1 y CP2 . . . 25
f) Individuos en el plano CP1–CP2 . . . 26
g) CP como variables explicativas . . . 27

4. Análisis de conglomerados **29**
a) Por qué estandarizar . . . 30
b) Matriz de distancias euclidianas . . . 30
c) Ward.D2 . . . 31
d) Dendrograma y número de grupos . . . 32
e) Asignación y características de cada grupo . . . 32
f) k-means con $k = 3$ . . . 33
g) Centroides y perfiles de riesgo . . . 34
Comparación a) Ward.D2 vs. k-means . . . 35
Comparación b) Similitudes y diferencias entre enfoques . . . 36

Comparación c) Relación con enfermedad_cardiaca 36

El análisis está en cuatro scripts independientes, uno por ejercicio: `RLM.R`, `Logistica.R`, `CP.R` y `Conglomerados.R` (R 4.6.1; paquetes `car`, `lmtest`, `pROC`, `cluster` y `corrplot`). Las bases son `student.csv` (395 estudiantes) y `heart.csv` (297 pacientes, sin valores faltantes). En cada pregunta muestro el bloque de código, su salida de consola y la interpretación.

1

SECCIÓN

Regresión lineal múltiple

Student Performance · preguntas a – e y método backward

Datos y modelo

$$\begin{aligned}\text{nota_final}_i = \beta_0 &+ \beta_1\,\text{edad}_i + \beta_2\,\text{tiempo_estudio}_i + \beta_3\,\text{inasistencias}_i + \beta_4\,\text{reprobaciones_previas}_i \\ &+ \beta_5\,\text{educacion_madre}_i + \beta_6\,\text{educacion_padre}_i + \beta_7\,\text{internet_casa}_i \\ &+ \beta_8\,\text{apoyo_familiar}_i + \varepsilon_i, \qquad \varepsilon_i \sim N(0,\sigma^2)\end{aligned}$$

Las variables binarias `internet_casa` y `apoyo_familiar` entran como factores con nivel de referencia *no*.

```
est <- read.csv("student.csv")
est$internet_casa  <- factor(est$internet_casa,  levels = c("no", "yes"))
est$apoyo_familiar <- factor(est$apoyo_familiar, levels = c("no", "yes"))
vars <- c("nota_final", "edad", "tiempo_estudio", "inasistencias",
          "reprobaciones_previas", "educacion_madre", "educacion_padre")
summary(est[, vars])
table(nota_final_cero = est$nota_final == 0)
```

```
   nota_final        edad      tiempo_estudio inasistencias   reprobaciones_previas
 Min.   : 0.0   Min.   :15.0   Min.   :1.00   Min.   : 0.00   Min.   :0.000
 1st Qu.: 8.0   1st Qu.:16.0   1st Qu.:1.00   1st Qu.: 0.00   1st Qu.:0.000
 Median :11.0   Median :17.0   Median :2.00   Median : 4.00   Median :0.000
 Mean   :10.4   Mean   :16.7   Mean   :2.04   Mean   : 5.71   Mean   :0.334
 3rd Qu.:14.0   3rd Qu.:18.0   3rd Qu.:2.00   3rd Qu.: 8.00   3rd Qu.:0.000
 Max.   :20.0   Max.   :22.0   Max.   :4.00   Max.   :75.00   Max.   :3.000
 educacion_madre educacion_padre
 Min.   :0.00    Min.   :0.00
 1st Qu.:2.00    1st Qu.:2.00
 Median :3.00    Median :2.00
 Mean   :2.75    Mean   :2.52
 3rd Qu.:4.00    3rd Qu.:3.00
 Max.   :4.00    Max.   :4.00
nota_final_cero
FALSE  TRUE
  357    38
```

La nota va de 0 a 20 y hay **38 notas iguales a 0**. Las revisé: los 38 tienen 0 inasistencias, es decir, son alumnos que no rindieron la evaluación final (abandono), no notas bajas "normales". Las mantengo en el ajuste porque el enunciado pide el modelo sobre la base completa, pero este detalle explica casi todos los problemas de supuestos que aparecen después.

Pregunta a)

Ajuste el modelo de regresión lineal múltiple utilizando mínimos cuadrados ordinarios. Presente la tabla de estimación de los parámetros e identifique las variables estadísticamente significativas al nivel $\alpha = 0{,}05$.

```
m_full <- lm(nota_final ~ edad + tiempo_estudio + inasistencias +
               reprobaciones_previas + educacion_madre + educacion_padre +
               internet_casa + apoyo_familiar, data = est)
summary(m_full)
```

```
Call:
lm(formula = nota_final ~ edad + tiempo_estudio + inasistencias +
    reprobaciones_previas + educacion_madre + educacion_padre +
    internet_casa + apoyo_familiar, data = est)

Residuals:
    Min      1Q  Median      3Q     Max
-12.346  -2.005   0.228   2.963   8.804
```

```
Coefficients:
                    Estimate Std. Error t value     Pr(>|t|)
(Intercept)          14.0789     3.1706    4.44 0.0000117344 ***
edad                 -0.3060     0.1784   -1.72        0.087 .
tiempo_estudio        0.2784     0.2625    1.06        0.290
inasistencias         0.0322     0.0275    1.17        0.242
reprobaciones_previas -1.8940     0.3090   -6.13 0.0000000022 ***
educacion_madre       0.5841     0.2560    2.28        0.023 *
educacion_padre      -0.0534     0.2550   -0.21        0.834
internet_casayes      0.5522     0.5879    0.94        0.348
apoyo_familiaryes    -0.9844     0.4542   -2.17        0.031 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.22 on 386 degrees of freedom
Multiple R-squared:  0.168,     Adjusted R-squared:  0.151
F-statistic: 9.77 on 8 and 386 DF,  p-value: 2.23e-12
```

Variable	$\hat{\beta}$	EE	t	p	¿Signif.?
Intercepto	14,079	3,171	4,44	$< 0{,}001$	sí
edad	$-0{,}306$	0,178	$-1{,}72$	0,087	no
tiempo_estudio	0,278	0,263	1,06	0,290	no
inasistencias	0,032	0,028	1,17	0,242	no
reprobaciones_previas	$-1{,}894$	0,309	$-6{,}13$	$< 0{,}001$	**sí**
educacion_madre	0,584	0,256	2,28	0,023	**sí**
educacion_padre	$-0{,}053$	0,255	$-0{,}21$	0,834	no
internet_casa (sí)	0,552	0,588	0,94	0,348	no
apoyo_familiar (sí)	$-0{,}984$	0,454	$-2{,}17$	0,031	**sí**

El test F global ($F_{8,386} = 9{,}77$, $p = 2{,}2 \times 10^{-12}$) rechaza que todos los β_j sean cero.

Resultado. Al 5 % son significativas **reprobaciones_previas**, **educacion_madre** y **apoyo_familiar**; edad queda al borde ($p = 0{,}087$).

Pregunta b)

Interprete los coeficientes asociados a las variables tiempo_estudio, inasistencias y reprobaciones_previas, manteniendo constantes las demás covariables.

- **tiempo_estudio** ($\hat{\beta}_2 = 0{,}278$): subir un nivel en la escala de estudio semanal (1: < 2 h … 4: > 10 h) se asocia con 0,28 puntos más en la nota final, con lo demás fijo. El efecto no es significativo ($p = 0{,}29$): no puedo descartar que sea cero.
- **inasistencias** ($\hat{\beta}_3 = 0{,}032$): cada falta adicional se asocia con 0,03 puntos *más*, también no significativo ($p = 0{,}24$). El signo contraintuitivo viene de los 38 alumnos con nota 0 y 0 faltas: la base registra 0 inasistencias para quien abandonó, y eso arrastra la pendiente hacia arriba.
- **reprobaciones_previas** ($\hat{\beta}_4 = -1{,}894$): cada curso reprobado antes se asocia con 1,89 puntos menos en la nota final (casi 10 % de la escala), manteniendo constantes las demás covariables. Es el efecto más fuerte y claro del modelo ($t = -6{,}13$).

Pregunta c)

Reporte el coeficiente de determinación R^2 y el R^2 ajustado. Explique por qué el R^2 ajustado es más apropiado en este contexto.

```
s <- summary(m_full)
c(R2 = s$r.squared, R2_ajustado = s$adj.r.squared,
  n = nobs(m_full), p = length(coef(m_full)) - 1)
```

```
        R2 R2_ajustado          n          p
    0.1684      0.1512   395.0000     8.0000
```

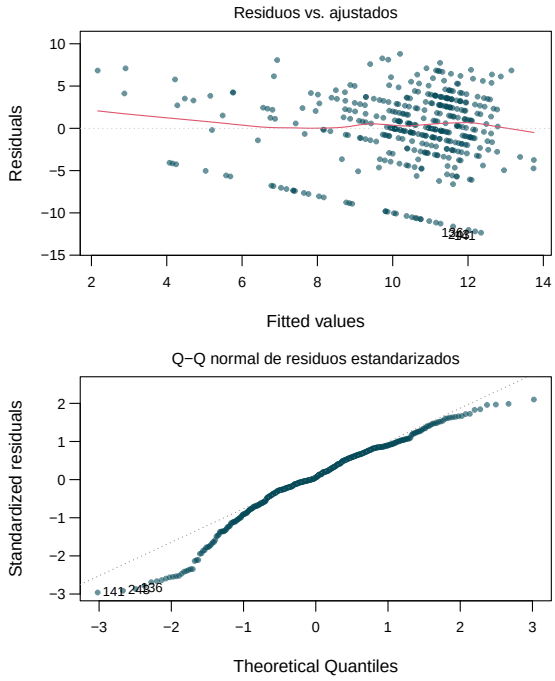
$$R^2 = 1 - \frac{SCE}{SCT} = 0{,}1684, \qquad R^2_{aj} = 1 - (1 - R^2)\frac{n-1}{n-p-1} = 1 - (0{,}8316)\frac{394}{386} = 0{,}1512$$

El modelo explica cerca del 17 % de la variabilidad de la nota final. El R^2 nunca baja al agregar variables, aunque sean ruido; el R^2_{aj} penaliza cada parámetro extra con $(n-1)/(n-p-1)$. Como aquí 5 de las 8 covariables no son significativas, el R^2_{aj} es el que permite comparar honestamente con modelos más pequeños (como el que sale del backward).

Resultado. $R^2 = 0{,}168$ y $R^2_{aj} = 0{,}151$: el modelo tiene poder explicativo bajo.

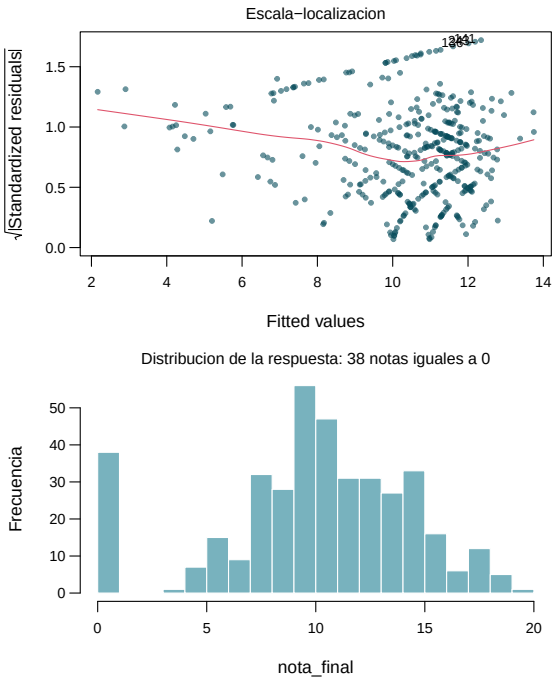
Pregunta d)

Evalúe los principales supuestos del modelo lineal (linealidad, normalidad de los residuos y homocedasticidad), incluyendo gráficos de diagnóstico y comentarios.




```
abrir("rlm-diag1", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
plot(m_full, which = 1, col = adjustcolor(azul, 0.6)
     , pch = 19, cex = 0.6,
     caption = "", sub.caption = "")
titulo("Residuos vs. ajustados")
plot(m_full, which = 2, col = adjustcolor(azul, 0.6)
     , pch = 19, cex = 0.6,
     caption = "", sub.caption = "")
titulo("Q-Q normal de residuos estandarizados")
dev.off()
```

Figura 1: *Residuos vs. ajustados (arriba) y Q-Q normal (abajo).*




```r
abrir("rlm-diag2", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
plot(m_full, which = 3, col = adjustcolor(azul, 0.6)
     , pch = 19, cex = 0.6,
     caption = "", sub.caption = "")
titulo("Escala-localizacion")
hist(est$nota_final, breaks = 0:20, col =
     adjustcolor(teal, 0.55), border = "white",
     main = "", xlab = "nota_final", ylab = "
     Frecuencia")
titulo("Distribucion de la respuesta: 38 notas
     iguales a 0")
dev.off()
```

Figura 2: *Escala-localización (arriba) y distribución de la nota final (abajo).*

```r
shapiro.test(residuals(m_full))      # normalidad
bptest(m_full)                       # homocedasticidad (Breusch-Pagan)
resettest(m_full, power = 2:3)       # linealidad / forma funcional (RESET)
```

```
        Shapiro-Wilk normality test

data:  residuals(m_full)
W = 0.96, p-value = 0.00000001


        studentized Breusch-Pagan test

data:  m_full
BP = 19, df = 8, p-value = 0.02


        RESET test

data:  m_full
RESET = 4.1, df1 = 2, df2 = 384, p-value = 0.02
```

Supuesto	Prueba	p	Conclusión
Linealidad	RESET (potencias 2 y 3)	0,020	se rechaza al 5 %
Normalidad	Shapiro-Wilk	1×10^{-8}	se rechaza
Homocedasticidad	Breusch-Pagan	0,020	se rechaza al 5 %

En el gráfico de residuos vs. ajustados aparece una **banda diagonal** de puntos con residuos de -5 a -13: son los 38 ceros (residuo $= 0 - \hat{y}_i$). Esa banda inclina la curva LOESS (no linealidad), produce la cola izquierda pesada del Q-Q y hace que la dispersión cambie con $\hat{y}$. Fuera de ella la nube es bastante homogénea. Los estimadores MCO siguen siendo insesgados, pero los errores estándar y los valores p deben leerse con cautela.

Resultado. Ninguno de los tres supuestos se cumple al 5 %, y la causa principal es la masa de ceros en la respuesta.

Pregunta e)

Analice la posible presencia de multicolinealidad utilizando el factor de inflación de la varianza (VIF).

```
vif(m_full)
```

```
                edad        tiempo_estudio          inasistencias reprobaciones_previas
               1.145                 1.073                  1.072                 1.168
     educacion_madre       educacion_padre          internet_casa        apoyo_familiar
               1.737                 1.703                  1.066                 1.086
```

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

Todos los VIF están entre 1,07 y 1,74, muy por debajo de los umbrales usuales (5 o 10). Los más altos son `educacion_madre` (1,74) y `educacion_padre` (1,70), que tienen correlación 0,62 entre sí; aun así la varianza de sus coeficientes solo se infla un 70 %.

Resultado. No hay multicolinealidad preocupante. Que `educacion_padre` no sea significativa no se debe a colinealidad, sino a que su efecto ya lo recoge `educacion_madre`.

Pregunta Backward a)

Aplique backward elimination con AIC partiendo del modelo completo. Indique qué variables son eliminadas y presente el modelo final seleccionado.

```
m_back <- step(m_full, direction = "backward", k = 2)
```

```
Start:  AIC=1147
nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
    educacion_madre + educacion_padre + internet_casa + apoyo_familiar

                       Df Sum of Sq  RSS  AIC
- educacion_padre       1         1 6878 1145
- internet_casa         1        16 6893 1145
- tiempo_estudio        1        20 6897 1146
- inasistencias         1        24 6902 1146
<none>                             6877 1147
- edad                  1        52 6930 1148
- apoyo_familiar        1        84 6961 1149
- educacion_madre       1        93 6970 1150
- reprobaciones_previas 1       669 7547 1181

Step:  AIC=1145
nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
    educacion_madre + internet_casa + apoyo_familiar

                       Df Sum of Sq  RSS  AIC
- internet_casa         1        16 6894 1143
- tiempo_estudio        1        21 6899 1144
- inasistencias         1        25 6903 1144
<none>                             6878 1145
- edad                  1        52 6930 1146
- apoyo_familiar        1        86 6964 1148
- educacion_madre       1       125 7003 1150
```

```
- reprobaciones_previas  1       676 7554 1180

Step:  AIC=1144
nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
    educacion_madre + apoyo_familiar

                        Df Sum of Sq  RSS  AIC
- tiempo_estudio         1        23 6917 1143
- inasistencias          1        29 6923 1143
<none>                               6894 1143
- edad                   1        58 6952 1145
- apoyo_familiar         1        83 6976 1146
- educacion_madre        1       143 7037 1150
- reprobaciones_previas  1       675 7569 1178

Step:  AIC=1143
nota_final ~ edad + inasistencias + reprobaciones_previas + educacion_madre +
    apoyo_familiar

                        Df Sum of Sq  RSS  AIC
- inasistencias          1        26 6943 1142
<none>                               6917 1143
- edad                   1        53 6970 1144
- apoyo_familiar         1        72 6989 1145
- educacion_madre        1       145 7062 1149
- reprobaciones_previas  1       739 7655 1181

Step:  AIC=1142
nota_final ~ edad + reprobaciones_previas + educacion_madre +
    apoyo_familiar

                        Df Sum of Sq  RSS  AIC
<none>                               6943 1142
- edad                   1        42 6985 1143
- apoyo_familiar         1        70 7012 1144
- educacion_madre        1       165 7108 1150
- reprobaciones_previas  1       727 7669 1180
```

Paso	Variable eliminada	AIC tras eliminarla
0	(modelo completo)	1146,5
1	educacion_padre	1144,6
2	internet_casa	1143,5
3	tiempo_estudio	1142,8
4	inasistencias	1142,3

En el paso 5 quitar cualquier variable sube el AIC (edad: 1143, apoyo_familiar: 1144), así que el algoritmo se detiene. `step()` reporta el AIC sin las constantes de la verosimilitud (`extractAIC`); las diferencias son las mismas que con `AIC()`.

```r
summary(m_back)
c(AIC_completo = AIC(m_full), AIC_reducido = AIC(m_back))
c(R2aj_completo = summary(m_full)$adj.r.squared,
  R2aj_reducido = summary(m_back)$adj.r.squared)
anova(m_back, m_full)               # F parcial de las variables eliminadas
```

```
Call:
lm(formula = nota_final ~ edad + reprobaciones_previas + educacion_madre +
    apoyo_familiar, data = est)

Residuals:
   Min     1Q Median     3Q    Max
-12.56  -2.04   0.21   3.04   9.10

Coefficients:
```

```
                     Estimate Std. Error t value      Pr(>|t|)
(Intercept)            14.354      3.035    4.73 0.00000314207 ***
edad                   -0.267      0.174   -1.54        0.1254
reprobaciones_previas  -1.924      0.301   -6.39 0.00000000048 ***
educacion_madre         0.621      0.204    3.04        0.0025 **
apoyo_familiaryes      -0.884      0.446   -1.98        0.0484 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.22 on 390 degrees of freedom
Multiple R-squared:  0.16,      Adjusted R-squared:  0.152
F-statistic: 18.6 on 4 and 390 DF,  p-value: 4.94e-14

AIC_completo AIC_reducido
        2270         2265
R2aj_completo R2aj_reducido
       0.1512        0.1519
Analysis of Variance Table

Model 1: nota_final ~ edad + reprobaciones_previas + educacion_madre +
    apoyo_familiar
Model 2: nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
    educacion_madre + educacion_padre + internet_casa + apoyo_familiar
  Res.Df  RSS Df Sum of Sq    F Pr(>F)
1    390 6943
2    386 6877  4      65.4 0.92   0.45
```

$$\widehat{\text{nota_final}} = 14{,}354 - 0{,}267\,\text{edad} - 1{,}924\,\text{reprobaciones_previas} + 0{,}621\,\text{educacion_madre} - 0{,}884\,\text{apoyo_familiar}_{\text{sí}}$$

Resultado. Se eliminan educacion_padre, internet_casa, tiempo_estudio e inasistencias. El modelo final conserva edad, reprobaciones_previas, educacion_madre y apoyo_familiar.

Pregunta Backward b)

Compare el AIC del modelo completo con el del modelo reducido y comente si la reducción implica una mejora en términos de parsimonia.

$$\text{AIC} = -2\ln L + 2k$$

$$\text{AIC}_{\text{completo}} = 2269{,}5\ (k=10), \qquad \text{AIC}_{\text{reducido}} = 2265{,}2\ (k=6), \qquad \Delta = 4{,}3$$

Con 4 parámetros menos el AIC baja 4,3 unidades: el modelo reducido pierde muy poco ajuste (la SCE pasa de 6877 a 6943) a cambio de ser más simple. El test F parcial de las 4 variables eliminadas ($F_{4,386} = 0{,}92$, $p = 0{,}45$) confirma que en conjunto no aportan.

Resultado. Sí hay mejora en parsimonia: menor AIC con la mitad de covariables y sin pérdida significativa de ajuste.

Pregunta Backward c)

Analice el coeficiente de determinación ajustado del modelo final y discuta los cambios respecto al modelo inicial.

Modelo	covariables	R^2	R^2_{aj}
Completo	8	0,1684	0,1512
Reducido (backward)	4	0,1600	0,1519

El R^2 baja (0,168 $\rightarrow$ 0,160) porque siempre baja al quitar variables, pero el R^2_{aj} sube ligeramente (0,1512 $\rightarrow$ 0,1519): las variables eliminadas no compensaban los grados de libertad que consumían. Además, `edad` y `apoyo_familiar` quedan con errores estándar algo menores.

Resultado. El R^2_{aj} se mantiene (incluso sube un poco) con la mitad de variables; el modelo reducido explica lo mismo con menos.

Pregunta Backward d)

Evalúe los supuestos del modelo seleccionado e interprete los resultados.

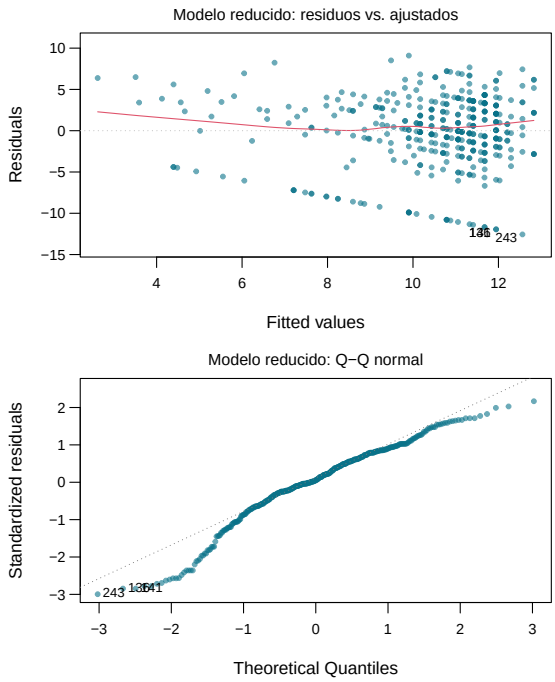


Figura 3: *Diagnóstico del modelo reducido.*

```
abrir("rlm-diag-final", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
plot(m_back, which = 1, col = adjustcolor(teal, 0.6)
     , pch = 19, cex = 0.6,
     caption = "", sub.caption = "")
titulo("Modelo reducido: residuos vs. ajustados")
plot(m_back, which = 2, col = adjustcolor(teal, 0.6)
     , pch = 19, cex = 0.6,
     caption = "", sub.caption = "")
titulo("Modelo reducido: Q-Q normal")
dev.off()
```

```
shapiro.test(residuals(m_back))
bptest(m_back)
resettest(m_back, power = 2:3)
vif(m_back)
```

```
        Shapiro-Wilk normality test
```

```
data:  residuals(m_back)
W = 0.96, p-value = 0.000000004


        studentized Breusch-Pagan test

data:  m_back
BP = 3.7, df = 4, p-value = 0.5


        RESET test

data:  m_back
RESET = 3.7, df1 = 2, df2 = 388, p-value = 0.03

                edad reprobaciones_previas       educacion_madre        apoyo_familiar
               1.091                 1.110                 1.102                 1.049
```

Prueba	Completo	Reducido	Conclusión (reducido)
RESET (linealidad)	0,020	0,030	se rechaza al 5 %
Shapiro-Wilk (normalidad)	1×10^{-8}	4×10^{-9}	se rechaza
Breusch-Pagan (homocedasticidad)	0,020	0,50	**se cumple**
VIF máximo	1,74	1,11	sin multicolinealidad

Al quitar variables desaparece la heterocedasticidad, pero la banda de ceros sigue ahí y mantiene la falta de normalidad y el RESET significativo. Para comprobar que esa es la causa, reajusté el modelo final sin los 38 ceros:

```r
# los 38 ceros corresponden a alumnos que no rindieron la evaluacion final
m_sin0 <- lm(formula(m_back), data = subset(est, nota_final > 0))
round(cbind(con_ceros = coef(m_back), sin_ceros = coef(m_sin0)), 3)
c(R2aj_sin_ceros = summary(m_sin0)$adj.r.squared,
  shapiro_p = shapiro.test(residuals(m_sin0))$p.value,
  bp_p = unname(bptest(m_sin0)$p.value))
```

```
                     con_ceros sin_ceros
(Intercept)             14.354    13.885
edad                    -0.267    -0.166
reprobaciones_previas   -1.924    -1.211
educacion_madre          0.621     0.432
apoyo_familiaryes       -0.884    -0.767
R2aj_sin_ceros      shapiro_p           bp_p
        0.1089         0.1007         0.0291
```

Sin los ceros los residuos pasan Shapiro-Wilk ($p = 0{,}10$) y todos los signos se mantienen; el efecto de `reprobaciones_previas` baja de $-1{,}92$ a $-1{,}21$ porque parte de él era "reprobar $\Rightarrow$ abandonar".

Resultado. El modelo reducido cumple homocedasticidad y no tiene multicolinealidad; la no normalidad se debe a los alumnos que abandonaron. Concluyo que **reprobaciones previas** es el factor de mayor peso (negativo), seguido de la **educación de la madre** (positivo); el apoyo familiar tiene signo negativo, que leo como causalidad inversa (las familias apoyan más a quien ya va mal). Un modelo en dos partes (abandono sí/no + nota si rinde) trataría mejor los ceros.

2

SECCIÓN

Regresión logística binaria

Heart Disease (Cleveland) · preguntas a – g

Datos y modelo

$$\log \frac{P(Y_i = 1 \mid x_i)}{1 - P(Y_i = 1 \mid x_i)} = \beta_0 + \beta_1 \,\text{edad}_i + \beta_2 \,\text{sexo}_i + \beta_3 \,\text{colesterol}_i + \beta_4 \,\text{presion_reposo}_i$$

$$+ \beta_5 \,\text{frecuencia_cardiaca_max}_i + \beta_6 \,\text{angina_ejercicio}_i + \beta_7 \,\text{depresion_st}_i$$

con $Y_i = 1$ si el paciente tiene enfermedad cardíaca. `sexo` (referencia: mujer) y `angina_ejercicio` (referencia: no) entran como factores.

```
cor_df <- read.csv("heart.csv")
cor_df$enf  <- factor(cor_df$enfermedad_cardiaca, levels = c("No", "Si"))
cor_df$sexo <- factor(cor_df$sexo, levels = 0:1, labels = c("mujer", "hombre"))
cor_df$angina_ejercicio <- factor(cor_df$angina_ejercicio, levels = 0:1,
                                  labels = c("no", "si"))
table(cor_df$enf)
```

```
 No  Si
160 137
```

Las clases están casi balanceadas: 137 enfermos (46,1 %) y 160 sanos.

Justificación de las variables. Antes de ajustar comparé cada covariable entre enfermos y sanos:

```
num <- c("edad", "colesterol", "presion_reposo", "frecuencia_cardiaca_max", "depresion_st")
t(sapply(num, function(v) {
  x <- cor_df[[v]]
  c(media_No = mean(x[cor_df$enf == "No"]), media_Si = mean(x[cor_df$enf == "Si"]),
    p_t = t.test(x ~ cor_df$enf)$p.value)
}))
prop.table(table(cor_df$sexo, cor_df$enf), 1)
prop.table(table(cor_df$angina_ejercicio, cor_df$enf), 1)
c(p_sexo = chisq.test(table(cor_df$sexo, cor_df$enf))$p.value,
  p_angina = chisq.test(table(cor_df$angina_ejercicio, cor_df$enf))$p.value)
```

```
                      media_No media_Si       p_t
edad                   52.6437   56.759 6.204e-05
colesterol            243.4938  251.854 1.650e-01
presion_reposo        129.1750  134.635 8.808e-03
frecuencia_cardiaca_max 158.5813  139.109 6.108e-14
depresion_st            0.5988    1.589 3.429e-13

             No     Si
  mujer  0.7396 0.2604
  hombre 0.4428 0.5572

        No     Si
  no 0.6850 0.3150
  si 0.2371 0.7629
   p_sexo  p_angina
2.946e-06 9.511e-13
```

Seis de las siete variables difieren claramente entre grupos: los enfermos son mayores, con más presión, menor frecuencia cardíaca máxima, mayor depresión ST, más hombres (56 % vs. 26 % de enfermos) y más angina de esfuerzo (76 % vs. 32 %). El colesterol no difiere de forma marginal ($p = 0{,}17$), pero lo mantengo porque es un factor de riesgo clásico y puede aportar ajustado por las demás. Todas son medidas clínicas baratas, disponibles antes de un cateterismo.

Pregunta a)

Ajuste el modelo de regresión logística binaria mediante el método de máxima verosimilitud.

$$\ln L(\boldsymbol{\beta}) = \sum_{i=1}^{n} \left[y_i \, x_i^{\top} \boldsymbol{\beta} - \ln\!\left(1 + e^{x_i^{\top} \boldsymbol{\beta}}\right) \right], \qquad \frac{\partial \ln L}{\partial \boldsymbol{\beta}} = \sum_{i=1}^{n} x_i \left(y_i - \pi_i \right) = \mathbf{0}$$

No tiene solución cerrada: `glm()` la resuelve por Fisher scoring (IRLS), que convergió en 5 iteraciones.

```
m_log <- glm(enf ~ edad + sexo + colesterol + presion_reposo +
               frecuencia_cardiaca_max + angina_ejercicio + depresion_st,
             family = binomial(link = "logit"), data = cor_df)
summary(m_log)
```

```
Call:
glm(formula = enf ~ edad + sexo + colesterol + presion_reposo +
    frecuencia_cardiaca_max + angina_ejercicio + depresion_st,
    family = binomial(link = "logit"), data = cor_df)

Coefficients:
                       Estimate Std. Error z value  Pr(>|z|)
(Intercept)            -2.38311    2.06517   -1.15    0.2485
edad                    0.01987    0.01952    1.02    0.3087
sexohombre              1.65158    0.36303    4.55 0.0000054 ***
colesterol              0.00616    0.00301    2.04    0.0411 *
presion_reposo          0.01424    0.00911    1.56    0.1182
frecuencia_cardiaca_max -0.02960    0.00836   -3.54    0.0004 ***
angina_ejerciciosi       1.32464    0.33709    3.93 0.0000851 ***
depresion_st             0.58259    0.14784    3.94 0.0000813 ***
---
Signif. codes:  0 ’***’ 0.001 ’**’ 0.01 ’*’ 0.05 ’.’ 0.1 ’ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 409.95  on 296  degrees of freedom
Residual deviance: 274.16  on 289  degrees of freedom
AIC: 290.2

Number of Fisher Scoring iterations: 5
```

Resultado. La devianza baja de 409,95 (modelo nulo) a 274,16 con 7 parámetros adicionales; AIC $= 290{,}2$.

Pregunta b)

Presente la tabla de estimación de los parámetros e identifique las variables estadísticamente significativas al nivel $\alpha = 0{,}05$.

Variable	$\hat{\beta}$	EE	z	p	¿Signif.?
Intercepto	$-2{,}383$	2,065	$-1{,}15$	0,249	no
edad	0,0199	0,0195	1,02	0,309	no
sexo (hombre)	1,652	0,363	4,55	$< 0{,}001$	**sí**
colesterol	0,0062	0,0030	2,04	0,041	**sí**
presion_reposo	0,0142	0,0091	1,56	0,118	no
frecuencia_cardiaca_max	$-0{,}0296$	0,0084	$-3{,}54$	$< 0{,}001$	**sí**
angina_ejercicio (sí)	1,325	0,337	3,93	$< 0{,}001$	**sí**
depresion_st	0,583	0,148	3,94	$< 0{,}001$	**sí**

Edad y presión en reposo sí diferían entre grupos por separado, pero dejan de ser significativas al ajustar: su información ya la cargan la frecuencia cardíaca máxima (que baja con la edad) y la depresión ST.

Resultado. Significativas al 5 %: **sexo, colesterol, frecuencia_cardiaca_max, angina_ejercicio y depresion_st**.

Pregunta c)

Interprete los coeficientes asociados a las variables edad, angina_ejercicio y depresion_st en términos de odds ratios.

$$OR_j = e^{\hat{\beta}_j} = \frac{\text{odds}(x_j + 1)}{\text{odds}(x_j)}$$

- **edad**: $e^{0{,}0199} = 1{,}020$. Cada año adicional multiplica los odds de enfermedad por 1,02 (+2 %); en 10 años, $e^{10(0{,}0199)} = 1{,}22$ (+22 %), con las demás variables fijas. No es significativo ($p = 0{,}31$).
- **angina_ejercicio**: $e^{1{,}325} = 3{,}76$. Un paciente con angina inducida por ejercicio tiene odds de enfermedad 3,8 veces mayores que uno sin angina, a igualdad del resto.
- **depresion_st**: $e^{0{,}583} = 1{,}79$. Cada milímetro adicional de depresión del segmento ST multiplica los odds por 1,79 (+79 %).

Pregunta d)

Calcule e interprete los odds ratios y sus intervalos de confianza al 95 %.

```
or <- exp(cbind(OR = coef(m_log), confint(m_log)))   # IC por verosimilitud perfil
round(or, 4)
```

```
                            OR  2.5 %  97.5 %
(Intercept)             0.0923 0.0015  5.1629
edad                    1.0201 0.9819  1.0603
sexohombre              5.2152 2.6183 10.9252
colesterol              1.0062 1.0003  1.0123
presion_reposo          1.0143 0.9965  1.0329
frecuencia_cardiaca_max 0.9708 0.9545  0.9864
angina_ejerciciosi      3.7608 1.9572  7.3753
depresion_st            1.7907 1.3534  2.4232
```

Los intervalos son por verosimilitud perfil (`confint` de un `glm`), mejores que $e^{\hat{\beta} \pm 1{,}96\, EE}$ cuando la log-verosimilitud no es simétrica.

Variable	OR	IC 95 %	Lectura
sexo (hombre)	5,22	[2,62 ; 10,93]	odds 5 veces mayores en hombres
angina_ejercicio (sí)	3,76	[1,96 ; 7,38]	odds casi 4 veces mayores
depresion_st	1,79	[1,35 ; 2,42]	+79 % por mm
colesterol	1,006	[1,0003 ; 1,012]	+6,4 % cada 10 mg/dl
frecuencia_cardiaca_max	0,971	[0,955 ; 0,986]	-26 % cada 10 lpm ($0{,}971^{10} = 0{,}74$)
presion_reposo	1,014	[0,997 ; 1,033]	incluye 1: no concluyente
edad	1,020	[0,982 ; 1,060]	incluye 1: no concluyente

Resultado. Los IC que no contienen al 1 coinciden con las variables significativas. Los factores de riesgo más fuertes son ser hombre y tener angina de esfuerzo; una frecuencia cardíaca máxima alta es protectora.

Pregunta e)

Evalúe la calidad del ajuste utilizando la razón de verosimilitudes, la matriz de confusión y la tasa de clasificación correcta (umbral 0,5); interprete exactitud, sensibilidad y especificidad en el contexto del diagnóstico.

```
m_nulo <- glm(enf ~ 1, family = binomial, data = cor_df)
lrtest(m_nulo, m_log)
c(R2_McFadden = 1 - as.numeric(logLik(m_log) / logLik(m_nulo)))
```

```
Likelihood ratio test

Model 1: enf ~ 1
Model 2: enf ~ edad + sexo + colesterol + presion_reposo + frecuencia_cardiaca_max +
    angina_ejercicio + depresion_st
  #Df LogLik Df Chisq Pr(>Chisq)
1   1   -205
2   8   -137  7   136     <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
R2_McFadden
     0.3312
```

$$G^2 = -2\big[\ln L_0 - \ln L_1\big] = 409{,}95 - 274{,}16 = 135{,}8 \;\sim\; \chi^2_7, \qquad p < 2\times 10^{-16}$$

Rechazo $H_0 : \beta_1 = \cdots = \beta_7 = 0$: el modelo explica significativamente más que solo la prevalencia. El R^2 de McFadden (0,33) está en el rango que se considera un buen ajuste (0,2–0,4).

```
p_hat <- fitted(m_log)
pred  <- factor(ifelse(p_hat >= 0.5, "Si", "No"), levels = c("No", "Si"))
mc <- table(Real = cor_df$enf, Predicha = pred)
mc
VN <- mc["No", "No"]; FP <- mc["No", "Si"]; FN <- mc["Si", "No"]; VP <- mc["Si", "Si"]
c(Exactitud = (VP + VN) / sum(mc), Sensibilidad = VP / (VP + FN),
  Especificidad = VN / (VN + FP), Tasa_error = (FP + FN) / sum(mc))
```

```
    Predicha
Real  No  Si
  No 133  27
  Si  37 100
   Exactitud  Sensibilidad Especificidad    Tasa_error
      0.7845        0.7299        0.8313        0.2155
```

	Clase predicha	
Clase real	No	Sí
No	VN = 133	FP = 27
Sí	FN = 37	VP = 100

$$\text{Exactitud} = \frac{100 + 133}{297} = 0{,}785$$

$$\text{Sensibilidad} = \frac{100}{100 + 37} = 0{,}730, \qquad \text{Especificidad} = \frac{133}{133 + 27} = 0{,}831$$

- **Exactitud 78,5 %**: clasifica bien a casi 4 de cada 5 pacientes (la regla trivial "todos sanos" acertaría 53,9 %).
- **Sensibilidad 73,0 %**: detecta 100 de 137 enfermos; **37 enfermos quedan como sanos**. En diagnóstico cardíaco este es el error caro, porque un enfermo no detectado no recibe tratamiento.
- **Especificidad 83,1 %**: 27 sanos serían derivados a pruebas adicionales sin necesidad; es un costo, pero menor.

Resultado. El modelo ajusta significativamente ($G^2 = 135{,}8$) y clasifica bien el 78,5 %. Con umbral 0,5 es más específico que sensible; para tamizaje convendría bajar el umbral (ver pregunta f).

Pregunta f)

Analice la capacidad predictiva del modelo mediante la curva ROC e interprete el área bajo la curva (AUC).

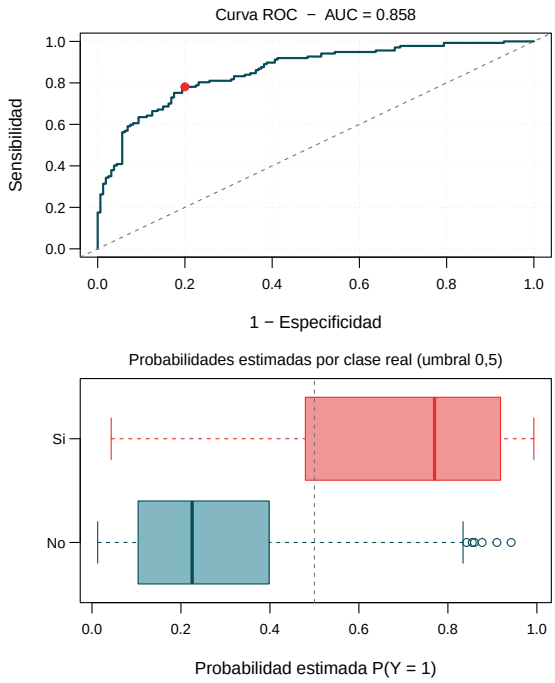


Figura 4: *Curva ROC con el punto de Youden (arriba) y probabilidades estimadas por clase (abajo).*

```
roc_log <- roc(cor_df$enf, p_hat, levels = c("No", "Si"), direction = "<", quiet = TRUE)
auc(roc_log)
ci.auc(roc_log)
coords(roc_log, "best", best.method = "youden",
       ret = c("threshold", "sensitivity", "specificity"))
```

```
Area under the curve: 0.858
95% CI: 0.816-0.9 (DeLong)
  threshold sensitivity specificity
1    0.4431       0.781         0.8
```

AUC $= 0{,}858$ (IC 95 % DeLong: 0,816–0,900): si tomo al azar un enfermo y un sano, en el 85,8 % de los casos el modelo le asigna mayor probabilidad al enfermo. Es una discriminación *buena* (0,8–0,9) y el IC está lejos de 0,5. El umbral de Youden (0,443) sube la sensibilidad a 78,1 % con especificidad de 80 %, un mejor equilibrio para tamizaje que 0,5.

Resultado. AUC $= 0{,}858$: el modelo discrimina bien entre enfermos y sanos.

Pregunta g)

Discuta las limitaciones del modelo y proponga posibles extensiones.

Todas las métricas anteriores se calcularon sobre los mismos 297 pacientes del ajuste, lo que las hace optimistas. Lo verifiqué con validación cruzada de 10 pliegues:

```
set.seed(2026)
pliegue <- sample(rep(1:10, length.out = nrow(cor_df)))
p_cv <- numeric(nrow(cor_df))
for (k in 1:10) {
  fit <- update(m_log, data = cor_df[pliegue != k, ])
  p_cv[pliegue == k] <- predict(fit, cor_df[pliegue == k, ], type = "response")
}
c(AUC_cv = as.numeric(auc(roc(cor_df$enf, p_cv, levels = c("No", "Si"),
                              direction = "<", quiet = TRUE))),
  Exactitud_cv = mean((p_cv >= 0.5) == (cor_df$enf == "Si")))
```

```
      AUC_cv Exactitud_cv
      0.8360       0.7609
```

Fuera de muestra el AUC baja de 0,858 a 0,836 y la exactitud de 78,5 % a 76,1 %: hay algo de sobreajuste, pero el modelo generaliza razonablemente.

Limitaciones

- ⛔ Solo 297 pacientes de un único hospital (Cleveland): poca validez externa.
- ⛔ Supone que el logit es lineal en cada variable continua (edad, colesterol, frecuencia cardíaca, depresión ST) y no incluye interacciones (por ejemplo, sexo $\times$ edad).
- ⛔ Deja fuera predictores muy informativos de la base: tipo de dolor torácico, vasos coloreados por fluoroscopía, talasemia y pendiente ST.
- ⛔ Es un estudio transversal: los OR son asociaciones, no efectos causales.

Extensiones

- ➕ Agregar las variables omitidas y seleccionar con AIC/BIC o con regularización (lasso).
- ➕ Términos no lineales (splines en edad y frecuencia cardíaca) o un GAM.
- ➕ Usar `diagnostico_original` (0–4) en un modelo logístico ordinal de severidad.
- ➕ Elegir el umbral según el costo relativo FN/FP y validar en una cohorte externa.

3



SECCIÓN

Análisis de componentes principales

Student Performance · preguntas a – g

Variables

Uso las 11 variables cuantitativas del enunciado, todas como numéricas:

```
est <- read.csv("student.csv")
vacp <- c("edad", "tiempo_estudio", "inasistencias", "reprobaciones_previas",
          "educacion_madre", "educacion_padre", "salud", "tiempo_libre",
          "salidas_sociales", "alcohol_dias_semana", "alcohol_fin_semana")
X <- as.matrix(est[, vacp])
round(cbind(media = colMeans(X), desv_est = apply(X, 2, sd),
            min = apply(X, 2, min), max = apply(X, 2, max)), 2)
```

```
                    media desv_est min max
edad                16.70     1.28  15  22
tiempo_estudio       2.04     0.84   1   4
inasistencias        5.71     8.00   0  75
reprobaciones_previas 0.33    0.74   0   3
educacion_madre      2.75     1.09   0   4
educacion_padre      2.52     1.09   0   4
salud                3.55     1.39   1   5
tiempo_libre         3.24     1.00   1   5
salidas_sociales     3.11     1.11   1   5
alcohol_dias_semana  1.48     0.89   1   5
alcohol_fin_semana   2.29     1.29   1   5
```

Pregunta a)

Explique por qué es necesario estandarizar las variables antes de aplicar el ACP en este contexto.

El ACP busca las direcciones de máxima varianza, así que una variable con varianza grande domina las primeras componentes solo por su escala. Aquí `inasistencias` va de 0 a 75 con $s = 8{,}0$ ($s^2 = 64$), mientras que las escalas Likert 1–5 tienen $s \approx 1$ y `reprobaciones_previas` $s = 0{,}74$ ($s^2 = 0{,}55$). Sin estandarizar, la CP1 sería prácticamente "inasistencias" (64 de unas 76 unidades de varianza total, el 84 %). Además las unidades no son comparables (años, faltas, escalas ordinales). Con

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

todas tienen varianza 1 y el ACP sobre Z equivale a diagonalizar la matriz de correlaciones R.

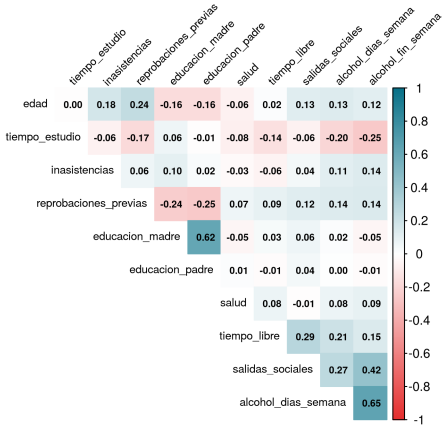
Resultado. Estandarizo para que cada variable pese lo mismo y las componentes reflejen correlaciones, no unidades.

Pregunta b)

Calcule la matriz de correlaciones entre las variables y comente brevemente la presencia de relaciones lineales relevantes.

```
R <- cor(X)
round(R, 2)
# test de esfericidad de Bartlett: H0: R = I
n <- nrow(X); p <- ncol(X)
chi2 <- -(n - 1 - (2 * p + 5) / 6) * log(det(R))
c(chi2 = chi2, gl = p * (p - 1) / 2, p_valor = pchisq(chi2, p * (p - 1) / 2, lower.tail = FALSE)
    )
```

```
                      edad tiempo_estudio inasistencias reprobaciones_previas
edad                  1.00           0.00          0.18                  0.24
tiempo_estudio        0.00           1.00         -0.06                 -0.17
inasistencias         0.18          -0.06          1.00                  0.06
reprobaciones_previas 0.24          -0.17          0.06                  1.00
educacion_madre      -0.16           0.06          0.10                 -0.24
educacion_padre      -0.16          -0.01          0.02                 -0.25
salud                -0.06          -0.08         -0.03                  0.07
tiempo_libre          0.02          -0.14         -0.06                  0.09
salidas_sociales      0.13          -0.06          0.04                  0.12
alcohol_dias_semana   0.13          -0.20          0.11                  0.14
alcohol_fin_semana    0.12          -0.25          0.14                  0.14
                      educacion_madre educacion_padre salud tiempo_libre
edad                            -0.16           -0.16 -0.06         0.02
tiempo_estudio                   0.06           -0.01 -0.08        -0.14
inasistencias                    0.10            0.02 -0.03        -0.06
reprobaciones_previas           -0.24           -0.25  0.07         0.09
educacion_madre                  1.00            0.62 -0.05         0.03
educacion_padre                  0.62            1.00  0.01        -0.01
salud                           -0.05            0.01  1.00         0.08
tiempo_libre                     0.03           -0.01  0.08         1.00
salidas_sociales                 0.06            0.04 -0.01         0.29
alcohol_dias_semana              0.02            0.00  0.08         0.21
alcohol_fin_semana              -0.05           -0.01  0.09         0.15
                      salidas_sociales alcohol_dias_semana alcohol_fin_semana
edad                              0.13                0.13               0.12
tiempo_estudio                   -0.06               -0.20              -0.25
inasistencias                     0.04                0.11               0.14
reprobaciones_previas             0.12                0.14               0.14
educacion_madre                   0.06                0.02              -0.05
educacion_padre                   0.04                0.00              -0.01
salud                            -0.01                0.08               0.09
tiempo_libre                      0.29                0.21               0.15
salidas_sociales                  1.00                0.27               0.42
alcohol_dias_semana               0.27                1.00               0.65
alcohol_fin_semana                0.42                0.65               1.00
      chi2          gl    p_valor
 7.013e+02  5.500e+01 7.286e-113
```




```
png("img/acp-corplot.png", width = 6, height = 6,
    units = "in", res = 300)
corrplot(R, method = "color", type = "upper",
    addCoef.col = "black", number.cex = 0.6,
        tl.col = "black", tl.cex = 0.7, tl.srt =
    45, diag = FALSE,
        col = colorRampPalette(c(rojo, "white",
    teal))(200))
dev.off()
```

Figura 5: *Matriz de correlaciones (triángulo superior).*

Relaciones más relevantes:

- **alcohol días de semana – fin de semana**: $r = 0{,}65$, la más fuerte.

- **educación de la madre – del padre**: $r = 0{,}62$.
- **salidas sociales** con alcohol fin de semana $(0{,}42)$, tiempo libre $(0{,}29)$ y alcohol semana $(0{,}27)$: un bloque de "vida social".
- **reprobaciones** con educación de los padres $(-0{,}24, -0{,}25)$ y con edad $(+0{,}24)$; **tiempo de estudio** con alcohol fin de semana $(-0{,}25)$.

El resto está por debajo de $|0{,}2|$ y `salud` casi no se relaciona con nada. El test de esfericidad de Bartlett ($\chi^2_{55} = 701{,}3$, $p \approx 10^{-113}$) rechaza $R = I$: hay correlación suficiente para que el ACP tenga sentido, aunque las correlaciones moderadas anticipan que la varianza se repartirá en varias componentes.

Pregunta c)

Aplique el Análisis de Componentes Principales utilizando la matriz de correlaciones.

$$R\,\mathbf{a}_k = \lambda_k\,\mathbf{a}_k, \qquad \sum_{k=1}^{11} \lambda_k = \operatorname{tr}(R) = 11, \qquad \mathrm{CP}_k = Z\,\mathbf{a}_k$$

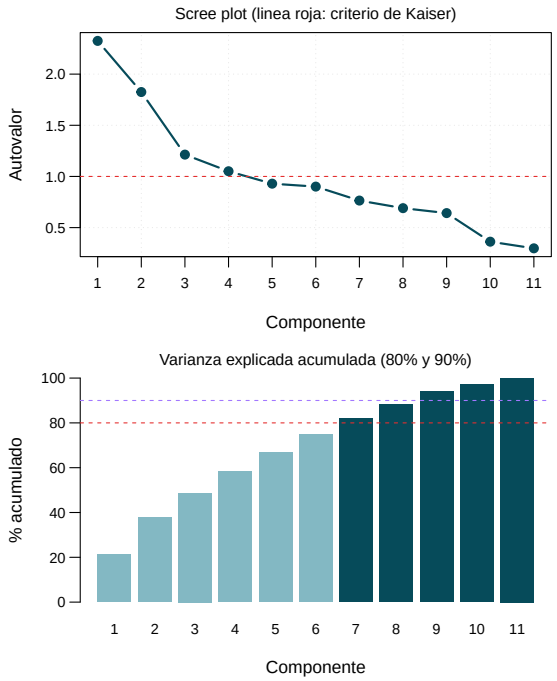
```
acp <- prcomp(X, center = TRUE, scale. = TRUE)   # equivale a usar la matriz R
vp <- acp$sdev^2
tab_vp <- data.frame(CP = paste0("CP", 1:p), autovalor = vp, var_pct = 100 * vp / sum(vp),
                     acumulada = 100 * cumsum(vp) / sum(vp))
print(tab_vp, digits = 3, row.names = FALSE)
c(Kaiser = sum(vp > 1), CP_80 = which(cumsum(vp) / sum(vp) >= 0.80)[1],
  CP_90 = which(cumsum(vp) / sum(vp) >= 0.90)[1])
```

```
   CP autovalor var_pct acumulada
  CP1     2.325   21.13      21.1
  CP2     1.825   16.59      37.7
  CP3     1.213   11.03      48.8
  CP4     1.051    9.55      58.3
  CP5     0.929    8.45      66.8
  CP6     0.901    8.19      74.9
  CP7     0.764    6.95      81.9
  CP8     0.690    6.27      88.2
  CP9     0.642    5.83      94.0
 CP10     0.362    3.29      97.3
 CP11     0.297    2.70     100.0
Kaiser  CP_80  CP_90
     4      7      9
```

Con `prcomp(scale. = TRUE)` los autovalores son los de R (suman 11) y los vectores `rotation` son las cargas $\mathbf{a}_k$.

Pregunta d)

Presente el scree plot e indique cuántos componentes deberían retenerse según la varianza explicada acumulada (80 % o 90 %).




```r
abrir("acp-scree", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
plot(vp, type = "b", pch = 19, col = azul, lwd = 2,
     xaxt = "n", xlab = "Componente",
     ylab = "Autovalor", panel.first = grid(col = "
     gray90"))
axis(1, at = 1:p); abline(h = 1, lty = 2, col = rojo
     )
titulo("Scree plot (linea roja: criterio de Kaiser)"
     )
acum <- 100 * cumsum(vp) / sum(vp)
barplot(acum, names.arg = 1:p, col = ifelse(acum <
     80, adjustcolor(teal, 0.5), azul),
        border = NA, ylim = c(0, 100), xlab = "
     Componente", ylab = "% acumulado")
abline(h = c(80, 90), lty = 2, col = c(rojo, lila))
titulo("Varianza explicada acumulada (80% y 90%)")
dev.off()
```

Figura 6: *Scree plot (arriba) y varianza acumulada con las líneas de 80 % y 90 % (abajo).*

Criterio	Componentes	Varianza retenida
Varianza acumulada $\geq$ 80 %	**7**	81,9 %
Varianza acumulada $\geq$ 90 %	9	94,0 %
Kaiser ($\lambda_k > 1$)	4	58,3 %
Codo del scree plot	3	48,8 %

Retengo **7 componentes** (criterio del 80 %): con 9 llegaría al 94 %, pero pasaría de 11 a 9 variables, que casi no reduce la dimensión. La curva cae despacio después de CP2, consecuencia de las correlaciones bajas: este conjunto no se comprime bien en pocas componentes.

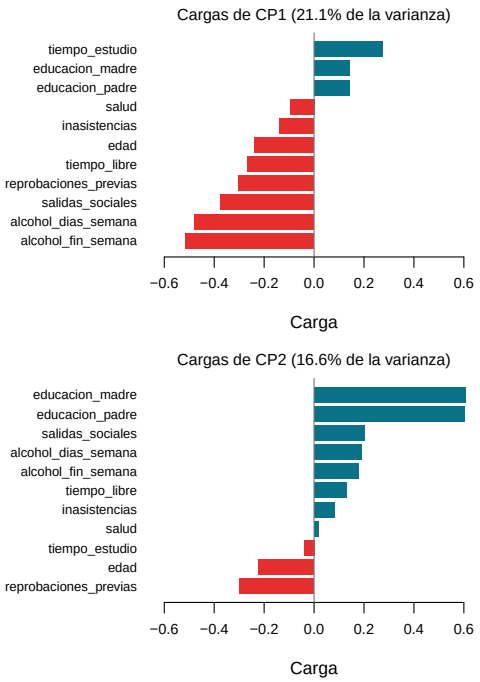
Resultado. 7 CP según el 80 % (81,9 %); 9 según el 90 %.

Pregunta e)

Interprete los dos primeros componentes en términos de las variables originales, analizando los signos y magnitudes de las cargas.

```
round(acp$rotation[, 1:4], 3)
round(cor(X, acp$x[, 1:2]), 3)   # correlacion variable-componente
```

```
                       PC1    PC2    PC3    PC4
edad                -0.238 -0.222 -0.492  0.129
tiempo_estudio       0.275 -0.040 -0.197  0.454
inasistencias       -0.138  0.080 -0.608 -0.367
reprobaciones_previas -0.302 -0.299 -0.052 -0.093
educacion_madre      0.144  0.605 -0.155 -0.003
educacion_padre      0.143  0.601 -0.068 -0.097
salud               -0.096  0.017  0.436 -0.502
tiempo_libre        -0.265  0.128  0.359  0.388
salidas_sociales    -0.374  0.203 -0.006  0.461
alcohol_dias_semana -0.480  0.191 -0.004 -0.072
alcohol_fin_semana  -0.516  0.177 -0.006 -0.067
                       PC1    PC2
edad                -0.363 -0.300
tiempo_estudio       0.419 -0.055
inasistencias       -0.210  0.109
reprobaciones_previas -0.461 -0.404
educacion_madre      0.220  0.817
educacion_padre      0.218  0.813
salud               -0.147  0.023
tiempo_libre        -0.404  0.174
salidas_sociales    -0.571  0.274
alcohol_dias_semana -0.731  0.258
alcohol_fin_semana  -0.787  0.239
```




```
round(acp$rotation[, 1:4], 3)
round(cor(X, acp$x[, 1:2]), 3)   # correlacion
    variable-componente
```

Figura 7: *Cargas de las dos primeras componentes.*

- **CP1 (21,1 %) – "estilo de vida social / riesgo"**: cargas negativas grandes en alcohol fin de semana ($-0{,}52$), alcohol semana ($-0{,}48$), salidas sociales ($-0{,}37$), reprobaciones ($-0{,}30$), tiempo libre ($-0{,}27$) y edad ($-0{,}24$), y positiva en tiempo de estudio ($+0{,}28$). Un CP1 *bajo* es un alumno que

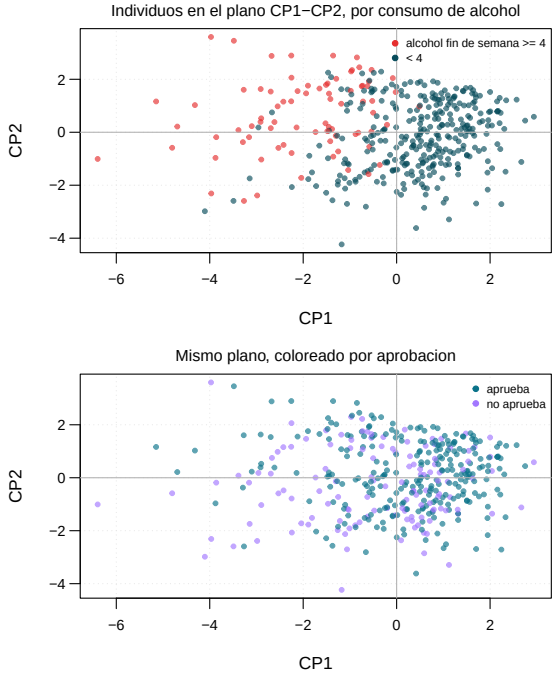
bebe, sale mucho, estudia poco, es mayor y ha reprobado; un CP1 *alto* es el perfil estudioso. (El signo global es arbitrario.)

- **CP2 (16,6 %) – "capital educativo familiar"**: dominada por educación de la madre ($+0{,}61$) y del padre ($+0{,}60$), contra reprobaciones ($-0{,}30$) y edad ($-0{,}22$). Un CP2 alto es un alumno de padres con educación superior y sin repitencia.

`salud` e `inasistencias` casi no cargan en ninguna de las dos; aparecen en CP3 (inasistencias $-0{,}61$, salud $+0{,}44$).

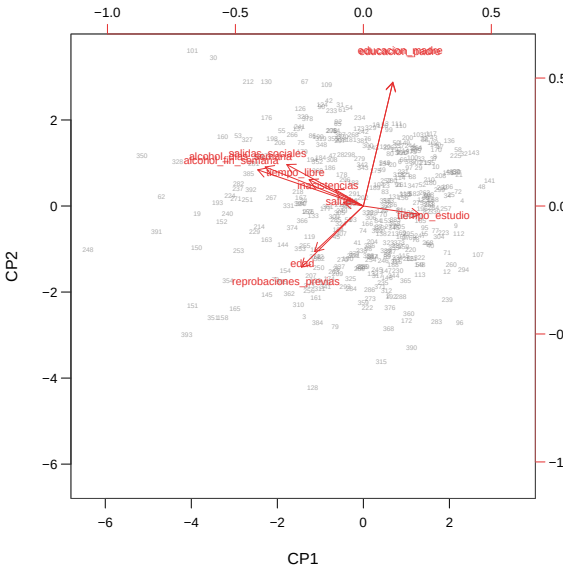
Pregunta f)

Represente gráficamente los individuos en el plano definido por los dos primeros componentes e identifique posibles patrones o agrupamientos.




```
abrir("acp-individuos", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
z <- acp$x
col_alc <- adjustcolor(ifelse(est$alcohol_fin_semana
     >= 4, rojo, azul), 0.65)
plot(z[, 1], z[, 2], pch = 19, cex = 0.6, col = col_
    alc, xlab = "CP1", ylab = "CP2",
     panel.first = grid(col = "gray90"))
abline(h = 0, v = 0, col = "gray70")
legend("topright", c("alcohol fin de semana >= 4", "
    < 4"), pch = 19, col = c(rojo, azul),
       cex = 0.7, bty = "n")
titulo("Individuos en el plano CP1-CP2, por consumo
    de alcohol")
col_ap <- adjustcolor(ifelse(est$aprueba == 1, teal,
     lila), 0.65)
plot(z[, 1], z[, 2], pch = 19, cex = 0.6, col = col_
    ap, xlab = "CP1", ylab = "CP2",
     panel.first = grid(col = "gray90"))
abline(h = 0, v = 0, col = "gray70")
legend("topright", c("aprueba", "no aprueba"), pch =
     19, col = c(teal, lila), cex = 0.7, bty = "n")
titulo("Mismo plano, coloreado por aprobacion")
dev.off()
```

Figura 8: *Puntajes de los 395 alumnos en CP1–CP2.*




```
abrir("acp-biplot", w = 6, h = 6)
biplot(acp, choices = 1:2, scale = 0, cex = c(0.4,
     0.7), col = c(adjustcolor(gris, 0.6), rojo),
       xlab = "CP1", ylab = "CP2")
dev.off()
```

Figura 9: *Biplot: individuos (gris) y cargas (flechas).*

- No hay grupos separados: la nube es continua y asimétrica, con una cola hacia CP1 negativo.
- Esa cola son los alumnos con alto consumo de alcohol el fin de semana (rojo): su CP1 medio es $-1{,}98$ frente a $0{,}50$ del resto. El biplot muestra las flechas de alcohol y salidas apuntando justo hacia ella.
- Por aprobación los puntos se mezclan, pero los aprobados están algo desplazados hacia arriba y a la derecha (CP1 medio $0{,}23$ vs. $-0{,}47$; CP2 $0{,}15$ vs. $-0{,}30$): estudiar más, beber menos y tener padres más educados va con aprobar.

Pregunta g)

Discuta si los componentes principales obtenidos podrían ser utilizados posteriormente como variables explicativas en un modelo de regresión.

Sí: es la *regresión sobre componentes principales*. Lo probé con las 7 CP retenidas para explicar la nota final:

```
k <- which(cumsum(vp) / sum(vp) >= 0.80)[1]
dat_pc <- data.frame(nota_final = est$nota_final, acp$x[, 1:k])
m_pc <- lm(nota_final ~ ., data = dat_pc)
round(summary(m_pc)$coefficients, 4)
c(R2aj_CP = summary(m_pc)$adj.r.squared,
  R2aj_originales = summary(lm(est$nota_final ~ X))$adj.r.squared,
  max_VIF_CP = max(vif(m_pc)))
```

```
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  10.4152     0.2141 48.6357   0.0000
PC1           0.6470     0.1406  4.6009   0.0000
PC2           0.8017     0.1587  5.0510   0.0000
PC3          -0.0276     0.1947 -0.1420   0.8872
PC4           0.0444     0.2092  0.2123   0.8320
PC5           0.5998     0.2224  2.6967   0.0073
PC6           0.1082     0.2259  0.4791   0.6321
PC7           0.9592     0.2453  3.9107   0.0001
        R2aj_CP R2aj_originales      max_VIF_CP
         0.1370          0.1531          1.0000
```

- ⊕ **Ventaja**: las CP son ortogonales (VIF $= 1$ exacto), así que eliminan cualquier multicolinealidad y cada coeficiente se estima de forma independiente.
- ⊕ CP1 y CP2 resultan significativas y con signo esperado: más "estilo estudioso" y más capital educativo, mejor nota.
- ⊖ **Desventaja 1**: las CP se eligen por varianza de las X, no por su relación con Y. Aquí CP5 y CP7, de poca varianza, son significativas, y CP3–CP4 no aportan.
- ⊖ **Desventaja 2**: interpretar "+1 en CP7" es difícil, y con 7 de 11 dimensiones se pierde algo de ajuste (R^2_{aj}: 0,137 frente a 0,153 con las 11 variables originales).
- ⊖ En esta base la multicolinealidad no era un problema (en el ejercicio de regresión lineal sobre esta base los VIF fueron $< 1{,}8$), por lo que el beneficio principal del ACP no aplica.

Resultado. Se pueden usar y garantizan ortogonalidad, pero aquí convienen poco: las correlaciones son bajas, se pierde interpretabilidad y ajuste. Las CP serían útiles con muchas variables muy correlacionadas o con p cercano a n; una alternativa es PLS, que elige componentes pensando en Y.

4

SECCIÓN

Análisis de conglomerados

Heart Disease (Cleveland) · Ward.D2, k-means y comparación

Variables

Uso `edad`, `presion_reposo`, `colesterol`, `frecuencia_cardiaca_max` y `depresion_st`, estandarizadas.

```
cor_df <- read.csv("heart.csv")
cor_df$enf  <- factor(cor_df$enfermedad_cardiaca, levels = c("No", "Si"))
cor_df$sexo <- factor(cor_df$sexo, levels = 0:1, labels = c("mujer", "hombre"))
cor_df$angina_ejercicio <- factor(cor_df$angina_ejercicio, levels = 0:1,
                                  labels = c("no", "si"))
vclu <- c("edad", "presion_reposo", "colesterol", "frecuencia_cardiaca_max", "depresion_st")
Y <- cor_df[, vclu]
round(rbind(media = colMeans(Y), desv_est = apply(Y, 2, sd)), 2)
Z <- scale(Y)
round(rbind(media = colMeans(Z), desv_est = apply(Z, 2, sd)), 2)
```

```
          edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
media    54.54         131.69      247.3                  149.60         1.06
desv_est  9.05          17.76       52.0                   22.94         1.17
         edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
media       0              0          0                       0            0
desv_est    1              1          1                       1            1
```

Pregunta a)

Explique por qué es necesario estandarizar las variables antes de realizar un análisis de conglomerados en este contexto.

La distancia euclidiana $d(x_i,x_j) = \sqrt{\sum_k (x_{ik} - x_{jk})^2}$ suma diferencias en unidades originales. El colesterol tiene $s = 52$ mg/dl y la depresión ST $s = 1{,}17$ mm: una diferencia típica de colesterol pesa unas $(52/1{,}17)^2 \approx 2000$ veces más que una de ST en d^2. Sin estandarizar, los grupos serían básicamente "colesterol alto / bajo". Lo comprobé: la correlación entre la distancia sin estandarizar y la diferencia de colesterol es 0,94 (figura de la pregunta b).

Resultado. Estandarizo $(z = (x - \bar{x})/s)$ para que las cinco variables clínicas contribuyan por igual a la distancia.

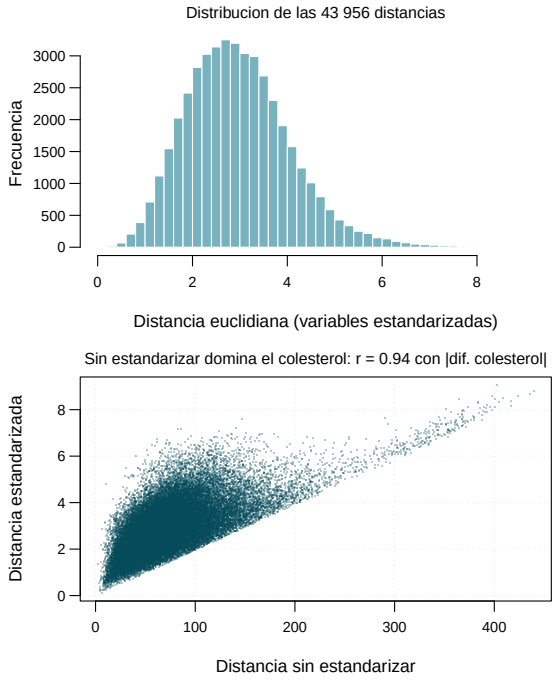
Pregunta b)

Calcule la matriz de distancias euclidianas entre los individuos a partir de las variables estandarizadas.

```
D <- dist(Z, method = "euclidean")
length(D)                                  # 297 * 296 / 2 pares
round(as.matrix(D)[1:6, 1:6], 3)
summary(as.vector(D))
```

```
[1] 43956
      1     2     3     4     5     6
1 0.000 2.402 1.757 3.569 2.907 2.393
2 2.402 0.000 2.829 5.396 4.624 4.140
3 1.757 2.829 0.000 4.296 3.657 2.905
4 3.569 5.396 4.296 0.000 2.156 3.211
5 2.907 4.624 3.657 2.156 0.000 1.943
6 2.393 4.140 2.905 3.211 1.943 0.000
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  0.123   2.179   2.877   2.965   3.626   9.049
```

La matriz es 297×297 simétrica con diagonal cero; tiene $\binom{297}{2} = 43\,956$ distancias distintas. Muestro los 6 primeros pacientes: el 2 y el 4 son los más distintos ($d = 5{,}40$) y el 1 y el 3 los más parecidos ($d = 1{,}76$). La distancia mediana es 2,88.




```r
D <- dist(Z, method = "euclidean")
length(D)                                  # 297 * 296 / 2 pares
round(as.matrix(D)[1:6, 1:6], 3)
summary(as.vector(D))
```

Figura 10: *Distribución de distancias (arriba) y distancia estandarizada vs. sin estandarizar (abajo).*

Pregunta c)

Aplique un análisis de conglomerados jerárquicos utilizando el método de Ward (ward.D2).

En cada paso Ward une los dos grupos que menos aumentan la suma de cuadrados dentro de grupos:

$$\Delta(A,B) = \frac{n_A n_B}{n_A + n_B} \, \|\bar{z}_A - \bar{z}_B\|^2$$

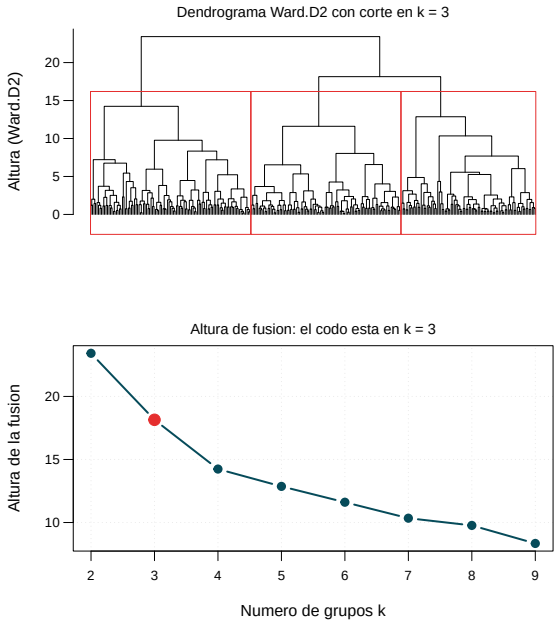
`ward.D2` trabaja con las distancias euclidianas sin elevar (las eleva internamente), que es la implementación correcta del criterio de Ward.

```r
hc <- hclust(D, method = "ward.D2")
alturas <- rev(hc$height)[1:8]
data.frame(k = 2:9, altura_fusion = round(alturas, 2),
           salto = round(c(-diff(alturas), NA), 2))
sil_hc <- sapply(2:6, function(k) mean(silhouette(cutree(hc, k), D)[, 3]))
round(setNames(sil_hc, paste0("k=", 2:6)), 3)
```

```
  k altura_fusion salto
1 2         23.42  5.27
2 3         18.15  3.91
3 4         14.24  1.37
4 5         12.87  1.26
5 6         11.61  1.27
6 7         10.34  0.57
7 8          9.77  1.43
8 9          8.34    NA
  k=2   k=3   k=4   k=5   k=6
0.199 0.146 0.147 0.139 0.134
```

Pregunta d)

Represente el dendrograma e indique el número de conglomerados que considera adecuado, justificando su elección.




```
abrir("clu-dendro", w = 6, h = 6.6)
par(mfrow = c(2, 1))
plot(hc, labels = FALSE, hang = -1, main = "", xlab
     = "", sub = "", ylab = "Altura (Ward.D2)")
rect.hclust(hc, k = 3, border = rojo)
titulo("Dendrograma Ward.D2 con corte en k = 3")
plot(2:9, alturas, type = "b", pch = 19, col = azul,
      lwd = 2, xlab = "Numero de grupos k",
     ylab = "Altura de la fusion", panel.first =
     grid(col = "gray90"))
points(3, alturas[2], pch = 19, cex = 1.6, col =
     rojo)
titulo("Altura de fusion: el codo esta en k = 3")
dev.off()
```

Figura 11: *Dendrograma Ward.D2 (arriba) y altura de las últimas fusiones (abajo).*

Elijo $k = 3$:

- Las dos últimas fusiones son los saltos grandes: 23,4 (de 2 a 1 grupo) y 18,2 (de 3 a 2). Desde $k = 4$ las fusiones bajan en pasos de apenas $\approx 1{,}3$: el codo está en $k = 3$.
- En el dendrograma, un corte a altura ≈ 16 cruza tres ramas largas y de tamaño parecido (107, 100 y 90 pacientes).
- La silueta media favorece algo a $k = 2$ (0,20 vs. 0,15). Aun así prefiero $k = 3$ porque separa un perfil clínico más (el de presión y colesterol altos, ver pregunta e), que con $k = 2$ se pierde.

Pregunta e)

Asigne cada individuo a un conglomerado y describa las principales características clínicas de cada grupo.

```
K <- 3
g_hc <- cutree(hc, k = K)
table(g_hc)
perfil <- function(g) {
  t(sapply(split(cor_df, g), function(d) c(n = nrow(d), colMeans(d[, vclu]),
    pct_hombre = 100 * mean(d$sexo == "hombre"),
    pct_angina = 100 * mean(d$angina_ejercicio == "si"),
    pct_enfermo = 100 * mean(d$enf == "Si"))))
}
round(perfil(g_hc), 1)
```

```
g_hc
  1   2   3
107 100  90
    n edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st pct_hombre
1 107 60.3          132.0      239.7                   131.5          2.0       76.6
2 100 48.0          124.9      215.4                   163.1          0.5       72.0
3  90 55.0          138.9      291.9                   156.0          0.6       52.2
  pct_angina pct_enfermo
1       51.4        72.9
2       16.0        24.0
3       28.9        38.9
```

	Grupo 1	Grupo 2	Grupo 3
n	107	100	90
Edad (años)	60,3	48,0	55,0
Presión reposo (mmHg)	132,0	124,9	**138,9**
Colesterol (mg/dl)	239,7	215,4	**291,9**
FC máxima (lpm)	**131,5**	163,1	156,0
Depresión ST (mm)	**2,0**	0,5	0,6
% hombres	76,6	72,0	52,2
% angina de esfuerzo	51,4	16,0	28,9
% con enfermedad	**72,9**	24,0	38,9

- **Grupo 1 – isquémico**: los mayores, con baja frecuencia cardíaca máxima y depresión ST alta (signos de isquemia en la prueba de esfuerzo); la mitad tiene angina.
- **Grupo 2 – joven y sano**: 48 años en promedio, buena capacidad cardíaca (163 lpm), ST casi normal y los valores más bajos de presión y colesterol.
- **Grupo 3 – metabólico**: colesterol muy alto (292) y presión alta, pero con prueba de esfuerzo casi normal; tiene la mayor proporción de mujeres.

Pregunta f)

Aplique el método de k-means considerando el mismo número de conglomerados seleccionado en el método jerárquico.

k-means minimiza $\sum_{g=1}^{3}\sum_{i\in g}\|z_i-\bar{z}_g\|^2$. Uso 50 arranques aleatorios (`nstart = 50`) para no quedarme en un mínimo local, y reetiqueto los grupos para que el grupo j sea el que más se parece al grupo j de Ward.

```r
set.seed(2026)
km <- kmeans(Z, centers = K, nstart = 50, iter.max = 100)
# reetiqueto: el grupo j de k-means es el que mas se solapa con el grupo j de Ward
eq <- apply(table(km$cluster, g_hc), 1, which.max)
km$cluster <- eq[km$cluster]; km$size <- km$size[order(eq)]
km$centers <- km$centers[order(eq), ]; rownames(km$centers) <- 1:K
km$size
round(km$centers, 2)                                   # centroides estandarizados
round(t(t(km$centers) * attr(Z, "scaled:scale") + attr(Z, "scaled:center")), 1)
c(R2_entre = km$betweenss / km$totss,
  silueta_km = mean(silhouette(km$cluster, D)[, 3]))
round(perfil(km$cluster), 1)
```

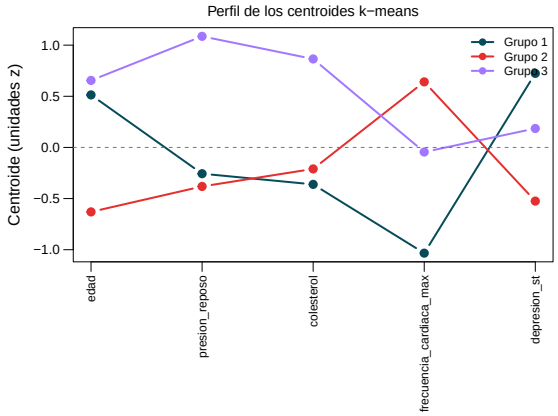
```
[1]  85 142  70
   edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
1  0.51          -0.26      -0.36                  -1.03         0.72
2 -0.63          -0.38      -0.21                   0.64        -0.52
```

```
3  0.66           1.09       0.87                   -0.04         0.19
  edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
1 59.2          127.1      228.6                   125.9          1.9
2 48.8          124.9      236.4                   164.3          0.4
3 60.5          151.0      292.3                   148.6          1.3
  R2_entre silueta_km
    0.3533     0.2276
    n edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st pct_hombre
1  85 59.2          127.1      228.6                   125.9          1.9       78.8
2 142 48.8          124.9      236.4                   164.3          0.4       68.3
3  70 60.5          151.0      292.3                   148.6          1.3       52.9
  pct_angina pct_enfermo
1       54.1        74.1
2       16.2        23.2
3       40.0        58.6
```

Los tres grupos explican el 35,3 % de la variabilidad total (SC_{entre}/SC_{total}).

Pregunta g)

Analice los centroides obtenidos e interprete los perfiles de cada grupo en términos de riesgo cardiovascular.




```
abrir("clu-centroides", w = 6, h = 4.6)
par(mar = c(9, 4, 1.8, 1))
matplot(t(km$centers), type = "b", pch = 19, lty =
    1, lwd = 2, col = pal[1:K],
       xaxt = "n", xlab = "", ylab = "Centroide (
    unidades z)")
axis(1, at = 1:5, labels = vclu, las = 2, cex.axis =
     0.75)
abline(h = 0, lty = 2, col = gris)
legend("topright", paste("Grupo", 1:K), col = pal[1:
    K], pch = 19, lwd = 2, cex = 0.75, bty = "n")
titulo("Perfil de los centroides k-means")
dev.off()
```

Figura 12: *Centroides de k-means en unidades z.*

Grupo	Edad	Presión	Colest.	FC máx.	ST	% enfermos
1 ($n = 85$)	59,2	127,1	228,6	**125,9**	**1,9**	**74,1**
2 ($n = 142$)	48,8	124,9	236,4	164,3	0,4	23,2
3 ($n = 70$)	60,5	**151,0**	**292,3**	148,6	1,3	58,6

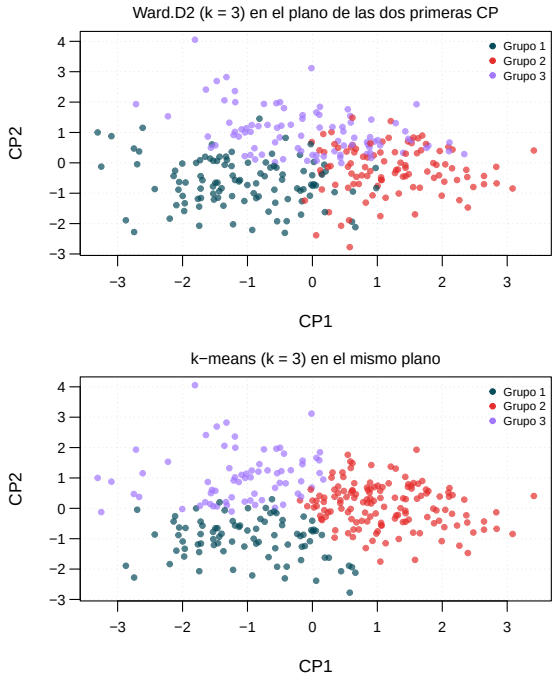
- **Grupo 1 – riesgo alto (isquémico)**: centroide con FC máxima a $-1{,}03$ desviaciones y ST a $+0{,}72$. Es la respuesta anormal al esfuerzo típica de enfermedad coronaria; 3 de cada 4 están enfermos.
- **Grupo 2 – riesgo bajo**: todos los valores por debajo de la media salvo la FC máxima ($+0{,}64$). Jóvenes con buena reserva cardíaca; 23 % de enfermos.
- **Grupo 3 – riesgo intermedio-alto (factores clásicos)**: presión ($+1{,}09$) y colesterol ($+0{,}87$) altos y mayor edad. Aún sin daño evidente en la prueba de esfuerzo, el 59 % ya está enfermo: es el grupo de prevención.

Pregunta Comparación a)

Compare los conglomerados obtenidos mediante los métodos ward.D2 y k-means.

```
tab_cmp <- table(Ward = g_hc, kmeans = km$cluster)
tab_cmp
ari <- function(a, b) {                          # indice de Rand ajustado
  t <- table(a, b); n <- sum(t); s <- sum(choose(t, 2))
  sa <- sum(choose(rowSums(t), 2)); sb <- sum(choose(colSums(t), 2))
  e <- sa * sb / choose(n, 2)
  (s - e) / ((sa + sb) / 2 - e)
}
c(ARI = ari(g_hc, km$cluster),
  acuerdo_max = sum(apply(tab_cmp, 1, max)) / sum(tab_cmp),
  silueta_ward = mean(silhouette(g_hc, D)[, 3]),
  silueta_kmeans = mean(silhouette(km$cluster, D)[, 3]))
```

```
     kmeans
Ward  1  2  3
   1 78 10 19
   2  7 91  2
   3  0 41 49
          ARI    acuerdo_max   silueta_ward silueta_kmeans
       0.4014         0.7340         0.1457         0.2276
```




```
abrir("clu-plano", w = 5.5, h = 6.6)
par(mfrow = c(2, 1))
pc <- prcomp(Z)$x
plot(pc[, 1], pc[, 2], pch = 19, cex = 0.7, col =
     adjustcolor(pal[g_hc], 0.7),
     xlab = "CP1", ylab = "CP2", panel.first = grid(
     col = "gray90"))
legend("topright", paste("Grupo", 1:K), pch = 19,
     col = pal[1:K], cex = 0.7, bty = "n")
titulo("Ward.D2 (k = 3) en el plano de las dos
     primeras CP")
plot(pc[, 1], pc[, 2], pch = 19, cex = 0.7, col =
     adjustcolor(pal[km$cluster], 0.7),
     xlab = "CP1", ylab = "CP2", panel.first = grid(
     col = "gray90"))
legend("topright", paste("Grupo", 1:K), pch = 19,
     col = pal[1:K], cex = 0.7, bty = "n")
titulo("k-means (k = 3) en el mismo plano")
dev.off()
```

Figura 13: *Los dos agrupamientos en el plano de las dos primeras CP de las 5 variables.*

- ✔ Coinciden en el 73,4 % de los pacientes (78 + 91 + 49 de 297). El índice de Rand ajustado es 0,40: acuerdo moderado.
- ✔ Los grupos 1 y 2 son casi los mismos (73 % y 91 % de coincidencia).
- ⇄ La diferencia está en el grupo 3: Ward lo forma con todo el colesterol alto (90 pacientes); k-means pasa 41 de ellos al grupo 2 y se queda con un grupo 3 más extremo (presión 151, colesterol 292). Por eso k-means queda con un grupo 2 más grande (142).

⚖ k-means logra grupos más compactos: silueta 0,23 frente a 0,15 de Ward.

Pregunta Comparación b)

Discuta las similitudes y diferencias entre ambos enfoques.

	Ward.D2 (jerárquico)	**k-means (no jerárquico)**
Criterio	Minimiza el aumento de SC dentro en cada fusión	Minimiza la SC dentro total
Número de grupos	Se decide después, mirando el dendrograma	Hay que fijarlo antes
Asignaciones	Definitivas: una fusión no se deshace	Se reasignan en cada iteración
Resultado	Determinista	Depende del arranque (uso 50)
Costo	$O(n^2)$ en memoria (matriz de distancias)	Lineal en n, escala a bases grandes
Aquí	Silueta 0,15; grupos 107/100/90	Silueta 0,23; grupos 85/142/70

Ambos comparten la distancia euclidiana, las variables estandarizadas y la misma función objetivo (suma de cuadrados dentro), por eso llegan a perfiles parecidos. En la práctica son complementarios: Ward sirve para elegir k y k-means para refinar las asignaciones.

Pregunta Comparación c)

Analice la relación entre los conglomerados obtenidos y la variable enfermedad_cardiaca.

```
t_hc <- table(Ward = g_hc, enf = cor_df$enf); t_km <- table(kmeans = km$cluster, enf = cor_df$
    enf)
cbind(t_hc, pct_Si = round(100 * prop.table(t_hc, 1)[, "Si"], 1))
cbind(t_km, pct_Si = round(100 * prop.table(t_km, 1)[, "Si"], 1))
chisq.test(t_hc)
chisq.test(t_km)
# V de Cramer
sqrt(chisq.test(t_km)$statistic / (sum(t_km) * (min(dim(t_km)) - 1)))
```

```
  No Si pct_Si
1 29 78   72.9
2 76 24   24.0
3 55 35   38.9
   No Si pct_Si
1  22 63   74.1
2 109 33   23.2
3  29 41   58.6

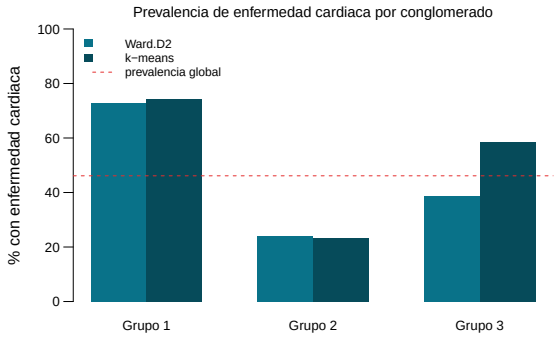
        Pearson's Chi-squared test

data:  t_hc
X-squared = 52, df = 2, p-value = 4e-12


        Pearson's Chi-squared test

data:  t_km
X-squared = 61, df = 2, p-value = 5e-14

X-squared
   0.4535
```




```r
t_hc <- table(Ward = g_hc, enf = cor_df$enf); t_km <-
     table(kmeans = km$cluster, enf = cor_df$enf)
cbind(t_hc, pct_Si = round(100 * prop.table(t_hc, 1)
    [, "Si"], 1))
cbind(t_km, pct_Si = round(100 * prop.table(t_km, 1)
    [, "Si"], 1))
chisq.test(t_hc)
chisq.test(t_km)
# V de Cramer
sqrt(chisq.test(t_km)$statistic / (sum(t_km) * (min(
    dim(t_km)) - 1)))
```

Figura 14: *Porcentaje de enfermos por grupo (línea roja: prevalencia global, 46,1 %).*

- ✔ La relación es fuerte en ambos métodos: $\chi^2_2 = 52$ (Ward) y $\chi^2_2 = 61$ (k-means), con $p < 10^{-11}$. La V de Cramer de k-means es 0,45 (asociación moderada a fuerte).
- ✔ El grupo 1 tiene 73–74 % de enfermos y el grupo 2, 23–24 %: una diferencia de 3 veces, sin haberle mostrado nunca la etiqueta al algoritmo.
- ⇄ En el grupo 3 los métodos difieren (39 % vs. 59 %): el grupo 3 más extremo de k-means concentra más enfermos, por eso su asociación es más fuerte.
- ⚖ Comparado con la regresión logística sobre esta misma base (AUC 0,86), el enfoque no supervisado separa menos, porque no usa sexo ni angina y no optimiza la predicción; a cambio entrega perfiles clínicos interpretables (isquémico, sano, metabólico).

Resultado. Los conglomerados, construidos solo con 5 variables clínicas, recuperan buena parte de la estructura de la enfermedad: el perfil “isquémico” (baja FC máxima, ST alta) concentra a los enfermos y el perfil “joven sano” a los sanos.